

StaticKD: Klasifikasi Topik Berita IPTC Multibahasa Secepat *Language Identification* melalui *Knowledge Distillation* ke Tabel Logit Token Statis

Obi Kastanya and Ananta Dwi Prayoga Alwy

Abstrak—Klasifikasi artikel berita ke taksonomi IPTC Media Topic dibutuhkan untuk menyaring jutaan artikel per hari. Namun pengklasifikasi IPTC multibahasa terbuka yang ada, berbasis XLM-RoBERTa-large, membutuhkan 1.239–2.971 ms per artikel pada satu *core* CPU. Penelitian ini mengusulkan StaticKD, yaitu *knowledge distillation* dari pengklasifikasi tersebut ke *student* berbasis *static embedding* multibahasa. Kepala linear *student* dilipat sehingga seluruh model menjadi satu tabel berisi 17 logit per token. *Teacher* melabeli 285.999 artikel tak berlabel dari 69 bahasa. Untuk evaluasi, kami membangun set uji gabungan berisi 12.744 artikel dari 47 bahasa dengan label yang independen dari *teacher*: anotasi manusia serta rubrik dan kategori penerbit yang dipetakan ke pohon IPTC, disertai kontrol kontaminasi dan *site-cluster bootstrap*. Pada set uji ini, StaticKD mencapai macro-F1 0,545 (*teacher* 0,598; 91,1%) dengan *throughput* 473 artikel per detik per *core*, sekitar 616 kali lebih cepat dari *teacher* ONNX int8, dalam model 34 MB yang hanya membutuhkan NumPy. StaticKD juga lebih akurat daripada fastText dan TF-IDF + SVM yang didistilasi dengan data yang sama. Ablasi dengan lima *seed* per varian menunjukkan bahwa keberhasilannya terutama berasal dari data distilasi multibahasa dan inisialisasi embedding yang selaras lintas bahasa, bukan dari *soft label*. *Ensemble* beberapa *seed* dapat dilipat ke satu tabel tanpa biaya inferensi. Kelemahan utama ada pada bahasa yang tidak terwakili di data distilasi maupun pra-latih.

Kata Kunci—Klasifikasi topik berita, IPTC Media Topic, *knowledge distillation*, *static embedding*, klasifikasi teks multibahasa, bahasa sumber daya rendah, efisiensi inferensi, CPU.

I. PENDAHULUAN

INDUSTRI data analitik memproses jutaan artikel berita setiap hari dalam puluhan bahasa. Agar analisis lanjutan tetap terarah dan murah, artikel perlu dikelompokkan ke topik terstandar sedini mungkin di dalam *pipeline*, sehingga hanya topik yang relevan yang diproses lebih jauh. Taksonomi yang paling banyak dipakai kantor berita adalah IPTC Media Topic dari International Press Telecommunications Council, yang level teratasnya terdiri atas 17 topik seperti *politics*, *economy*, *business and finance*, dan *sport* [1], [2].

Kuzman dan Ljubešić [2] merilis pengklasifikasi IPTC multibahasa terbuka pertama. GPT-4o melabeli ribuan artikel dalam empat bahasa, lalu label tersebut dipakai untuk melakukan *fine-tuning* XLM-RoBERTa-large [3]. Model yang dihasilkan menyamai GPT-4o pada *test set* manusia, dan resep

LLM teacher–encoder student yang sama kemudian dipakai untuk melabeli jutaan pidato parlemen [4]. Kelompok yang sama juga menegaskan bahwa *encoder* yang di-*fine-tune* lebih praktis daripada LLM untuk anotasi berskala besar karena biaya dan latensinya lebih rendah [5], [6]. Namun *encoder* berukuran 559,9 juta parameter tetap mahal. Tanpa GPU, satu artikel membutuhkan 2.971 ms per *core* CPU, dan konfigurasi CPU tercepatnya (ONNX int8) masih membutuhkan 1.239 ms (Subbagian IV-D). Biaya inferensi ini tidak dilaporkan dalam penelitian-penelitian tersebut, padahal inferensi mendominasi jejak biaya dan energi model yang sudah di-*deploy* [7], [8].

Kebutuhan praktis yang kami targetkan serupa dengan fastText *language identification* [9]: satu model kecil yang bekerja untuk banyak bahasa dalam hitungan milidetik di CPU. Alternatif yang ada belum memenuhi kebutuhan ini.

- *Parameter-efficient fine-tuning* seperti LoRA [10], [11] dan KD-LoRA [12] menurunkan biaya *training*, bukan biaya inferensi. Setelah adapter digabungkan, model tetap sebesar *backbone*-nya.
- Transformer kecil hasil distilasi [13], [14] hanya mempercepat satu orde besaran.
- Kuantisasi [15] hanya memberi percepatan dengan faktor konstan.
- fastText sangat cepat, tetapi embedding-nya dilatih dari nol sehingga tidak ada transfer lintas bahasa. Padahal data berlabel IPTC hanya tersedia untuk empat bahasa.

Penelitian ini mengajukan StaticKD, yaitu *knowledge distillation* [16], [17] dari pengklasifikasi IPTC XLM-R-large ke *student* yang, setelah *training*, hanya berupa *satu tabel berisi 17 logit per token*. Tiga pengamatan mendasarinya:

- 1) *Teacher* yang kuat lintas bahasa dapat melabeli berita tak berlabel dalam bahasa apa pun tanpa biaya anotasi.
- 2) *Static embedding* multibahasa yang didistilasi dari *sentence encoder* [18]–[20] menempatkan kata yang bermakna sama dalam bahasa berbeda di posisi yang berdekatan, dengan biaya inferensi berupa *lookup*.
- 3) Topik berita sangat ditentukan oleh kosakata, sehingga representasi *bag-of-words* cukup kompetitif untuk klasifikasi topik [21], [22].

Karena kepala klasifikasinya linear, rata-rata embedding dan kepala tersebut dapat dilipat menjadi tabel token. Inferensi kemudian hanya berupa tokenisasi dan rata-rata baris tabel, cukup dengan NumPy.

O. Kastanya (NRP 6025252015) dan A. D. P. Alwy (NRP 6025252007) berasal dari [TODO: program studi, departemen, institusi, kota, negara]. E-mail: [TODO: alamat e-mail penulis korespondensi].

Klaim multibahasa membutuhkan evaluasi multibahasa dengan label yang independen dari *teacher*. *Test set* manusia Kuzman dan Ljubešić tidak publik dan hanya mencakup empat bahasa, sedangkan SIB-200 [23] mencakup 205 bahasa tetapi berupa kalimat pendek dengan taksonomi non-IPTC. Karena itu kami membangun set uji gabungan berisi 12.744 artikel dari 47 bahasa. Set ini menggabungkan artikel CC-NEWS 2024–2026 berlabel rubrik penerbit (metadata JSON-LD schema.org [24]) dan dataset publik berlabel manusia maupun kategori penerbit [25]–[28]. Seluruh label dipetakan ke pohon IPTC Media Topic resmi.

Pertanyaan penelitian (*research question*, RQ) yang dijawab adalah sebagai berikut.

- **RQ1 (biaya):** Berapa biaya inferensi CPU pengklasifikasi IPTC *teacher*, dan berapa besar StaticKD menurunkan biaya?
- **RQ2 (akurasi):** Berapa besar akurasi *teacher* yang dipertahankan StaticKD pada label yang independen dari *teacher*, dibandingkan *baseline* berbiaya serupa (fastText, TF-IDF + SVM) dan berbiaya lebih tinggi (MiniLM-L6, DistilmBERT)?
- **RQ3 (komponen):** Komponen distilasi apa yang menentukan keberhasilan *student* berkapasitas sangat rendah ini? Yang diuji: *soft label*, data multibahasa, inisialisasi embedding, *fine-tuning* embedding, *token dropout*, *temperature*, dan *ensemble*.
- **RQ4 (generalisasi):** Di bahasa, label, dan sumber label mana StaticKD lemah, dan faktor apa yang menjelaskannya?

Kontribusi penelitian ini adalah sebagai berikut.

- 1) **StaticKD**, resep distilasi *teacher* transformer multibahasa ke tabel logit token yang diinisialisasi dari *static embedding* lintas bahasa. Model akhirnya berukuran 34 MB, hanya membutuhkan *numpy* dan *tokenizers*, dan memproses 473 artikel per detik per *core*. Kami juga menunjukkan tiga sifat *student* berkapasitas sangat rendah ini:
 - manfaat distilasi berasal dari *transfer set* multibahasa dan inisialisasi yang selaras lintas bahasa, bukan dari *soft label*: label keras setara, dan $\tau \geq 2$ merugikan;
 - *fine-tuning* embedding menaikkan akurasi indistribusi tetapi mengurangi transfer ke bahasa tanpa data distilasi;
 - *ensemble* beberapa *seed* dapat dilipat menjadi satu tabel tanpa biaya inferensi.
- 2) **Set uji IPTC multibahasa** berisi 12.744 artikel dari 47 bahasa dengan label yang independen dari *teacher*. Set ini dilengkapi aturan pemetaan rubrik ke pohon IPTC yang tervalidasi, deduplikasi lintas sumber, kontrol kontaminasi terhadap seluruh data latih, dan *site-cluster bootstrap* untuk interval kepercayaan.
- 3) **Analisis empiris lengkap**: ablasi dengan lima *seed* per varian, *frontier* akurasi–biaya dari tujuh keluarga model yang diukur hanya di CPU dengan protokol *pinning* untuk CPU *hybrid*, serta analisis per bahasa, per label,

dan per asal label, termasuk bahasa yang sama sekali tidak ada di data distilasi.

- 4) **Rilis** kode, notebook yang mereproduksi setiap angka naskah ini, model, dan manifest set uji.

Bagian II membahas penelitian terkait. Bagian III menjelaskan data, konstruksi set uji, metode, dan protokol evaluasi. Bagian IV menyajikan hasil, Bagian V membahasnya, Bagian VI memuat keterbatasan, dan Bagian VII menyimpulkan.

II. PENELITIAN TERKAIT

A. Klasifikasi Topik Berita Multibahasa dan Skema IPTC

Sumber daya klasifikasi topik berita umumnya memakai taksonomi yang berbeda-beda dan berfokus pada satu bahasa atau satu wilayah. Contohnya:

- MasakhaNEWS: 16 bahasa Afrika dan en/fr, 7 kategori [25];
- L3Cube-IndicNews: 10 bahasa India, kategori situs penerbit [27];
- berita Bangla, 8 kategori penerbit [28];
- N24News: rubrik New York Times [29].

MN-DS [26] adalah satu-satunya dataset publik yang dianotasi manusia langsung dengan topik IPTC level atas, tetapi hanya berbahasa Inggris. SIB-200 [23] mencakup 205 bahasa, tetapi berupa kalimat Flores-200 dengan tujuh topik non-IPTC. Kuzman dan Ljubešić [2] menunjukkan bahwa label GPT-4o dapat menggantikan anotasi manusia untuk IPTC, sejalan dengan temuan bahwa LLM dapat menyaingi anotator *crowd* [30]. Meski begitu, LLM belum menggantikan model yang di-*fine-tune* untuk klasifikasi berskala besar [5], [31]. Satu-satunya pengklasifikasi IPTC multibahasa terbuka adalah *encoder* 560 juta parameter, dan belum ada pengklasifikasi IPTC murah yang dievaluasi pada berita nyata di banyak bahasa.

B. Distilasi Pengklasifikasi Transformer ke Student Ringkas

Distilasi melatih model murah untuk meniru model mahal, sering kali pada data tak berlabel yang dilabeli *teacher* [16], [17]. Pada klasifikasi teks, hampir semua penelitian mempertahankan *student* transformer: TinyBERT, MiniLMv2, XtremeDistil [13], [14], [32], distilasi LLM ke T5 [33], dan distilasi lintas bahasa untuk bahasa sumber daya rendah [34]–[36]. Survei terbaru [37], [38] menempatkan distilasi berdampingan dengan kuantisasi dan pemangkasan sebagai teknik kompresi utama.

Karya yang paling dekat dengan StaticKD adalah *Sparse Distillation* [39]. RoBERTa-large didistilasi ke *deep averaging network* dengan tabel n-gram yang sangat besar, dan hasilnya ratusan kali lebih cepat pada tugas satu kalimat berbahasa Inggris. StaticKD berbeda dalam tiga hal:

- 1) tabelnya diinisialisasi dari *static embedding* multibahasa yang sudah selaras lintas bahasa, bukan dilatih dari nol;
- 2) kepala linearnya dilipat sehingga setiap token hanya menyimpan 17 angka;
- 3) sasarannya klasifikasi dokumen berita dalam 69 bahasa, termasuk evaluasi pada bahasa yang tidak ada di data distilasi.

LoRA dan KD-LoRA [10]–[12], [40] tidak termasuk kategori ini karena biaya inferensinya tetap sebesar *backbone*.

C. Temperature dan Capacity Gap

Efektivitas distilasi bergantung pada kesenjangan kapasitas *teacher* dan *student* [41], [42]. Kesenjangan optimal pada distilasi model bahasa bahkan mengikuti hukum empiris [43], [44]. Beberapa penelitian terkait membahas cara mengatasinya:

- DIST melonggarkan pencocokan KL ketika *teacher* jauh lebih kuat [45];
- *temperature* dijadikan hiperparameter yang dipelajari [46] atau dibuat asimetris [47];
- standardisasi logit menghilangkan kewajiban *student* meniru skala logit *teacher* [48];
- KL dipecah menjadi bagian kelas target dan non-target [49];
- analisis terbaru menunjukkan bahwa KL di bawah *capacity mismatch* mendistorsi peringkat kelas [50].

Distilasi dipandang sebagai *function matching* yang diuntungkan oleh augmentasi konsisten [51], dan *fidelity* terhadap *teacher* tidak selalu sejalan dengan generalisasi [52], [53]. Hampir semua temuan ini berasal dari *student* jaringan dalam. Perilaku *temperature* pada kesenjangan ekstrem, yaitu dari 560 juta parameter ke satu lapisan linear di atas rata-rata embedding, belum dikarakterisasi.

D. Static Embedding dan Inferensi Efisien di CPU

Model2Vec [18] dan Wada dkk. [19] mengekstrak embedding kata statis dari *sentence transformer*, dan rata-ratanya menghasilkan embedding kalimat yang kompetitif. Varian potion-multilingual didistilasi dari BGE-M3 [20] untuk 101 bahasa, dan penelitian lain menunjukkan bahwa agregasi token statis dapat mendekati model BERT [54], [55]. Embedding ini umumnya dievaluasi sebagai embedding umum pada *benchmark* bergaya MTEB [56], bukan sebagai *student* distilasi untuk taksonomi tertentu. Penelitian efisiensi NLP [7], [8] menganjurkan pelaporan biaya inferensi. Namun sedikit yang melaporkan latensi CPU dengan sedikit *thread* terhadap *teacher* terkuantisasi, dan sedikit pula yang memperhitungkan bahwa biaya per bahasa bergantung pada tokenisasi [57].

E. Set Uji Berlabel Silver, Kontaminasi, dan Ketergantungan Sampel

Kategori penerbit sudah lama dipakai sebagai label topik [27], [29], tetapi biasanya hanya untuk satu penerbit atau satu bahasa. Metadata `articleSection` schema.org [24] belum pernah dipetakan ke taksonomi standar lintas puluhan bahasa. Label *silver* mengandung kesalahan [58]–[60], sehingga validitasnya perlu diperiksa. Kontaminasi antara data latih dan data uji perlu diukur untuk setiap *benchmark* [61]–[63], dan deduplikasi *near-duplicate* dengan MinHash [64], [65] menjadi praktik standar. Uji signifikansi di NLP [66], [67] umumnya mengasumsikan sampel independen, padahal artikel dari situs yang sama saling bergantung. Karena itu kami memakai *cluster bootstrap* [68] dan melaporkan variasi antar-seed [69].

III. METODOLOGI

A. Kerangka Penelitian

Gbr. 1 merangkum alur penelitian yang terdiri atas tujuh tahap.

- 1) Pengumpulan korpus distilasi.
- 2) Pelabelan korpus oleh *teacher*.
- 3) *Training* StaticKD dan *baseline* pada data yang sama.
- 4) Konstruksi set uji independen.
- 5) Evaluasi akurasi dengan uji statistik.
- 6) *Benchmark* CPU.
- 7) Analisis per subkelompok.

Tahap 1–3 dan 4 dijalankan terpisah: resep StaticKD ditetapkan dari set *development* sebelum set uji dibangun, dan tidak ada hiperparameter yang dipilih berdasarkan set uji.

B. Formulasi Masalah

Diberikan artikel berita d (judul dan isi, 512 kata pertama, sama dengan [2]) dalam bahasa apa pun, model memprediksi satu label $y \in \mathcal{Y}$ dari 17 topik IPTC level atas. *Teacher* f_T menghasilkan logit $\mathbf{z}^T(d) \in \mathbb{R}^{17}$. Tujuannya adalah *student* f_S dengan biaya inferensi $O(n)$ operasi penjumlahan untuk n token, tanpa perkalian matriks dan tanpa pustaka *deep learning*, yang akurasi terhadap label independen sedekat mungkin dengan f_T .

C. Data Distilasi dan Set Development

EMMediaTopic 1.0 [2], [70] berisi artikel berbahasa Katalan, Yunani, Kroasia, dan Slovenia yang dilabeli GPT-4o.

- Split *train* (20.000 artikel) dipakai sebagai data distilasi.
- Split *dev* (1.000 artikel, median 218 kata) tidak pernah dipakai melatih *teacher* maupun *student*. Split ini menjadi set *development* untuk memilih resep.

Korpus CC-News multibahasa [71] diambil dari arsip 2019–2021 dengan aturan berikut.


- 1) Hanya dokumen yang bahasa metadatanya sama dengan hasil fastText-LID.
- 2) Teks berupa judul dan isi, minimal 75 kata (200 karakter untuk ja, zh, th, my), dipotong ke 512 kata.
- 3) Maksimal 150 dokumen per situs.
- 4) Split *held-out* dibuat per domain: seluruh dokumen dari sebagian situs disisihkan, maksimal 20% per bahasa.
- 5) Sebanyak 156.157 dokumen tambahan (maksimal 5.000 per bahasa, maksimal 400 per situs) diambil hanya dari situs *train*.

Total data distilasi adalah 285.999 dokumen dari 69 bahasa (median 269 kata).

Split *held-out* bersifat *domain-disjoint* di dalam setiap bahasa. Beberapa situs multibahasa (misalnya bbc.com) juga muncul di bahasa lain di data distilasi, sehingga artikelnya dikeluarkan. Set *fidelity* akhirnya berisi 12.554 dokumen dari 63 bahasa dan 217 situs yang tidak pernah muncul di data distilasi.

Tabel I
POSISI STATICKD TERHADAP PENDEKATAN TERKAIT

Pendekatan	Bentuk model saat inferensi	Multibahasa	Transfer lintas bahasa	Tanpa pustaka <i>deep learning</i>	Biaya CPU dilaporkan	Label IPTC
Kuzman & Ljubešić [2]	XLM-R-large (560 jt parameter)	ya	ya	tidak	tidak	ya
KD-LoRA [12], PEFT [11]	transformer <i>backbone</i> utuh	sebagian	ya	tidak	tidak	tidak
TinyBERT/MiniLMv2 [13], [14]	transformer 4–6 <i>layer</i>	sebagian	ya	tidak	sebagian	tidak
<i>Sparse Distillation</i> [39]	<i>averaging network</i> + tabel n-gram	tidak (en)	tidak	ya	ya	tidak
Model2Vec [18], Wada dkk. [19]	embedding statis (umum)	ya	ya	ya	sebagian	tidak
fastText [9]	<i>bag of n-grams</i>	per bahasa	tidak	ya	ya	tidak
StaticKD (usulan)	tabel 17 logit per token	ya	ya	ya	ya	ya



Gbr. 1. Alur StaticKD. *Teacher* melabeli korpus berita tak berlabel sekali secara *offline*; *student* dilatih meniru distribusi *teacher*, lalu kepala linearnya dilipat ke dalam tabel token sehingga inferensi hanya berupa pengambilan baris tabel dan rata-rata. Evaluasi akhir memakai set uji yang labelnya independen dari *teacher*.

D. Konstruksi Set Uji Gabungan

Sumber (a): CC-NEWS 2024–2026. Satu file WARC per bulan, Januari 2024 sampai Agustus 2026 (32 file), diunduh dari Common Crawl [72]. Dari setiap halaman diambil blok JSON-LD schema.org [24] bertipe `NewsArticle` dan turunannya, beserta bidang `articleSection`, `BreadcrumbList`, `inLanguage`, `datePublished`, `isAccessibleForFree`, dan `articleBody`. Teks diambil dari `articleBody` bila berisi minimal 30 kata; jika tidak, teks diekstrak dengan Trafilatura [73]. Situs yang ada di data distilasi atau set evaluasi lain dikeluarkan. Hasilnya adalah 399.468 artikel dari situs baru.

Sumber (b): dataset publik.

- Berlabel manusia: MasakhaNEWS [25] dan MN-DS [26].
- Berlabel kategori penerbit: L3Cube-IndicNews (split LDC) [27], berita Bangla [28], IndoNews [74], berita Amharik [75], dan berita Swahili [76]. Dua sumber terakhir diproses dengan cara yang sama, tetapi tidak terpilih saat sampling karena sel bahasanya sudah terisi MasakhaNEWS yang berlabel manusia.

Totalnya 312.551 artikel.

Pemetaan ke IPTC. Nama rubrik atau kategori (setelah normalisasi huruf dan diakritik) dipetakan ke node pohon IPTC Media Topic resmi (1.085 node aktif). Aturannya konservatif: sebuah nama hanya dipetakan bila *seluruh isi yang lazim di rubrik itu* berada di bawah satu topik level atas. Hasilnya adalah 814 nama yang dipetakan ke 79 node. Sebanyak 62 nama ambigu sengaja tidak dipetakan, misalnya:

- *tech*: bisa *science and technology* atau industri TI di *economy*;
- *entertainment*: bisa *arts* atau *lifestyle*;
- *terrorism*: bisa *conflict* atau *crime*.

Rubrik astrologi ditolak. Validasi otomatis memeriksa bahwa setiap node tujuan ada di pohon IPTC, tidak berstatus *retired*,

dan leluhur level-1-nya sama dengan label tujuan. Artikel dengan beberapa rubrik yang dipetakan ke label berbeda ditolak. Label MN-DS dipakai langsung karena sudah berupa topik IPTC.

Filter kualitas dan kebocoran. Filter diterapkan berurutan.

- 1) Tanggal terbit $\geq 2024-01-01$ (khusus CC-NEWS).
- 2) Artikel tidak berbayar.
- 3) Bahasa yang dideklarasikan cocok dengan fastText lid.176 (bila bahasanya dikenal).
- 4) Panjang ≥ 75 kata.
- 5) Deduplikasi URL, teks identik, dan *near-duplicate* (Min-Hash, Jaccard $\geq 0,7$ [64], [65]) *lintas semua sumber*.
- 6) Kontaminasi: artikel dibuang bila $\geq 30\%$ 8-gram katanya muncul di salah satu dari ~ 300 ribu dokumen latih atau evaluasi. Filter ini membuang 50 artikel, sebagian besar dari MasakhaNEWS yang juga bersumber dari BBC.

Sampling.


- Maksimal 50 artikel per sel (bahasa $\times$ label).
- Sumber berlabel manusia diprioritaskan, lalu kategori penerbit, lalu rubrik JSON-LD.
- Bahasa dengan kurang dari 30 artikel dikeluarkan.
- Tidak ada batas jumlah artikel per situs. Kebanyakan sel hanya berasal dari sedikit situs, sehingga batas seperti itu membuang data tanpa menambah keragaman. Ketergantungan antarartikel dari situs yang sama ditangani saat evaluasi dengan *site-cluster bootstrap*, dan Subbagian IV-A menyertakan uji sensitivitas dengan batas 5 artikel per situs.

Hasil. Set uji berisi 12.744 artikel dari 47 bahasa, 17 label, dan 1.227 situs atau sumber (median 313 kata), dengan komposisi asal label:

- anotasi manusia: 4.094 artikel (32,1%);
- kategori penerbit: 2.600 artikel (20,4%);

Tabel II
KOMPOSISI SET UJI GABUNGAN PER SUMBER

Sumber	Asal label	Artikel	Bahasa	Situs/sumber
CC-NEWS 2024–2026 [72]	rubrik JSON-LD	6.050	29	1.092
MasakhaNEWS [25]	anotasi manusia	3.339	16	6
L3Cube-IndicNews [27]	kategori penerbit	2.361	10	1
MN-DS [26]	anotasi manusia	755	1	127
Berita Bangla [28]	kategori penerbit	139	1	1
IndoNews [74]	kategori penerbit	100	1	1
Total		12.744	47	1.227



Gbr. 2. Jumlah artikel set uji gabungan per bahasa dan label (maksimal 50 per sel). Label dalam kurung adalah asal label dominan bahasa tersebut.

- rubrik JSON-LD: 6.050 artikel (47,5%).

Menurut data distilasi di bahasanya, 13 bahasa sama sekali tidak ada di data distilasi (misalnya ha, yo, ig, bn, pa), 9 bahasa punya kurang dari 500 dokumen, dan 25 bahasa punya sisanya. Menurut keragaman situs, 13 bahasa memiliki minimal 10 situs efektif, sedangkan 27 bahasa praktis berasal dari satu penerbit. Tabel II merangkum sumber dan Gbr. 2 memperlihatkan cakupan bahasa $\times$ label.

E. Teacher dan Pelabelan Distilasi

Teacher adalah classla/multilingual-IPTC-news-topic-classifier [2]: XLM-RoBERTa-large dengan 24 layer, 559,9 juta parameter, dan maksimal 512 token. Untuk setiap dokumen distilasi, *teacher* menghasilkan vektor logit $\mathbf{z}^T(d) \in \mathbb{R}^{17}$ yang disimpan utuh. Pelabelan dijalankan

sekali dalam fp16 pada GPU RTX 4050, dengan *batch* yang diurutkan berdasarkan panjang teks. Distribusi label *teacher* pada CC-News wajar (*politics* 16,5%, *economy* 12,7%, *sport* 11,6%, *weather* 1,3%), dan keyakinan rata-ratanya per bahasa berkisar 0,90–1,00.

F. Student StaticKD

Arsitektur. Dokumen d ditokenisasi menjadi $t_1, \dots, t_n$ dengan tokenizer Unigram *potion-multilingual-128M* [18] (500.353 token; tanpa token khusus; token tidak dikenal dibuang; maksimal 1.024 token). Setiap token memiliki embedding $\mathbf{e}_t \in \mathbb{R}^{256}$, dan

$$\mathbf{h}(d) = \frac{1}{n} \sum_{i=1}^n \mathbf{e}_{t_i}, \quad \mathbf{z}^S(d) = W \text{drop}(\mathbf{h}(d)) + \mathbf{b}, \quad (1)$$

dengan $W \in \mathbb{R}^{17 \times 256}$ dan *dropout* 0,1 selama *training*. Matriks E diinisialisasi dari *potion-multilingual*, yaitu embedding statis 101 bahasa yang didistilasi dari BGE-M3 [20].

Fungsi loss. Dengan $p^T = \text{softmax}(\mathbf{z}^T/\tau)$ dan $p^S = \text{softmax}(\mathbf{z}^S/\tau)$,

$$\mathcal{L}_{KD} = \tau^2 \text{KL}(p^T \| p^S), \quad \tau = 1. \quad (2)$$

Optimasi. E , W , dan $\mathbf{b}$ dilatih *end-to-end*.

- E memakai SparseAdam ($\eta = 10^{-3}$), sehingga hanya baris token yang muncul di *batch* yang diperbarui.
- W dan $\mathbf{b}$ memakai AdamW ($\eta = 3 \cdot 10^{-3}$, *weight decay* 10^{-4}).
- Ukuran *batch* 64 dan 6 *epoch*.
- *Token dropout*: setiap token dokumen latih dibuang dengan probabilitas 0,2 pada setiap langkah, sebagai augmentasi yang konsisten [51].
- Sebanyak 3% data distilasi (8.579 dokumen) disisihkan sebagai validasi internal. *Epoch* dengan kesepakatan *argmax* tertinggi terhadap *teacher* dipilih.

Pelipatan tabel. Karena kepala klasifikasinya linear,

$$W \left(\frac{1}{n} \sum_i \mathbf{e}_{t_i} \right) + \mathbf{b} = \frac{1}{n} \sum_i T_{t_i} + \mathbf{b}, \quad T = EW^T \in \mathbb{R}^{|V| \times 17}. \quad (3)$$

Model produksi hanyalah T (fp16), $\mathbf{b}$, dan tokenizer. Inferensi terdiri atas tokenisasi, rata-rata baris tabel, dan penambahan bias.

Ensemble tanpa biaya. Rata-rata logit K *student* dengan *seed* berbeda sama dengan logit satu *student* bertabel $\bar{T} = \frac{1}{K} \sum_k T^{(k)}$ dan bias $\bar{\mathbf{b}}$ (Persamaan 3 linear terhadap T). StaticKD final adalah *ensemble* tabel *seed* 0, 1, dan 2 ($K = 3$), dengan 8,5 juta parameter dan ukuran 34 MB.

Varian compact. Struktur internal tokenizer Unigram membutuhkan RAM jauh lebih besar daripada tabelnya (16 MB). Varian *compact* membuang potongan token yang muncul kurang dari 10 kali di korpus distilasi (karakter tunggal dipertahankan), sehingga kosakata menjadi 335.441 token dan ukuran model 23 MB.

Tabel III
HIPERPARAMETER SELURUH MODEL

Komponen	Nilai
<i>StaticKD</i>	
embedding awal	potion-multilingual-128M (500.353 × 256)
maks. token / dropout vektor	1.024 / 0,1
loss, τ	KL, $\tau = 1$
token dropout	0,2
optimizer embedding / kepala	SparseAdam 10^{-3} / AdamW $3 \cdot 10^{-3}$, wd 10^{-4}
batch, epoch, validasi	64, 6, 3% data (pilih epoch)
ensemble	rata-rata tabel 3 seed
<i>fastText</i>	
dim, lr, epoch, n-gram kata	100, 0,5, 15 (25 untuk label GPT-4o), 2; softmax, 2 jt bucket
token	kata (+ n-gram karakter 2-5) atau subword XLM-R
kuantisasi	quantize, cutoff 300 rb, retrain
<i>TF-IDF + SVM</i>	
fitur	subword XLM-R uni+bigram, min. df 3, maks. 1.000.000, sublinear tf
klasifikator	LinearSVC, $C = 0,5$
<i>MiniLM-L6 / DistilmBERT + KD</i>	
optimizer	AdamW $5 \cdot 10^{-5}$, wd 0,01, warmup 6%, linear, fp16
batch, epoch, maks. token	32, 2, 256
τ	{1, 2}, dipilih pada dev

G. Baseline

Semua *baseline* dilatih pada data distilasi yang sama (285.999 dokumen) dengan target *teacher* yang sama. Hiperparameternya ada di Tabel III.

- 1) **fastText + KD** [9]: dilatih dengan *argmax teacher*, memakai token kata (dengan n-gram karakter) atau subword XLM-R, ditambah varian terkuantisasi (.ftz).
- 2) **fastText, label GPT-4o**: dilatih hanya pada EMMediaTopic *train*, sama dengan data berlabel yang tersedia bagi [2].
- 3) **TF-IDF + SVM + KD**: *baseline* non-neural Kuzman dan Ljubešić (TF-IDF + SVC), dilatih dengan *argmax teacher* di atas subword XLM-R.
- 4) **MiniLM-L6 + KD**: mMiniLMv2-L6-H384 yang didistilasi dari XLM-R-large [13]. *Temperature* $\tau \in \{1, 2\}$ dipilih pada set *development*.
- 5) **DistilmBERT + KD**: distilbert-base-multilingual-cased [77] dengan resep yang sama. Kedua transformer diekspor ke ONNX fp32 untuk *benchmark* CPU.
- 6) **Teacher ONNX int8**: ekspor kuantisasi *dynamic int8* dari *teacher*, konfigurasi CPU tercepat untuk *teacher* [15].

H. Protokol Evaluasi dan Uji Statistik

Metrik.

- Macro-F1 atas label yang hadir di referensi, sama dengan kode evaluasi [2]. Ini metrik utama karena distribusi labelnya tidak seimbang.
- Akurasi.
- Macro-F1 per bahasa yang dirata-rata antarbahasa, supaya bahasa besar tidak mendominasi.
- Kesepakatan dengan *teacher* pada set *fidelity*.

Interval kepercayaan 95% dihitung dengan *bootstrap percentile* 1.000 kali. Di set uji yang di-*resample* adalah situs (atau dataset sumber bila tidak ada URL), yaitu *site-cluster bootstrap* [68]. Di dev yang di-*resample* adalah dokumen.

Perbandingan dua model pada dokumen yang sama:

- *paired (cluster) bootstrap* 2.000 kali untuk Δ macro-F1 [66];
- uji McNemar eksak untuk akurasi [78];
- koreksi Holm–Bonferroni [79] per set.

Variasi antar-seed. Setiap varian ablasi dilatih dengan lima *seed* dan resep final dengan sepuluh *seed*. Perbedaannya diuji dengan uji Welch pada tingkat *seed*, dikoreksi Holm [69].

Analisis subkelompok dilakukan menurut asal label, wilayah, jumlah data distilasi bahasa, keragaman situs, sistem tulisan, bahasa, dan label.

Kalibrasi diukur dengan *expected calibration error* (ECE, 15 bin) [80].

I. Protokol Efisiensi

Benchmark dijalankan hanya di CPU, dengan GPU disembunyikan.

- Setiap model dijalankan di proses baru, dan jumlah *thread* dikunci pada seluruh pustaka (OMP, MKL, OpenBLAS, ONNX Runtime, tokenizers).
- Latensi diukur dengan satu artikel per panggilan (skenario *streaming*; p50 dan p95).
- *Throughput* diukur dengan *batch* 64, atau 8 untuk transformer.
- RAM model adalah kenaikan RSS setelah model dimuat.
- Sampel teks adalah sampel acak tetap dari set uji gabungan (47 bahasa), sama untuk semua model.
- Perangkat: Intel Core Ultra 7 155H, RAM 31 GB, Windows 11.

CPU ini bersifat *hybrid*: 6 P-core, 8 E-core yang sekitar 2,5 kali lebih lambat, dan 2 LP E-core. Tanpa *pinning*, sistem operasi memindahkan *thread* ke *core* lambat. Karena itu setiap proses dipin ke P-core fisik (1 *core*: CPU logis 0; 4 *core*: CPU logis 0, 10, 12, 14) untuk mensimulasikan server kecil dengan *core* seragam. Semua model diukur dalam satu sesi saat mesin idle.

J. Desain Eksperimen dan Detail Implementasi

Tabel VII mendaftar seluruh 72 run StaticKD. Setiap varian mengubah satu faktor terhadap resep final:

- label keras;
- data EMMediaTopic saja (4 bahasa, 10 *epoch*);
- 130 ribu dokumen tanpa CC-News tambahan;
- inisialisasi acak dengan simpangan baku yang sama dengan *potion*;
- embedding beku;
- tanpa *token dropout*;
- kepala MLP 512 unit;
- $\tau \in \{0,5; 2; 4\}$;
- empat varian eksplorasi (bigram *hashing* 2^{21} , *pooling* berbobot $\text{idf}^{0,5}$, bobot dokumen berdasarkan keyakinan *teacher*, dan *cross-entropy* tambahan terhadap label GPT-4o).

Satu run StaticKD rata-rata membutuhkan 5,2 menit pada RTX 4050. Implementasi memakai Python 3.12, PyTorch 2.6, tokenizers 0.23, ONNX Runtime 1.30, scikit-learn 1.9, dan fastText 0.9.2. *Seed*, versi pustaka, dan riwayat *training* setiap run disimpan bersama model.

Tabel IV

HASIL UTAMA. MACRO-F1 [CI95] DAN AKURASI PADA SET *Development* (EMMEDIATOPIC DEV, LABEL GPT-4o), KESEPAKATAN DENGAN *Teacher* PADA CC-News *Held-Out*, DAN SET UJI GABUNGAN (47 BAHASA, LABEL INDEPENDEN). CI SET UJI DARI *Site-Cluster Bootstrap*.

Model	dev (4 bahasa)		<i>held-out</i> Kesepakatan	uji gabungan (47 bahasa)			
	Macro-F1 [CI95]	Akurasi		Macro-F1 [CI95]	Akurasi	Macro-F1/bahasa	% <i>teacher</i>
Teacher XLM-R-large	0,822 [0,779–0,851]	0,859	–	0,598 [0,546–0,643]	0,700	0,705	100,0%
Teacher XLM-R-large, ONNX int8	0,823 [0,781–0,852]	0,858	–	0,600 [0,547–0,646]	0,699	0,702	100,3%
DistilmBERT + KD	0,753 [0,710–0,785]	0,801	0,799	0,534 [0,481–0,618]	0,623	0,602	89,4%
MiniLM-L6 + KD	0,785 [0,737–0,815]	0,820	0,825	0,566 [0,511–0,624]	0,667	0,661	94,6%
StaticKD (usulan)	0,761 [0,717–0,792]	0,800	0,811	0,545 [0,490–0,605]	0,641	0,622	91,1%
StaticKD-compact	0,754 [0,710–0,786]	0,797	0,802	0,484 [0,421–0,597]	0,544	0,507	81,0%
fastText + KD, subword, kuantisasi	0,708 [0,664–0,739]	0,759	0,740	0,435 [0,370–0,556]	0,512	0,464	72,7%
fastText + KD, subword	0,727 [0,691–0,756]	0,769	0,751	0,445 [0,384–0,563]	0,522	0,473	74,4%
fastText + KD, kata	0,743 [0,707–0,773]	0,789	0,753	0,438 [0,373–0,560]	0,511	0,472	73,3%
TF-IDF + SVM + KD	0,755 [0,719–0,786]	0,798	0,776	0,486 [0,431–0,585]	0,567	0,522	81,3%
fastText, label GPT-4o, subword	0,665 [0,613–0,700]	0,729	0,260	0,086 [0,069–0,119]	0,150	0,118	14,4%
fastText, label GPT-4o, kata	0,651 [0,601–0,693]	0,738	0,307	0,106 [0,085–0,150]	0,181	0,142	17,7%

IV. HASIL

A. Akurasi Seluruh Model (RQ2)

Tabel IV memuat hasil utama.

Set uji gabungan.

- *Teacher* mencapai macro-F1 0,598 [0,546–0,643] dan akurasi 0,700. Angka ini jauh di bawah skornya di dev (0,822), karena set uji mencakup bahasa, sumber, dan periode yang tidak pernah dilihat.
- StaticKD mencapai macro-F1 0,545 [0,490–0,605] dan akurasi 0,641, atau 91,1% dari macro-F1 *teacher*.
- Pada dev, StaticKD mempertahankan 92,6% macro-F1 *teacher* (0,761 vs 0,822).
- Kesepakatan StaticKD dengan *teacher* di 63 bahasa *held-out* adalah 0,811.
- Satu *student* tanpa *ensemble* mencapai rata-rata $0,542 \pm 0,004$ (10 *seed*) di set uji dan $0,755 \pm 0,010$ di dev.

Baseline.

- Di antara transformer kecil hasil distilasi, MiniLM-L6 (0,566), yang diinisialisasi dari distilasi XLM-R-large, berada di antara StaticKD dan *teacher*. DistilmBERT (0,534) justru berada di bawah StaticKD walaupun jauh lebih mahal.
- *Baseline* berbiaya serupa (fastText + KD, TF-IDF + SVM + KD) berada di bawah StaticKD.
- fastText yang hanya dilatih dengan label GPT-4o empat bahasa gagal di luar bahasa latihnya (macro-F1 uji 0,086), walaupun cukup baik di dev (0,665).

Uji berpasangan (Tabel V), dengan Δ = StaticKD – pembandingan pada set uji:

- terhadap *teacher*: Δ macro-F1 $-0,053 [-0,065; -0,033]$, $p < 0,001$;
- terhadap MiniLM-L6: $-0,021 [-0,038; -0,008]$, $p < 0,004$;
- terhadap DistilmBERT: $+0,010 [-0,026; +0,041]$, $p < 0,800$;
- terhadap fastText + KD terkuantisasi: $+0,110 [+0,042; +0,151]$, $p < 0,001$;

- terhadap TF-IDF + SVM: $+0,059 [+0,009; +0,093]$, $p < 0,030$.

Menurut subkelompok (Tabel VI, Gbr. 3):

- Pada artikel berlabel rubrik JSON-LD, StaticKD mempertahankan 95,8% skor *teacher*.
- Pada kategori penerbit angkanya 89,5%, dan pada anotasi manusia 89,6%.
- Menurut data distilasi bahasa, StaticKD mempertahankan 97,5% skor *teacher* di bahasa dengan data cukup, 89,1% di bahasa dengan sedikit data, dan 72,3% di bahasa yang sama sekali tidak ada di data distilasi.

Uji sensitivitas pada subset dengan maksimal lima artikel per situs per sel (8.139 artikel) menghasilkan peringkat model yang sama dengan set uji penuh (StaticKD 0,587, *teacher* 0,627).

B. Validitas Label Silver

Label silver diperiksa secara tidak langsung dengan dua cara.

- 1) **Perbandingan dengan label manusia di bahasa yang sama.** Seluruh sel bahasa Inggris di set uji terisi sumber berlabel manusia. Karena itu diambil sampel terpisah berisi 754 artikel CC-NEWS berbahasa Inggris berlabel rubrik JSON-LD dari 306 situs yang tidak masuk set uji, maksimal 50 per label.

- Akurasi *teacher* pada label silver adalah 0,646 (macro-F1 0,617), sedangkan pada label manusia MN-DS/MasakhaNEWS 0,559 (macro-F1 0,565).
- Akurasinya lebih tinggi pada label silver di 12 dari 17 label (Wilcoxon $p < 0,033$).
- Urutan tingkat kesulitan label pada kedua jenis label berkorelasi ($\rho = 0,63$, $p < 0,007$).

Dengan kata lain, label silver tidak lebih bising daripada label manusia yang tersedia, setidaknya jika diukur dengan kesepakatan terhadap *teacher*. Label yang sulit (*society*, *human interest*, *religion*) sulit di kedua jenis label.

Tabel V
UJI BERPASANGAN STATICKD TERHADAP MODEL LAIN (Δ = STATICKD – PEMBANDING; p DIKOREKSI HOLM PER SET; b/c = DOKUMEN YANG HANYA BENAR DI STATICKD / HANYA BENAR DI PEMBANDING)

Set	StaticKD vs	Δ macro-F1 [CI95]	p bootstrap	Δ akurasi	McNemar b/c	p McNemar
dev	Teacher XLM-R-large	−0,061 [−0,096; −0,028]	0,009	−0,059	45/104	<0,001
	Teacher XLM-R-large, ONNX int8	−0,062 [−0,096; −0,028]	0,009	−0,058	46/104	<0,001
	DistilmBERT + KD	+0,008 [−0,030; +0,044]	1,000	−0,001	92/93	1,000
	MiniLM-L6 + KD	−0,024 [−0,057; +0,009]	0,672	−0,020	72/92	0,688
	StaticKD-compact	+0,007 [+0,000; +0,016]	0,276	+0,003	4/1	1,000
	fastText + KD, subword, kuantisasi	+0,053 [+0,019; +0,089]	0,021	+0,041	80/39	0,002
	fastText + KD, subword	+0,034 [−0,005; +0,069]	0,400	+0,031	71/40	0,025
	fastText + KD, kata	+0,018 [−0,022; +0,052]	1,000	+0,011	61/50	1,000
	TF-IDF + SVM + KD	+0,006 [−0,030; +0,038]	1,000	+0,002	52/50	1,000
	fastText, label GPT-4o, subword	+0,096 [+0,056; +0,144]	<0,001	+0,071	125/54	<0,001
uji	fastText, label GPT-4o, kata	+0,110 [+0,071; +0,154]	<0,001	+0,062	113/51	<0,001
	Teacher XLM-R-large	−0,053 [−0,065; −0,033]	<0,001	−0,059	654/1400	<0,001
	Teacher XLM-R-large, ONNX int8	−0,055 [−0,067; −0,035]	<0,001	−0,058	644/1386	<0,001
	DistilmBERT + KD	+0,010 [−0,026; +0,041]	0,800	+0,018	1372/1143	<0,001
	MiniLM-L6 + KD	−0,021 [−0,038; −0,008]	0,004	−0,026	866/1197	<0,001
	StaticKD-compact	+0,060 [+0,003; +0,100]	0,030	+0,097	1345/110	<0,001
	fastText + KD, subword, kuantisasi	+0,110 [+0,042; +0,151]	<0,001	+0,129	2157/519	<0,001
	fastText + KD, subword	+0,100 [+0,037; +0,138]	<0,001	+0,119	2021/505	<0,001
	fastText + KD, kata	+0,106 [+0,041; +0,149]	<0,001	+0,130	2176/513	<0,001
	TF-IDF + SVM + KD	+0,059 [+0,009; +0,093]	0,030	+0,074	1667/719	<0,001
	fastText, label GPT-4o, subword	+0,458 [+0,415; +0,496]	<0,001	+0,491	6597/344	<0,001
	fastText, label GPT-4o, kata	+0,439 [+0,393; +0,475]	<0,001	+0,460	6252/391	<0,001

Tabel VI
MACRO-F1 SET UJI PER SUBKELOMPOK. KOLOM TERAKHIR: MACRO-F1 STATICKD SEBAGAI PERSENTASE MACRO-F1 *Teacher* PADA SUBKELOMPOK YANG SAMA

Subkelompok	n	<i>Teacher</i>	DistilmBERT	MiniLM	StaticKD	fastText (q)	TF-IDF+SVM	fastText GPT	% <i>teacher</i>
<i>Asal label</i>									
anotasi manusia	4.094	0,463	0,436	0,436	0,414	0,336	0,393	0,027	90%
kategori penerbit	2.600	0,702	0,498	0,674	0,629	0,319	0,330	0,063	90%
rubrik JSON-LD	6.050	0,651	0,629	0,634	0,624	0,579	0,609	0,136	96%
<i>Data distilasi bahasa</i>									
cukup (≥ 500)	7.644	0,633	0,617	0,616	0,618	0,572	0,593	0,116	98%
sedikit (< 500)	2.243	0,537	0,344	0,496	0,478	0,202	0,227	0,037	89%
tidak ada (0)	2.857	0,557	0,452	0,502	0,402	0,174	0,230	0,048	72%
<i>Wilayah</i>									
Afrika	3.044	0,697	0,532	0,576	0,542	0,312	0,408	0,085	78%
Asia Selatan	2.681	0,575	0,410	0,544	0,509	0,246	0,276	0,046	88%
Asia Timur/Tenggara & Timur Tengah	1.574	0,636	0,620	0,621	0,622	0,560	0,629	0,085	98%
Eropa	5.445	0,653	0,637	0,638	0,638	0,595	0,610	0,136	98%
<i>Cakupan pra-latih teacher</i>									
di luar pra-latih XLM-R	1.750	0,719	0,586	0,620	0,501	0,317	0,457	0,086	70%
tercakup pra-latih XLM-R	10.994	0,609	0,549	0,585	0,576	0,468	0,503	0,096	95%
<i>Keragaman situs</i>									
beragam (≥ 10)	5.225	0,657	0,642	0,643	0,642	0,598	0,616	0,134	98%
satu penerbit (< 3)	6.204	0,517	0,387	0,475	0,433	0,221	0,287	0,045	84%
sedang (3–10)	1.315	0,559	0,556	0,539	0,543	0,503	0,533	0,089	97%

2) **Pemeriksaan per kategori sumber**, hanya pada bahasa yang tercakup pra-latih XLM-R. Median kesepakatan *teacher* dengan label hasil pemetaan per kategori adalah 0,46 untuk MasakhaNEWS, 0,50 untuk MN-DS, 0,81 untuk L3Cube, dan 0,87 untuk rubrik CC-NEWS. Kesepakatan terendah muncul pada dua jenis kategori.

- Kategori sumber yang cakupannya lebih luas daripada topik IPTC tujuannya. Contohnya, MasakhaNEWS *politics* hanya 0,45 sesuai, dengan alternatif utama conflict (29%).
- Label yang batasnya kabur bahkan bagi anotator manusia, misalnya MN-DS *society*, sejalan dengan kesepakatan antaranotator yang rendah pada label


tersebut [2].

Karena itu, skor absolut pada label berskema non-IPTC merupakan batas bawah akurasi yang sebenarnya, sedangkan perbandingan antarmodel tetap sah karena semua model dinilai terhadap label yang sama.

C. Ablasi, Temperature, dan Ensemble (RQ3)

Tabel VII merangkum kontribusi setiap komponen, dengan lima *seed* per varian.

- **Data distilasi multibahasa adalah komponen terpenting.** Distilasi hanya pada EMMediaTopic (4 bahasa) menurunkan macro-F1 uji sebesar −0,051 dan kesepakatan *held-out* sebesar −0,077.



Gbr. 3. Macro-F1 set uji menurut asal label (kiri) dan menurut jumlah data distilasi di bahasa artikel (kanan).

Tabel VII

ABLASI, *Temperature*, DAN VARIAN EKSPLORASI (SATU *Student*, TANPA *Ensemble*). RATA-RATA $\pm$ SIMPANGAN BAKU ANTAR-*Seed*; *: BERBEDA DARI RESEP FINAL (WELCH, HOLM, $p < 0,05$)

Varian	<i>Seed</i>	Macro-F1 dev	Kesepakatan <i>held-out</i>	Macro-F1 uji	Akurasi uji
<i>Resep final</i>					
Resep final (satu <i>seed</i>)	10	0,755 $\pm$ 0,010	0,808 $\pm$ 0,001	0,542 $\pm$ 0,004	0,640
<i>Ablasi komponen</i>					
Label keras <i>teacher</i> (<i>cross-entropy</i>)	5	0,749 $\pm$ 0,007	0,805 $\pm$ 0,001	0,547 $\pm$ 0,004	0,643
Data distilasi hanya EMMediaTopic (4 bahasa, 20 rb)	5	0,723 $\pm$ 0,006*	0,730 $\pm$ 0,001*	0,491 $\pm$ 0,002*	0,583
Data distilasi 130 rb (tanpa CC-News tambahan)	5	0,736 $\pm$ 0,009*	0,799 $\pm$ 0,002*	0,541 $\pm$ 0,002	0,638
Embedding diinisialisasi acak	5	0,715 $\pm$ 0,005*	0,739 $\pm$ 0,004*	0,422 $\pm$ 0,006*	0,493
Embedding beku (hanya kepala linear)	5	0,720 $\pm$ 0,001*	0,788 $\pm$ 0,001*	0,557 $\pm$ 0,002*	0,661
Tanpa <i>token dropout</i>	5	0,757 $\pm$ 0,004	0,808 $\pm$ 0,001	0,544 $\pm$ 0,002	0,640
Kepala MLP 512 unit (tidak dapat dilipat)	5	0,762 $\pm$ 0,009	0,813 $\pm$ 0,002*	0,551 $\pm$ 0,006	0,649
<i>Temperature</i>					
$\tau = 0,5$	5	0,750 $\pm$ 0,004	0,807 $\pm$ 0,002	0,546 $\pm$ 0,005	0,642
$\tau = 2$	5	0,748 $\pm$ 0,003	0,801 $\pm$ 0,001*	0,537 $\pm$ 0,001	0,638
$\tau = 4$	5	0,723 $\pm$ 0,004*	0,791 $\pm$ 0,001*	0,529 $\pm$ 0,002*	0,635
<i>Hasil negatif (eksplorasi)</i>					
+ bigram hashing ²²¹	3	0,754 $\pm$ 0,008	0,811 $\pm$ 0,002	0,544 $\pm$ 0,002	0,643
+ <i>pooling</i> berbobot $idf^{0,5}$	3	0,759 $\pm$ 0,005	0,810 $\pm$ 0,000*	0,541 $\pm$ 0,002	0,639
+ bobot dokumen = keyakinan <i>teacher</i>	3	0,759 $\pm$ 0,005	0,809 $\pm$ 0,001	0,543 $\pm$ 0,003	0,640
+ <i>cross-entropy</i> label GPT-4o	3	0,744 $\pm$ 0,006	0,800 $\pm$ 0,001*	0,539 $\pm$ 0,005	0,632

Tabel VIII

MACRO-F1 VARIAN TERPILIH MENURUT JUMLAH DATA DISTILASI DI BAHASA ARTIKEL (SET UJI; RATA-RATA ANTAR-*Seed*)

Varian	dev	cukup (≥ 500)	sedikit (< 500)	tidak ada (0)
Resep final (satu <i>seed</i>)	0,755	0,615	0,482	0,403
Embedding beku (hanya kepala linear)	0,720	0,607	0,541	0,440
Embedding diinisialisasi acak	0,715	0,567	0,182	0,161
Data distilasi hanya EMMediaTopic (4 bahasa, 20 rb)	0,723	0,559	0,466	0,351
Label keras <i>teacher</i> (<i>cross-entropy</i>)	0,749	0,617	0,482	0,410
Kepala MLP 512 unit (tidak dapat dilipat)	0,762	0,613	0,484	0,421
$\tau = 2$	0,748	0,612	0,476	0,363

- **Inisialisasi embedding yang selaras lintas bahasa.** Inisialisasi acak mengubah macro-F1 uji sebesar $-0,120$ ($p < 0,001$).
- **Fine-tuning embedding: kecocokan in-distribusi vs transfer.** Membekukan embedding potion dan hanya melatih kepala linear menurunkan dev sebesar $-0,035$ ($p < 0,001$) dan kesepakatan *held-out* sebesar $-0,020$ ($p < 0,001$), tetapi *menaikkan* macro-F1 uji sebesar $+0,014$ ($p < 0,001$). Tabel VIII menunjukkan bahwa kenaikan ini seluruhnya berasal dari bahasa dengan sedikit data

distilasi ($+0,059$) dan tanpa data distilasi ($+0,037$), sedangkan di bahasa kaya data embedding beku lebih lemah ($-0,007$).

- **Soft label.** Label keras *teacher* mengubah macro-F1 uji sebesar $+0,005$ ($p 0,433$) dan dev sebesar $-0,006$ ($p 1,000$).
- **Ukuran data.** Mengurangi data ke 130 ribu dokumen mengubah macro-F1 uji sebesar $-0,002$ ($p 1,000$).
- **Token dropout.** Tanpa *token dropout*, macro-F1 uji berubah sebesar $+0,001$ ($p 1,000$).
- **Kepala MLP.** Kepala MLP, yang tidak dapat dilipat, mengubah macro-F1 uji sebesar $+0,009$ ($p 0,281$).

Temperature (Gbr. 4). Dibanding $\tau = 1$:

- $\tau = 2$, nilai yang lazim dipakai [16], mengubah dev sebesar $-0,006$ ($p 0,705$) dan kesepakatan *held-out* sebesar $-0,007$ ($p < 0,001$);
- $\tau = 4$ mengubah macro-F1 uji sebesar $-0,014$ ($p < 0,001$).

Varian eksplorasi (bigram *hashing*, *pooling* *idf*, bobot keyakinan, label GPT-4o) tidak memperbaiki set uji. Hasilnya:

bigram +0,002, idf −0,001, bobot keyakinan +0,000, dan CE GPT-4o −0,004.

Ensemble (Gbr. 5). Menaikkan ukuran *ensemble* dari satu ke tiga *seed* mengubah macro-F1 uji rata-rata dari 0,542 menjadi 0,544, dan kesepakatan *held-out* dari 0,808 menjadi 0,810. Sepuluh *seed* memberi 0,546. Semua ukuran *ensemble* tetap berupa satu tabel dengan biaya inferensi yang sama.

D. Efisiensi CPU (RQ1)

Tabel IX dan Gbr. 6–7 menunjukkan efisiensi seluruh model.

Teacher. Dalam PyTorch fp32, *teacher* membutuhkan 2.971 ms per artikel pada satu *core*, dengan *throughput* 0,33 artikel per detik. Konfigurasi CPU terbaiknya, ONNX int8, membutuhkan 1.239 ms dengan *throughput* 0,77 artikel per detik. Untuk satu juta artikel per hari dibutuhkan 15,1 *core* (ONNX int8) sampai 34,8 *core* (PyTorch) khusus untuk klasifikasi.

StaticKD.

- Latensi 2,03 ms dan *throughput* 473 artikel per detik per *core*.
- Sekitar 616 kali lebih cepat dari *teacher* ONNX int8, 1.420 kali lebih cepat dari *teacher* PyTorch, dan 29 kali lebih cepat dari MiniLM-L6.
- Ukuran file 16 kali lebih kecil dari *teacher* ONNX int8.
- Satu juta artikel per hari hanya membutuhkan 0,02 *core*.
- RAM model 501 MB, sebagian besar dipakai struktur tokenizer. Varian *compact* menurunkannya ke 277 MB.
- **Tokenisasi adalah hampir seluruh biaya.** Pada satu *thread*, tokenisasi (rata-rata 579 token per artikel) memakan 98% waktu prediksi. *Pooling* tabel sendiri berjalan pada 28.755 artikel per detik. Batas kecepatan StaticKD karena itu ditentukan oleh implementasi tokenizer, bukan oleh model.

E. Analisis per Bahasa dan per Label (RQ4)

Per bahasa (Gbr. 8).

- Median selisih akurasi StaticKD terhadap *teacher* per bahasa uji adalah −0,024. StaticKD lebih akurat daripada fastText + KD di 41 dari 47 bahasa.
- Di *held-out* (53 bahasa dengan minimal 20 dokumen), kesepakatan StaticKD berkorelasi dengan log jumlah data distilasi ($\rho = 0,31$, $p = 0,022$) dan dengan keyakinan *teacher* ($\rho = 0,71$, $p < 0,001$), tetapi tidak berbeda antarsistem tulisan (Kruskal–Wallis $H = 10,37$, $p = 0,065$) (Tabel X).
- **Bahasa yang lemah.** Akurasi StaticKD rata-rata 0,407 (*teacher* 0,643) pada bahasa di luar pra-latih XLM-R (ig, lg, ln, pcm, rn, sn, ti, yo), yang juga tidak ada di data distilasi.
- **Cakupan token.** Pada 4 bahasa (bn, ml, or, pa), kurang dari separuh kemunculan token pernah muncul minimal 10 kali di data distilasi (maksimal 32%). Meski begitu, StaticKD tetap mencapai akurasi rata-rata 0,624 (*teacher* 0,738). Varian *compact* membuang token-token tersebut dari tokenizer, dan akurasinya di bahasa-bahasa

ini jatuh ke 0,013. Di bahasa lainnya, akurasi *compact* 0,578 dibanding 0,640 untuk StaticKD penuh. Bagian V membahas mekanisme di balik pola ini.

Per label (Gbr. 9).

- Label tersulit bagi StaticKD adalah *society* (0,16), *disaster* (0,29), *human int.* (0,32), *conflict* (0,37), sedangkan yang termudah *sport* (0,88), *weather* (0,84), *education* (0,75).
- Selisih terbesar terhadap *teacher* ada pada *environment* (−0,17), *religion* (−0,15), *arts* (−0,08).
- Kebingungan terbesar adalah *society* → *human int.* (20%); *human int.* → *arts* (20%); *society* → *politics* (20%).

F. Kalibrasi dan Mode Cascade

Kalibrasi. ECE StaticKD adalah 0,041 di dev dan 0,139 di set uji, lebih rendah daripada ECE *teacher* (0,090 dan 0,245). Kedua model menjadi terlalu yakin (*overconfident*) di set uji yang berada di luar distribusi latih (Gbr. 10).

Cascade. Artikel dengan keyakinan StaticKD minimal θ diputuskan oleh StaticKD, dan sisanya dikirim ke *teacher* (Tabel XI). Dengan $\theta = 0,8$:

- StaticKD memutuskan 60,3% artikel dengan akurasi 0,813;
- akurasi *cascade* keseluruhan menjadi 0,703 (*teacher* saja: 0,699) dan macro-F1 0,602 (*teacher* saja: 0,600);
- *throughput* efektifnya 1,9 artikel per detik per *core*, dibanding 0,8 untuk *teacher* saja.


Jadi dengan hanya sekitar dua perlima artikel yang dikirim ke *teacher*, *cascade* menyamai akurasi *teacher*.

V. PEMBAHASAN

Tabel token cukup untuk sebagian besar topik berita (RQ1, RQ2). StaticKD mempertahankan 91,1% macro-F1 *teacher* di set uji gabungan dan 92,6% di dev, dengan biaya inferensi dua sampai tiga orde besaran lebih rendah ($616\times$ terhadap ONNX int8, $1.420\times$ terhadap PyTorch). Hal ini konsisten dengan temuan bahwa representasi tanpa urutan kata sudah kompetitif untuk klasifikasi topik [21], [22]: nama lembaga, istilah olahraga, dan kosakata medis membawa sebagian besar sinyal topik. Sisa kesenjangan terkonsentrasi di dua tempat.

- Label yang kosakatanya tumpang tindih dengan topik lain. Selisih terbesar terhadap *teacher* ada pada *environment* (−0,17), *religion* (−0,15), *arts* (−0,08). Label tersulit bagi StaticKD (*society* (0,16), *disaster* (0,29), *human int.* (0,32), *conflict* (0,37)) juga termasuk yang tersulit bagi *teacher* (Gbr. 9). *Society* dan *human interest* juga dikenal sulit bagi anotator manusia [2].
- Bahasa yang kurang terwakili di data distilasi. Pada bahasa dengan data distilasi cukup, StaticKD mencapai 97,5% skor *teacher*; pada bahasa tanpa data distilasi, 72,3%.


Dengan data distilasi yang sama, MiniLM-L6 menutup sebagian kesenjangan tersebut (selisih StaticKD − MiniLM −0,021, $p = 0,004$). DistilBERT tidak menutupnya (selisih



Gbr. 4. Pengaruh *temperature* distilasi. Titik = satu *seed*, garis = rata-rata.

Tabel IX
EFISIENSI CPU (P-Core TERPIN; SAMPEL SET UJI GABUNGAN; 1C/4C = 1/4 *Core*)

Model	Latensi p50 / p95, 1c (ms)	Throughput 1c (dok/s)	Throughput 4c (dok/s)	RAM model (MB)	File (MB)	Dependensi
Teacher XLM-R-large	2.971 / 3.210	0,33	0,76	2.957	2.136	torch, transformers
Teacher XLM-R-large, ONNX int8	1.239 / 1.279	0,77	2,62	1.383	537	onnxruntime, transformers
DistilmBERT + KD	198 / 215	4,88	14,6	1.068	516	onnxruntime, transformers
MiniLM-L6 + KD	57,8 / 68,5	16,4	36,5	1.242	408	onnxruntime, transformers
StaticKD	2,03 / 3,46	473	893	501	34	numpy, tokenizers
StaticKD-compact	1,87 / 3,32	549	1.851	277	23	numpy, tokenizers
fastText + KD, subword, kuantisasi	2,08 / 3,95	532	892	300	18	fasttext, tokenizers
fastText + KD, subword	2,26 / 4,30	455	592	1.121	839	fasttext, tokenizers
TF-IDF + SVM + KD	2,93 / 4,48	421	595	826	166	scikit-learn, tokenizers




Gbr. 5. Pengaruh ukuran *ensemble* label (rata-rata $\pm$ SD atas kombinasi *seed*).

Tabel X
FAKTOR PENENTU KINERJA PER BAHASA

Uji	Statistik	<i>p</i>
Spearman: kesepakatan vs log(data distilasi)	$\rho = 0,31$	0,022
Spearman: kesepakatan vs jumlah situs latih	$\rho = 0,29$	0,033
Spearman: kesepakatan vs keyakinan <i>teacher</i>	$\rho = 0,71$	<0,001
Kruskal-Wallis: antarsistem tulisan	$H = 10,37$	0,065
Spearman (uji): selisih akurasi vs log(data)	$\rho = 0,52$	<0,001
Spearman (uji): akurasi StaticKD vs cakupan token	$\rho = 0,50$	<0,001
Spearman (uji): selisih akurasi vs cakupan token	$\rho = 0,49$	<0,001


StaticKD – DistilmBERT +0,010, *p* 0,800). Keduanya membutuhkan biaya satu sampai dua orde besaran lebih tinggi. Ini menunjukkan bahwa kualitas representasi multibahasa awal




Gbr. 6. *Trade-off* macro-F1 set uji gabungan terhadap *throughput* satu *core* CPU (skala log).

Tabel XI
Cascade StaticKD $\rightarrow$ *Teacher* ONNX INT8 PADA SET UJI (*Throughput* EFEKTIF 1 *Core*)


θ	Porsi StaticKD	Akurasi porsi	Macro-F1	Akurasi	dok/s
0 (StaticKD saja)	100,0%	0,641	0,545	0,641	473
0,5	80,8%	0,732	0,586	0,690	4,0
0,6	74,0%	0,760	0,593	0,697	2,9
0,7	67,4%	0,788	0,600	0,702	2,3
0,8	60,3%	0,813	0,602	0,703	1,9
0,9	51,7%	0,839	0,602	0,703	1,6
<i>Teacher</i> saja	0,0%	–	0,600	0,699	0,8



Gbr. 7. Latensi per artikel, RAM model, dan ukuran file (skala log).




Gbr. 8. Kiri: akurasi StaticKD terhadap akurasi *teacher* per bahasa uji (warna = jumlah data distilasi bahasa, ukuran = jumlah artikel). Kanan: kesepakatan per bahasa *held-out* terhadap jumlah data distilasi, StaticKD vs fastText + KD.



Gbr. 9. F1 per label di set uji (kiri) dan *confusion matrix* StaticKD yang dinormalisasi per label referensi (kanan).

lebih menentukan daripada jumlah *layer*: MiniLM berasal dari XLM-R-large, sedangkan DistilBERT dari mBERT.

Dari mana pengetahuan *student* berasal (RQ3). Ablasi memisahkan tiga sumber.



Gbr. 10. Diagram reliabilitas StaticKD pada dev dan set uji.

- 1) **Data distilasi multibahasa yang dilabeli *teacher*** adalah faktor terbesar. Tanpa data ini, macro-F1 uji turun sebesar $-0,051$. Temuan ini sejalan dengan pandangan klasik bahwa nilai distilasi terletak pada *transfer set* berlabel *teacher* [17], [39].
- 2) **Inisialisasi embedding yang selaras lintas bahasa.** Inisialisasi acak mengubah macro-F1 uji sebesar $-0,120$. Bukti yang lebih langsung datang dari varian *compact*. Pada bahasa India yang hampir tidak ada di data distilasi (misalnya bn, pa, or), sebagian besar token tidak pernah diperbarui saat *training*, sehingga embedding-nya tetap embedding awal potion. Meski begitu, StaticKD tetap mengklasifikasikan bahasa-bahasa ini dengan cukup baik (akurasi rata-rata 0,624; Gbr. 8). Ketika token-token tersebut dibuang oleh pemangkasan tokenizer, akurasinya jatuh ke 0,013. Jadi transfer ke bahasa tanpa data dibawa oleh baris embedding yang *tidak pernah dilatih*, tetapi berada dalam ruang yang sama dengan baris yang dilatih. Kepala linear yang dipelajari dari bahasa kaya data berlaku juga untuk baris-baris ini. Ablasi embedding beku memperlihatkan sisi lain dari mekanisme yang sama. *Fine-tuning* menggeser embedding token dari bahasa yang ada di data distilasi. Akibatnya kecocokan in-distribusi naik (dev $-0,035$ bila dibekukan), tetapi token bahasa lain tertinggal di ruang potion yang asli, sehingga kepala linear yang sudah menyesuaikan diri dengan ruang baru kurang cocok untuk token-token itu. Di bahasa tanpa atau dengan sedikit data distilasi, embedding beku lebih baik sebesar $+0,037$ dan $+0,059$. Ini adalah bentuk pergeseran representasi (*representation drift*) akibat *fine-tuning* pada sebagian kosakata. Resep final tetap memakai *fine-tuning* karena resep dipilih pada set *development* yang berbahasa latih. Namun untuk penggunaan yang menargetkan bahasa tanpa data distilasi, varian beku atau regularisasi yang menahan embedding dekat ke potion adalah pilihan yang lebih aman. Keduanya tetap dapat dilipat menjadi tabel.
- 3) ***Soft label* memberi manfaat kecil atau tidak ada.**

Label keras *teacher* tidak berbeda signifikan dari *soft label* dengan $\tau = 1$ (dev $-0,006$, uji $+0,005$). Sebaliknya, $\tau = 2$ menurunkan kesepakatan *held-out* dan macro-F1 uji, dan $\tau = 4$ menurunkan semua metrik. Temuan ini sejalan dengan literatur *capacity gap* [41], [43], [50]. *Student* yang hanya berupa satu lapisan linear di atas rata-rata embedding tidak mampu merepresentasikan struktur antarkelas dalam ekor distribusi *teacher* (*dark knowledge*) [45], [49]. Distribusi yang lebih tajam ($\tau = 1$) atau label keras memberi target yang dapat dicapai, sedangkan τ tinggi memaksa *student* meniru skala dan bentuk logit yang di luar kapasitasnya [48].

Kesimpulan praktisnya: untuk *student* berkapasitas sangat rendah, sumber daya sebaiknya diarahkan ke cakupan *transfer set* (bahasa, situs, topik) dan inisialisasi yang selaras, bukan ke penyetulan bentuk *soft label*.

Batas generalisasi lintas bahasa (RQ4). Kinerja per bahasa terutama ditentukan oleh keterwakilan bahasa di data distilasi dan di pra-latih, bukan oleh sistem tulisan (Kruskal-Wallis p 0,065). Kelemahan terbesar ada pada bahasa Afrika yang berada di luar pra-latih XLM-R dan tidak ada di data distilasi (ig, lg, ln, pcm, rn, sn, ti, yo). Pada bahasa-bahasa ini *teacher* masih cukup kuat (akurasi 0,643), mungkin berkat subword yang dipakai bersama dengan bahasa lain dan konteks kalimat, sedangkan StaticKD jauh lebih lemah (0,407). Solusi termudahnya tidak memerlukan perubahan arsitektur: tambahkan berita dalam bahasa-bahasa tersebut ke *transfer set* dan biarkan *teacher* melabelinya. Ablasi data dan korelasi kesepakatan dengan jumlah data ($\rho = 0,31$) mendukung saran ini.

Fidelity tidak sama dengan akurasi. Beberapa varian menggerakkan kesepakatan dengan *teacher* dan akurasi terhadap label independen ke arah yang berlawanan.

- Embedding beku menurunkan kesepakatan *held-out* ($-0,020$) tetapi menaikkan macro-F1 uji ($+0,014$).
- Mengurangi data ke 130 ribu dokumen menurunkan kesepakatan ($-0,009$) tanpa perubahan signifikan di set uji ($-0,002$).

Sejalan dengan [52], [53], pemilihan *student* sebaiknya memakai label yang independen dari *teacher* dan set uji di luar distribusi latih, bukan *fidelity* saja.

Posisi terhadap penelitian sebelumnya.

- Dibanding *Sparse Distillation* [39], StaticKD mengganti tabel n-gram yang dilatih dari nol dengan embedding multibahasa pra-latih yang dilipat ke 17 logit per token. Model menjadi jauh lebih kecil dan dapat ditransfer ke bahasa yang tidak ada di *transfer set*.
- Dibanding KD-LoRA dan PEFT [11], [12], StaticKD menurunkan biaya inferensi, bukan biaya *training*. Untuk *pipeline* berita, biaya inferensi inilah yang dominan [7].
- Kuantisasi int8 *teacher* hanya memberi percepatan dengan faktor konstan [15].

Implikasi praktis.

- Untuk *pipeline real-time* di server tanpa GPU, StaticKD memproses satu juta artikel per hari dengan 0,02 core, file 34 MB, dan dependensi hanya numpy dan tokenizers.

- Probabilitas StaticKD lebih terkalibrasi daripada *teacher* (ECE uji 0,139 vs 0,245), sehingga dapat dipakai untuk mode *cascade*. Dengan $\theta = 0,8, 60,3\%$ artikel diputuskan StaticKD dan sisanya dikirim ke *teacher*. Akurasi keseluruhannya (0,703) setara dengan *teacher* saja (0,699), dengan *throughput* 1,9 artikel per detik per *core*, dibanding 0,77 untuk *teacher* saja. Mode ini cocok untuk jalur *batch* yang membutuhkan akurasi setara *teacher*.
- Varian *compact* menurunkan RAM, tetapi hanya layak bila semua bahasa sasaran tercakup data distilasi.

VI. KETERBATASAN

- 1) **Label silver.** Sebanyak 47,5% artikel set uji berlabel rubrik JSON-LD dan 20,4% berlabel kategori penerbit. Pemetaannya konservatif dan tervalidasi terhadap pohon IPTC, tetapi tidak dianotasi ulang oleh manusia. Pemeriksaan tidak langsung pada Subbagian IV-B menunjukkan bahwa, di bahasa yang sama, kesepakatan *teacher* dengan label silver tidak lebih rendah daripada dengan label manusia. Walau begitu, skor absolut pada label silver sebaiknya dibaca sebagai estimasi yang mengandung derau, terutama untuk label yang batasnya kabur (*society, human interest, lifestyle*).
- 2) **Label MasakhaNEWS dianotasi manusia dengan skemanya sendiri,** lalu dipetakan ke IPTC. Hanya MN-DS yang dianotasi langsung dengan topik IPTC, dan dataset itu hanya berbahasa Inggris. *Test set* manusia IPTC multibahasa dari Kuzman dan Ljubešić [2] tidak publik, sehingga tidak dipakai.
- 3) **Cakupan label per bahasa timpang.** Median jumlah label per bahasa adalah 7. Bahasa Afrika hanya mencakup empat sampai lima topik besar. Macro-F1 dihitung atas label yang hadir, sehingga skor per bahasa tidak dapat dibandingkan secara langsung antarbahasa dengan cakupan label berbeda.
- 4) **Keragaman penerbit terbatas pada sebagian bahasa.** Sebanyak 27 bahasa praktis berasal dari satu penerbit: BBC/VOA untuk bahasa Afrika, L3Cube untuk bahasa India, dan satu situs untuk beberapa bahasa CC-NEWS. Klaim untuk bahasa-bahasa ini terbatas pada penerbit tersebut. *Site-cluster bootstrap* memperlebar interval kepercayaan sesuai kondisi ini.
- 5) **Batas atas *student* adalah *teacher*.** Kesalahan dan bias *teacher* ikut tertiru. Set *fidelity* mengukur kemiripan dengan *teacher*, bukan kebenaran.
- 6) **Satu perangkat *benchmark*.** Angka absolut di server akan berbeda, tetapi rasio antarmodel yang diukur dalam sesi dan protokol yang sama tetap informatif.
- 7) **Keadilan antarbahasa dan dampak.** Akurasi StaticKD jauh lebih rendah pada bahasa Afrika yang tidak terwakili di data distilasi maupun pra-latih (Subbagian V). Karena itu, penerapan sebagai penyaring topik dapat membuat berita dalam bahasa-bahasa ini lebih sering salah dikategorikan atau terbuang. Kami menyarankan agar akurasi dipantau per bahasa sebelum model dipakai, dan agar artikel berkeyakinan rendah dikirim ke *teacher* lewat mode *cascade*.

- 8) **Cakupan tugas.** Penelitian ini hanya mencakup label IPTC level atas dan klasifikasi *single-label*. Level yang lebih dalam dan artikel multi-topik belum diuji.

VII. KESIMPULAN

Penelitian ini mengukur biaya CPU pengklasifikasi IPTC multibahasa terbuka dan menunjukkan bahwa biayanya dapat diturunkan dua sampai tiga orde besaran (terhadap *teacher* ONNX int8 dan PyTorch) sambil mempertahankan sebagian besar akurasi. StaticKD mendistilasi *teacher* XLM-R-large ke tabel 17 logit per token. Tabel ini diinisialisasi dari *static embedding* multibahasa dan dilatih pada 285.999 artikel dari 69 bahasa yang dilabeli *teacher*.

- Pada set uji gabungan (12.744 artikel, 47 bahasa) yang labelnya independen dari *teacher*, StaticKD mencapai macro-F1 0,545, atau 91,1% dari *teacher*.
- Kecepatannya 473 artikel per detik per *core* CPU, sekitar 616 kali lebih cepat dari *teacher* ONNX int8, dengan model 34 MB tanpa pustaka *deep learning*.
- Kunci keberhasilannya adalah *transfer set* multibahasa dan embedding yang selaras lintas bahasa. Pada *student* berkapasitas sangat rendah, *soft label* dan *temperature* tinggi tidak memberi manfaat, sedangkan *ensemble* beberapa *seed* dapat dilipat menjadi satu tabel tanpa biaya.
- *Fine-tuning* embedding menaikkan akurasi pada bahasa yang ada di data distilasi, tetapi menurunkannya pada bahasa tanpa data distilasi. Transfer ke bahasa-bahasa tersebut dibawa oleh embedding pra-latih yang tidak ikut dilatih.
- Set uji dengan pemetaan rubrik ke pohon IPTC, kontrol kontaminasi, dan *site-cluster bootstrap* dapat dipakai ulang untuk mengevaluasi pengklasifikasi IPTC lain.

Penelitian lanjutan mencakup:

- memperluas *transfer set* ke bahasa yang lemah, terutama bahasa Afrika di luar pra-latih XLM-R;
- regularisasi *fine-tuning* yang menahan embedding dekat ke ruang pra-latih, supaya akurasi in-distribusi dan transfer lintas bahasa dapat diperoleh bersamaan;
- kepala non-linear yang tetap murah dengan embedding terkuantisasi, mengingat kepala MLP memberi kenaikan kecil;
- tokenizer yang lebih cepat (misalnya pencarian kata langsung ke tabel), karena tokenisasi mengambil 98% waktu inferensi;
- pemangkasan tokenizer yang mempertahankan token lintas bahasa;
- klasifikasi hierarkis ke IPTC level 2 dan klasifikasi multi-label;
- validasi dengan anotasi manusia IPTC multibahasa pada sampel set uji.

KETERSEDIAAN KODE, MODEL, DAN DATA

Kode (pengumpulan data, konstruksi set uji, pelabelan *teacher*, *training*, evaluasi, *benchmark*) dan notebook yang mereproduksi setiap angka, tabel, dan gambar naskah ini tersedia di [TODO: URL GitHub]. Model StaticKD tersedia di [TODO: URL Hugging Face]. Set uji dirilis sebagai

manifest berisi URL/ID artikel, label, dan asal label, beserta skrip rekonstruksi. Teks artikel tidak dirilis ulang karena hak cipta penerbit dan lisensi dataset sumber (misalnya CC BY-NC untuk MasakhaNEWS). EMMediaTopic tersedia di CLARIN.SI [70].

PERNYATAAN PENGGUNAAN AI

[TODO: Sesuaikan dengan kebijakan jurnal.] Penulis menggunakan asisten AI (Claude, Anthropic) untuk membantu penulisan kode eksperimen, analisis, dan penyusunan draf naskah. Seluruh desain, hasil, dan klaim telah diperiksa dan menjadi tanggung jawab penulis.

UCAPAN TERIMA KASIH

[TODO: Pembimbing, pendanaan, fasilitas.]

REFERENSI

- [1] International Press Telecommunications Council (IPTC), "Media topics - IPTC NewsCodes," [Online]. Available: <https://iptc.org/standards/media-topics/>, 2024.
- [2] T. Kuzman and N. Ljubešić, "LLM teacher-student framework for text classification with no manually annotated data: A case study in IPTC news topic classification," *IEEE Access*, vol. 13, pp. 35 621–35 633, 2025.
- [3] A. Conneau, K. Khandelwal, N. Goyal, V. Chaudhary, G. Wenzek, F. Guzmán, E. Grave, M. Ott, L. Zettlemoyer, and V. Stoyanov, "Un-supervised cross-lingual representation learning at scale," in *Proc. 58th Annu. Meeting Assoc. Comput. Linguistics (ACL)*, 2020, pp. 8440–8451.
- [4] T. Kuzman, P. Pungeršek, P. Rupnik, D. Širinić, and N. Ljubešić, "Super-charging agenda setting research: The ParlaCAP dataset of 28 European parliaments and a scalable multilingual LLM-based classification," in *Proc. 3rd Workshop Natural Language Process. for Political Sciences (PoliticalNLP) at LREC 2026*, 2026, pp. 94–110.
- [5] T. Kuzman, P. Pungeršek, P. Rupnik, I. Porupski, V. Dinić, and N. Ljubešić, "State of the art in text classification for South Slavic languages: Fine-tuning or prompting?" in *Proc. Workshop Shaping Multilingual, Multimodal AI for the Social Sciences and Humanities (LLMs4SSH) at LREC 2026*, 2026, pp. 1–17.
- [6] T. Kuzman, I. Mozetič, and N. Ljubešić, "Automatic genre identification for robust enrichment of massive text collections: Investigation of classification methods in the era of large language models," *Mach. Learn. Knowl. Extraction*, vol. 5, no. 3, pp. 1149–1175, 2023.
- [7] S. Luccioni, Y. Jernite, and E. Strubell, "Power hungry processing: Watts driving the cost of AI deployment?" in *Proc. ACM Conf. Fairness, Accountability, and Transparency (FAccT)*, 2024, pp. 85–99.
- [8] M. Treviso, J.-U. Lee, T. Ji, B. van Aken, Q. Cao, M. R. Ciosici, M. Hassid, K. Heafield, S. Hooker, C. Raffel, P. H. Martins, A. F. T. Martins, J. Z. Forde, P. Milder, E. Simpson, N. Slonim, J. Dodge, E. Strubell, N. Balasubramanian, L. Derczynski, I. Gurevych, and R. Schwartz, "Efficient methods for natural language processing: A survey," *Trans. Assoc. Comput. Linguistics*, vol. 11, pp. 826–860, 2023.
- [9] A. Joulin, E. Grave, P. Bojanowski, and T. Mikolov, "Bag of tricks for efficient text classification," in *Proc. 15th Conf. European Chapter Assoc. Comput. Linguistics (EACL)*, Vol. 2: Short Papers, 2017, pp. 427–431.
- [10] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen, "LoRA: Low-rank adaptation of large language models," in *Proc. 10th Int. Conf. Learn. Represent. (ICLR)*, 2022.
- [11] O. Razuvayevskaya, B. Wu, J. A. Leite, F. Heppell, I. Srba, C. Scarton, K. Bontcheva, and X. Song, "Comparison between parameter-efficient techniques and full fine-tuning: A case study on multilingual news article classification," *PLOS ONE*, vol. 19, no. 5, p. e0301738, 2024.
- [12] R. Azimi, R. Rishav, M. Teichmann, and S. Ebrahimi Kahou, "KD-LoRA: A hybrid approach to efficient fine-tuning with LoRA and knowledge distillation," in *Proc. 4th NeurIPS Efficient Natural Language and Speech Processing Workshop*, ser. Proc. Mach. Learn. Res., vol. 262, 2024, pp. 73–80.
- [13] W. Wang, H. Bao, S. Huang, L. Dong, and F. Wei, "MiniLMv2: Multi-head self-attention relation distillation for compressing pretrained transformers," in *Findings Assoc. Comput. Linguistics: ACL-IJCNLP 2021*, 2021, pp. 2140–2151.
- [14] X. Jiao, Y. Yin, L. Shang, X. Jiang, X. Chen, L. Li, F. Wang, and Q. Liu, "TinyBERT: Distilling BERT for natural language understanding," in *Findings Assoc. Comput. Linguistics: EMNLP 2020*, 2020, pp. 4163–4174.
- [15] Z. Yao, R. Yazdani Aminabadi, M. Zhang, X. Wu, C. Li, and Y. He, "ZeroQuant: Efficient and affordable post-training quantization for large-scale transformers," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 35, 2022, pp. 27 168–27 183.
- [16] G. Hinton, O. Vinyals, and J. Dean, "Distilling the knowledge in a neural network," *NIPS Deep Learning and Representation Learning Workshop*, arXiv:1503.02531, 2015.
- [17] C. Bucilua, R. Caruana, and A. Niculescu-Mizil, "Model compression," in *Proc. 12th ACM SIGKDD Int. Conf. Knowl. Discovery Data Mining (KDD)*, 2006, pp. 535–541.
- [18] S. Tulkens and T. van Dongen, "Model2Vec: Fast state-of-the-art static embeddings," Software, Zenodo, 2024, [Online]. Available: <https://github.com/MinishLab/model2vec>.
- [19] T. Wada, Y. Hirakawa, R. Shimizu, T. Kawashima, and Y. Saito, "Static word embeddings for sentence semantic representation," in *Proc. Empirical Methods Natural Language Process. (EMNLP)*, 2025, pp. 6195–6211.
- [20] J. Chen, S. Xiao, P. Zhang, K. Luo, D. Lian, and Z. Liu, "M3-Embedding: Multi-linguality, multi-functionality, multi-granularity text embeddings through self-knowledge distillation," in *Findings Assoc. Comput. Linguistics: ACL 2024*, 2024, pp. 2318–2335.
- [21] L. Galke and A. Scherp, "Bag-of-words vs. graph vs. sequence in text classification: Questioning the necessity of text-graphs and the surprising strength of a wide MLP," in *Proc. 60th Annu. Meeting Assoc. Comput. Linguistics (ACL)*, Vol. 1: Long Papers, 2022, pp. 4038–4051.
- [22] M. Iyyer, V. Manjunatha, J. Boyd-Graber, and H. Daumé III, "Deep unordered composition rivals syntactic methods for text classification," in *Proc. 53rd Annu. Meeting Assoc. Comput. Linguistics and 7th Int. Joint Conf. Natural Language Process. (ACL-IJCNLP)*, Vol. 1: Long Papers, 2015, pp. 1681–1691.
- [23] D. I. Adelani, H. Liu, X. Shen, N. Vassilyev, J. O. Alabi, Y. Mao, H. Gao, and E.-S. A. Lee, "SIB-200: A simple, inclusive, and big evaluation dataset for topic classification in 200+ languages and dialects," in *Proc. 18th Conf. European Chapter Assoc. Comput. Linguistics (EACL)*, Vol. 1: Long Papers, 2024, pp. 226–245.
- [24] R. V. Guha, D. Brickley, and S. Macbeth, "Schema.org: Evolution of structured data on the web," *Commun. ACM*, vol. 59, no. 2, pp. 44–51, 2016.
- [25] D. I. Adelani, M. Masiak, I. A. Azime, J. Alabi, A. L. Tonja, C. Mwase, O. Ogundepo, B. F. P. Dossou, A. Oladipo, D. Nixdorf *et al.*, "MasakhaNEWS: News topic classification for African languages," in *Proc. 13th Int. Joint Conf. Natural Language Process. and 3rd Conf. Asia-Pacific Chapter Assoc. Comput. Linguistics (IJCNLP-AAACL)*, Vol. 1: Long Papers, 2023, pp. 144–159.
- [26] A. Petukhova and N. Fachada, "MN-DS: A multilabeled news dataset for news articles hierarchical classification," *Data*, vol. 8, no. 5, p. 74, 2023.
- [27] A. Mirashi, S. Sonavane, P. Lingayat, T. Padhiyar, and R. Joshi, "L3Cube-IndicNews: News-based short text and long document classification datasets in Indic languages," in *Proc. 20th Int. Conf. Natural Language Process. (ICON)*, 2023, pp. 442–449.
- [28] T. Hossain, A.-R. Islam, M. H. K. Mehedi, A. A. Rasel, M. Abdullah-Al-Wadud, and J. Uddin, "BanglaNewsClassifier: A machine learning approach for news classification in Bangla newspapers using hybrid stacking classifiers," *PLOS ONE*, vol. 20, no. 6, p. e0321291, 2025.
- [29] Z. Wang, X. Shan, X. Zhang, and J. Yang, "N24News: A new dataset for multimodal news classification," in *Proc. 13th Language Resources and Evaluation Conf. (LREC)*, 2022, pp. 6768–6775.
- [30] F. Gildardi, M. Alizadeh, and M. Kubli, "ChatGPT outperforms crowd workers for text-annotation tasks," *Proc. Nat. Acad. Sci. USA*, vol. 120, no. 30, p. e2305016120, 2023.
- [31] C. Ziems, W. Held, O. Shaikh, J. Chen, Z. Zhang, and D. Yang, "Can large language models transform computational social science?" *Computational Linguistics*, vol. 50, no. 1, pp. 237–291, 2024.
- [32] S. Mukherjee and A. Hassan Awadallah, "XtremeDistil: Multi-stage distillation for massive multilingual models," in *Proc. 58th Annu. Meeting Assoc. Comput. Linguistics (ACL)*, 2020, pp. 2221–2234.
- [33] C.-Y. Hsieh, C.-L. Li, C.-K. Yeh, H. Nakhost, Y. Fujii, A. Ratner, R. Krishna, C.-Y. Lee, and T. Pfister, "Distilling step-by-step! Outperforming larger language models with less training data and smaller model sizes," in *Findings Assoc. Comput. Linguistics: ACL 2023*, 2023, pp. 8003–8017.

- [34] S. Gupta, Y. Matsubara, A. Chadha, and A. Moschitti, "Cross-lingual knowledge distillation for answer sentence selection in low-resource languages," in *Findings Assoc. Comput. Linguistics: ACL 2023*, 2023, pp. 14 078–14 092.
- [35] R. Piperno, L. Bacco, F. Dell'Orletta, M. Merone, and L. Pecchia, "Cross-lingual distillation for domain knowledge transfer with sentence transformers," *Knowledge-Based Systems*, vol. 311, p. 113079, 2025.
- [36] N. Reimers and I. Gurevych, "Making monolingual sentence embeddings multilingual using knowledge distillation," in *Proc. Conf. Empirical Methods Natural Language Process. (EMNLP)*, 2020, pp. 4512–4525.
- [37] C. Yang, Y. Zhu, W. Lu, Y. Wang, Q. Chen, C. Gao, B. Yan, and Y. Chen, "Survey on knowledge distillation for large language models: Methods, evaluation, and application," *ACM Trans. Intell. Syst. Technol.*, vol. 16, no. 6, pp. 1–27, 2025.
- [38] X. Zhu, J. Li, Y. Liu, C. Ma, and W. Wang, "A survey on model compression for large language models," *Trans. Assoc. Comput. Linguistics*, vol. 12, pp. 1556–1577, 2024.
- [39] Q. Ye, M. Khabsa, M. Lewis, S. Wang, X. Ren, and A. Jaech, "Sparse distillation: Speeding up text classification by using bigger student models," in *Proc. Conf. North American Chapter Assoc. Comput. Linguistics: Human Language Technologies (NAACL-HLT)*, 2022, pp. 2361–2375.
- [40] N. Ding, Y. Qin, G. Yang, F. Wei, Z. Yang, Y. Su, S. Hu, Y. Chen, C.-M. Chan, W. Chen, J. Yi, W. Zhao, X. Wang, Z. Liu, H.-T. Zheng, J. Chen, Y. Liu, J. Tang, J. Li, and M. Sun, "Parameter-efficient fine-tuning of large-scale pre-trained language models," *Nature Mach. Intell.*, vol. 5, no. 3, pp. 220–235, 2023.
- [41] J. H. Cho and B. Hariharan, "On the efficacy of knowledge distillation," in *Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV)*, 2019, pp. 4793–4801.
- [42] S. I. Mirzadeh, M. Farajtabar, A. Li, N. Levine, A. Matsukawa, and H. Ghasemzadeh, "Improved knowledge distillation via teacher assistant," in *Proc. AAAI Conf. Artif. Intell.*, vol. 34, no. 4, 2020, pp. 5191–5198.
- [43] C. Zhang, Q. Li, D. Song, Z. Ye, Y. Gao, and Y. Hu, "Towards the law of capacity gap in distilling language models," in *Proc. 63rd Annu. Meeting Assoc. Comput. Linguistics (ACL)*, Vol. 1: Long Papers, 2025, pp. 22 504–22 528.
- [44] C. Zhang, Y. Yang, J. Liu, J. Wang, Y. Xian, B. Wang, and D. Song, "Lifting the curse of capacity gap in distilling language models," in *Proc. 61st Annu. Meeting Assoc. Comput. Linguistics (ACL)*, Vol. 1: Long Papers, 2023, pp. 4535–4553.
- [45] T. Huang, S. You, F. Wang, C. Qian, and C. Xu, "Knowledge distillation from a stronger teacher," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 35, 2022, pp. 33 716–33 727.
- [46] Z. Li, X. Li, L. Yang, B. Zhao, R. Song, L. Luo, J. Li, and J. Yang, "Curriculum temperature for knowledge distillation," in *Proc. AAAI Conf. Artif. Intell.*, vol. 37, no. 2, 2023, pp. 1504–1512.
- [47] X.-C. Li, W.-S. Fan, S. Song, Y. Li, B. Li, Y. Shao, and D.-C. Zhan, "Asymmetric temperature scaling makes larger networks teach well again," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 35, 2022, pp. 3830–3842.
- [48] S. Sun, W. Ren, J. Li, R. Wang, and X. Cao, "Logit standardization in knowledge distillation," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2024, pp. 15 731–15 740.
- [49] B. Zhao, Q. Cui, R. Song, Y. Qiu, and J. Liang, "Decoupled knowledge distillation," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2022, pp. 11 943–11 952.
- [50] Y. Wang, W. Niu, X. Yao, L. You, and W. Fei, "Rethinking the dark knowledge and Kullback-Leibler divergence loss in knowledge distillation under capacity mismatching," in *Proc. AAAI Conf. Artif. Intell.*, vol. 40, no. 31, 2026, pp. 26 688–26 696.
- [51] L. Beyer, X. Zhai, A. Royer, L. Markeeva, R. Anil, and A. Kolesnikov, "Knowledge distillation: A good teacher is patient and consistent," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2022, pp. 10 915–10 924.
- [52] S. Stanton, P. Izmailov, P. Kirichenko, A. A. Alemi, and A. G. Wilson, "Does knowledge distillation really work?" in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 34, 2021, pp. 6906–6919.
- [53] U. Ojha, Y. Li, A. S. Rajan, Y. Liang, and Y. J. Lee, "What knowledge gets distilled in knowledge distillation?" in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 36, 2023, pp. 11 037–11 048.
- [54] P. Gupta and M. Jaggi, "Obtaining better static word embeddings using contextual embedding models," in *Proc. 59th Annu. Meeting Assoc. Comput. Linguistics and 11th Int. Joint Conf. Natural Language Process. (ACL-IJCNLP)*, Vol. 1: Long Papers, 2021, pp. 5241–5253.
- [55] L. Stankevičius and M. Lukoševičius, "Extracting sentence embeddings from pretrained transformer models," *Applied Sciences*, vol. 14, no. 19, p. 8887, 2024.
- [56] K. Enevoldsen, I. Chung, I. Kerboua, M. Kardos, A. Mathur, D. Stap et al., "MMTEB: Massive multilingual text embedding benchmark," in *Proc. 13th Int. Conf. Learn. Represent. (ICLR)*, 2025.
- [57] A. Petrov, E. La Malfa, P. Torr, and A. Bibi, "Language model tokenizers introduce unfairness between languages," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 36, 2023, pp. 36 963–36 990.
- [58] J.-C. Klie, B. Webber, and I. Gurevych, "Annotation error detection: Analyzing the past and present for a more coherent future," *Computational Linguistics*, vol. 49, no. 1, pp. 157–198, 2023.
- [59] H. Song, M. Kim, D. Park, Y. Shin, and J.-G. Lee, "Learning from noisy labels with deep neural networks: A survey," *IEEE Trans. Neural Netw. Learn. Syst.*, vol. 34, no. 11, pp. 8135–8153, 2023.
- [60] C. Northcutt, A. Athalye, and J. Mueller, "Pervasive label errors in test sets destabilize machine learning benchmarks," in *Proc. Neural Inf. Process. Syst. Track Datasets and Benchmarks*, vol. 1, 2021.
- [61] O. Sainz, J. Campos, I. García-Ferrero, J. Etxaniz, O. Lopez de Lacalle, and E. Agirre, "NLP evaluation in trouble: On the need to measure LLM data contamination for each benchmark," in *Findings Assoc. Comput. Linguistics: EMNLP 2023*, 2023, pp. 10 776–10 787.
- [62] I. Magar and R. Schwartz, "Data contamination: From memorization to exploitation," in *Proc. 60th Annu. Meeting Assoc. Comput. Linguistics (ACL)*, Vol. 2: Short Papers, 2022, pp. 157–165.
- [63] C. Deng, Y. Zhao, X. Tang, M. Gerstein, and A. Cohan, "Investigating data contamination in modern benchmarks for large language models," in *Proc. Conf. North American Chapter Assoc. Comput. Linguistics: Human Language Technologies (NAACL-HLT)*, Vol. 1: Long Papers, 2024, pp. 8706–8719.
- [64] A. Z. Broder, "On the resemblance and containment of documents," in *Proc. Compression and Complexity of SEQUENCES*, 1997, pp. 21–29.
- [65] K. Lee, D. Ippolito, A. Nystrom, C. Zhang, D. Eck, C. Callison-Burch, and N. Carlini, "Deduplicating training data makes language models better," in *Proc. 60th Annu. Meeting Assoc. Comput. Linguistics (ACL)*, Vol. 1: Long Papers, 2022, pp. 8424–8445.
- [66] P. Koehn, "Statistical significance tests for machine translation evaluation," in *Proc. Conf. Empirical Methods Natural Language Process. (EMNLP)*, 2004, pp. 388–395.
- [67] R. Dror, G. Baumer, S. Shlomov, and R. Reichart, "The hitchhiker's guide to testing statistical significance in natural language processing," in *Proc. 56th Annu. Meeting Assoc. Comput. Linguistics (ACL)*, Vol. 1: Long Papers, 2018, pp. 1383–1392.
- [68] C. A. Field and A. H. Welsh, "Bootstrapping clustered data," *J. Roy. Statist. Soc. B*, vol. 69, no. 3, pp. 369–390, 2007.
- [69] M. Hagmann, P. Meier, and S. Riezler, "Towards inferential reproducibility of machine learning research," in *Proc. 11th Int. Conf. Learn. Represent. (ICLR)*, 2023.
- [70] T. Kuzman and N. Ljubešić, "News topic dataset EMMediaTopic 1.0," Slovenian language resource repository CLARIN.SI, <http://hdl.handle.net/11356/1991>, 2025.
- [71] CloverSearch, "cc-news-multilingual: Common Crawl news split by language and year," Hugging Face Datasets. [Online]. Available: <https://huggingface.co/datasets/CloverSearch/cc-news-multilingual>.
- [72] Common Crawl Foundation, "CC-NEWS: News crawl archive," <https://commoncrawl.org/blog/news-dataset-available>, WARC files 2024-01 to 2026-08, accessed Sep. 2026, 2026.
- [73] A. Barbaresi, "Trafilatura: A web scraping library and command-line tool for text discovery and extraction," in *Proc. 59th Annu. Meeting Assoc. Comput. Linguistics and 11th Int. Joint Conf. Natural Lang. Process.: System Demonstrations*, 2021, pp. 122–131.
- [74] Jakarta Artificial Intelligence Research, "IndoNews: Indonesian news topic classification dataset (liputan6)," Hugging Face dataset jakartaresearch/indonews, 2021.
- [75] I. A. Azime and N. Mohammed, "An Amharic news text classification dataset," arXiv:2103.05639 (dataset); Hugging Face rasyosef/amharic-news-category-classification, 2021.
- [76] D. David, "Swahili: News classification dataset," Zenodo, doi:10.5281/zenodo.5514203; Hugging Face dataset community-datasets/swahili_news, 2020.
- [77] V. Sanh, L. Debut, J. Chaumond, and T. Wolf, "DistilBERT, a distilled version of BERT: Smaller, faster, cheaper and lighter," arXiv:1910.01108 (NeurIPS 2019 EMC² Workshop), 2019.

- [78] Q. McNemar, "Note on the sampling error of the difference between correlated proportions or percentages," *Psychometrika*, vol. 12, no. 2, pp. 153–157, 1947.
- [79] S. Holm, "A simple sequentially rejective multiple test procedure," *Scand. J. Statist.*, vol. 6, no. 2, pp. 65–70, 1979.
- [80] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, "On calibration of modern neural networks," in *Proc. 34th Int. Conf. Mach. Learn. (ICML)*, ser. Proc. Mach. Learn. Res., vol. 70, 2017, pp. 1321–1330.