Date of publication xxxx 00, 0000, date of current version xxxx 00, 0000.

Digital Object Identifier 10.1109/ACCESS.2024.0429000

StaticKD: Mendistilasi Pengklasifikasi Topik Berita IPTC Multibahasa menjadi Tabel Token-Logit Statis untuk Inferensi Ringan pada CPU

OBI KASTANYA[1] AND ANANTA DWI PRAYOGA ALWY[1]

[1]Departemen Teknik Informatika, Institut Teknologi Sepuluh Nopember, Surabaya, Indonesia (e-mail: 6025252015@student.its.ac.id; 6025252007@student.its.ac.id)

Penulis korespondensi: Obi Kastanya (e-mail: 6025252015@student.its.ac.id).

Penelitian ini tidak menerima pendanaan khusus.

ABSTRACT Penyaringan berita berdasarkan taksonomi Media Topic dari International Press Telecommunications Council (IPTC) memerlukan pengklasifikasi yang cukup murah untuk aliran *pipeline* artikel multibahasa *real-time*. Pengklasifikasi IPTC multibahasa terbuka berbasis XLM-RoBERTa-large yang sudah ada memerlukan 1,190 hingga 2,816 milidetik per artikel pada satu *core* prosesor. StaticKD memakai pengklasifikasi ini sebagai *teacher* dan memberi setiap token kosakata satu skor untuk masing-masing dari 17 topik IPTC tingkat atas. Klasifikasi hanya memerlukan tokenisasi artikel dan perataan skor tokennya. *Student* diinisialisasi dari *embedding* statis multibahasa (satu vektor tetap per token) dan belajar dari keluaran *teacher* pada 285,999 artikel dalam 69 bahasa. Evaluasi memakai *test set* baru berisi 12,744 artikel dalam 47 bahasa. Labelnya berasal dari anotator manusia atau editor redaksi dan bukan dari model yang membaca artikel. Perbedaan antarmodel diuji dengan *site-cluster bootstrap* berpasangan dan koreksi Holm. StaticKD mencapai macro-F1 sebesar 0.545 (interval kepercayaan 95% 0.490–0.605) dan mempertahankan 91.1% skor *teacher* (0.598). Model berukuran 34 megabyte ini mengklasifikasikan 539 artikel per detik per *core* dan berjalan sekitar 682 kali lebih cepat daripada *teacher* yang dikuantisasi 8-bit. Model ini lebih akurat daripada fastText (+0.098 macro-F1, $p < 0.001$) dan *support vector machine* linear (+0.059, $p = 0.040$) yang dilatih pada label yang sama. Pengklasifikasi Model2Vec yang dilatih pada label ini sama akuratnya dalam batas 0.01 macro-F1 (*two one-sided tests*, $p = 0.025$). Pengklasifikasi tersebut memerlukan berkas 15 kali lebih besar dan memori dua kali lipat. StaticKD lemah pada bahasa yang tidak terdapat baik dalam data pelatihannya maupun dalam data prapelatihan *teacher*.

INDEX TERMS Inferensi efisien, *knowledge distillation*, klasifikasi teks multibahasa, klasifikasi topik berita, *embedding* statis.

I. PENDAHULUAN

SISTEM klasifikasi berita yang dipakai di dunia nyata memerlukan taksonomi yang terstandar dan konsisten tetapi banyak studi sebelumnya masih bergantung pada himpunan label yang lokal, terfragmentasi, atau khusus korpus [1], [2], [3]. Taksonomi Media Topic dari International Press Telecommunications Council (IPTC) menyediakan standar bersama tersebut untuk interoperabilitas semantik dan pertukaran informasi antarorganisasi media global [4]. Taksonomi ini berupa hierarki yang tidak bergantung pada bahasa dengan 17 kategori tingkat atas (Bagian II-A) sehingga satu pengklasifikasi dapat melayani berita dalam banyak bahasa.

Model berbasis *transformer* seperti BERT, RoBERTa, dan perluasan multibahasanya kini mendominasi klasifikasi artikel berita karena mampu menangkap representasi semantik yang dalam dan dependensi kontekstual [1], [5], [6] tetapi biaya komputasinya tinggi. Model *transformer* yang memetakan artikel berita ke taksonomi IPTC akurat tetapi biaya tersebut menghambat penerapannya dalam produksi pada server *central processing unit* (CPU) tanpa *graphics processing unit* (GPU) [7], [8]. Hambatan ini berasal dari *multi-head self-attention* yang kompleksitas komputasi dan memorinya $O(N^2)$ terhadap panjang input N [9] serta dari

ratusan juta parameter yang menempati memori berukuran gigabyte. Setiap lapisan model juga menjalankan perkalian matriks padat pada sedikit *core* CPU yang dipakai bersama dengan tahap-tahap lain dari *pipeline* berita sehingga klasifikasi bersaing dengan tahap-tahap tersebut untuk *core* yang sama.

Sejumlah penelitian telah mencoba menurunkan biaya tersebut melalui distilasi *transformer* atau melalui model *bag-of-words* tetapi kedua jalur ini masih menyisakan kelemahan. *Transformer* besar dapat didistilasi menjadi arsitektur ringkas seperti MiniLM [10] dan DistilBERT [11] tetapi versi multibahasa dari *transformer* ringkas ini tetap memiliki lebih dari 100 juta parameter dan masih memakai *self-attention* serta perkalian matriks padat. Model *bag-of-words* seperti fastText [12] sebaliknya mencapai latensi milidetik pada CPU tetapi buruk dalam transfer lintas bahasa karena vektor token-nya dipelajari dari awal tanpa penyelarasan lintas bahasa.

Klasifikasi topik berita cocok untuk representasi statis karena model *bag-of-words* tetap kompetitif dengan model sekuens pada klasifikasi topik [13]. Tiga hasil terdahulu menyediakan bahan untuk membangun pengklasifikasi statis yang belajar dari *transformer* dan dapat dipakai lintas bahasa. Sparse Distillation [14] memindahkan pengetahuan *transformer* besar sebagai *teacher* ke *student* berupa rata-rata *embedding* kata dan n-gram (*bag-of-embeddings*) dengan meminimalkan divergensi Kullback–Leibler (KL) terhadap distribusi probabilitas keluaran *teacher*. Wada dkk. [15] dan kerangka kerja Model2Vec [16] mengompresi *sentence transformer* menjadi *embedding* token statis. *Embedding* Model2Vec multibahasa selaras lintas 101 bahasa sehingga lapisan klasifikasi (*head*) yang dilatih pada sebagian bahasa berpeluang dipakai pada bahasa lain. Singh dkk. [17] mengonversi model klasifikasi linear atas *embedding* n-gram menjadi kamus *lookup* koefisien yang mempercepat inferensi pada CPU tanpa GPU. StaticKD memakai prinsip yang sama dalam bentuk *folding* yang menerapkan *head* linear pada setiap *embedding* token sekali sebelum model dipakai.

Penelitian terdahulu menyisakan dua celah yang menghalangi klasifikasi IPTC multibahasa yang murah pada CPU.

1) *Belum ada pengklasifikasi IPTC multibahasa berbiaya rendah yang dievaluasi pada berita nyata.* Pengklasifikasi IPTC multibahasa terbuka dari Kuzman dan Ljubešić [6] adalah model XLM-RoBERTa-large (XLM-R) [18] dengan 24 lapisan *transformer* dan 559.9 juta parameter. Sparse Distillation [14] menghasilkan *student* yang hingga 600 kali lebih cepat tetapi hanya dievaluasi pada bahasa Inggris dan menyimpan sekitar satu miliar parameter dalam tabel n-gram-nya.
2) *Belum ada pengklasifikasi statis multibahasa dengan embedding selaras lintas bahasa yang head-nya dilipat menjadi satu tabel token.* Sparse Distillation [14] dan pengklasifikasi bawaan Model2Vec [16] menempatkan *head multilayer perceptron* (MLP) nonlinear di atas *embedding* yang dirata-ratakan. Lapisan nonlinear ini mencegah *folding* sehingga matriks *embedding* 256 dimensi harus tetap disimpan utuh bersama *head*-nya.

Studi ini mengisi kedua celah dengan StaticKD dan menguji-nya pada *test set* IPTC multibahasa baru. StaticKD memakai pengklasifikasi IPTC terbuka sebagai *teacher* dan melatih *head* linear di atas *embedding* statis multibahasa Model2Vec pada berita berlabel *teacher* dalam banyak bahasa. Kontribusi studi ini adalah sebagai berikut.

- *Model ringan hasil folding. Embedding* Model2Vec dan *head* linear yang dilatih bersama melalui distilasi dilipat menjadi satu tabel token-logit berisi 17 skor topik per token sehingga klasifikasi pada CPU cukup merata-ratakan baris tabel tanpa pustaka *deep learning*.
- *Test set IPTC multibahasa dengan label manusia dan editorial. Test set* ini mencakup 47 bahasa dan disusun dari halaman berita CC-NEWS 2024–2026 yang penerbitnya mencatat rubrik redaksi dalam metadata schema.org [19] serta dari *dataset* publik berlabel manusia atau kategori penerbit [2], [3], [20], [21], [22]. Set ini dirilis sebagai manifes beserta skrip rekonstruksi dan tabel pemetaan rubrik ke IPTC.

Bagian II mengulas penelitian terkait dan Bagian III menjelaskan StaticKD. Data dan *test set* dijelaskan pada Bagian IV dan *baseline* serta protokol evaluasi pada Bagian V. Hasil disajikan pada Bagian VI dan dibahas bersama keterbatasan studi pada Bagian VII. Bagian VIII menutup makalah ini.

II. PENELITIAN TERKAIT

A. KLASIFIKASI BERITA MULTIBAHASA DAN TAKSONOMI IPTC

Taksonomi IPTC Media Topic [4] adalah satu skema bersama pengganti skema pelabelan *ad hoc* dari masing-masing redaksi. Tingkat atas taksonomi ini memiliki 17 kategori: *arts, culture, entertainment and media*; *conflict, war and peace*; *crime, law and justice*; *disaster, accident and emergency incident*; *economy, business and finance*; *education*; *environment*; *health*; *human interest*; *labour*; *lifestyle and leisure*; *politics*; *religion*; *science and technology*; *society*; *sport*; dan *weather*.

Test set studi ini (Bagian IV-C) memakai lima *dataset* berita publik berlabel topik: MasakhaNEWS [2], L3Cube-IndicNews [3], *dataset* berita Bangla [21], IndoNews [22], dan MN-DS [20]. *Dataset* semacam ini biasanya mendefinisikan taksonominya sendiri dan hanya mencakup satu bahasa atau satu wilayah. Anotator manusia melabeli artikel berita MasakhaNEWS dengan tujuh kategori dalam bahasa Inggris dan bahasa Prancis serta 14 bahasa lain yang banyak dituturkan di Afrika. L3Cube-IndicNews mencakup 10 bahasa India dan bersama *dataset* berita Bangla serta IndoNews mengambil label dari kategori situs penerbit. MN-DS adalah satu-satunya *dataset* publik yang dianotasi manusia secara langsung dengan topik IPTC tingkat atas tetapi hanya berisi artikel berbahasa Inggris.

Anotasi berita oleh pakar dalam puluhan bahasa memerlukan biaya besar sehingga penelitian terbaru memakai *large language model* (LLM) *zero-shot* sebagai anotator. Studi dalam ilmu sosial komputasional melaporkan bahwa anotasi LLM atas teks politik dan sentimen dapat mencapai

kesepakatan yang sebanding dengan manusia [23], [24]. Fatemi dkk. [25] mengevaluasi GPT untuk klasifikasi *zero-shot* artikel berita ke dalam taksonomi IPTC. Kuzman dan Ljubešić [6] membangun korpus EMMediaTopic [26] dengan memakai GPT-4o untuk menganotasi artikel berita dalam empat bahasa Eropa (Slovenia, Kroasia, Katalan, dan Yunani). Data berlabel GPT-4o ini dipakai untuk *fine-tuning transformer* XLM-R-large [18]. Model yang dihasilkan berkinerja setara dengan GPT-4o pada *test set* beranotasi manusia. Studi selanjutnya oleh kelompok yang sama mendapati bahwa *encoder* hasil *fine-tuning* lebih praktis daripada LLM untuk anotasi skala besar [27].

Model XLM-R-large hasil *fine-tuning* Kuzman dan Ljubešić [6] menjadi *teacher* dalam studi ini (Bagian III-C). *Teacher* ini menjalani *fine-tuning* hanya pada empat bahasa sehingga akurasinya pada bahasa lain bergantung pada transfer lintas bahasa dari prapelatihan XLM-R.

B. *KNOWLEDGE DISTILLATION* KE DALAM ARSITEKTUR *BAG-OF-EMBEDDINGS*

Knowledge distillation (KD) memindahkan pengetahuan dari jaringan *teacher* yang berat ke model *student* yang ringan dengan menyelaraskan distribusi probabilitas keluaran kedua model [28], [29], [30]. *Student* dapat belajar dari distribusi lengkap *teacher* yang disebut *soft label* atau hanya dari kelas teratasnya yang disebut *hard label*. Distribusi *teacher* dan *student* dihitung dari vektor logit yang dibagi dengan *temperature* τ sebelum *softmax*. Nilai τ yang lebih tinggi meratakan distribusi sehingga *student* dapat melihat seberapa besar probabilitas yang diberikan *teacher* pada kelas yang salah. Divergensi KL di antara distribusi *teacher* dan *student* dapat dipecah menjadi bagian kelas target dan bagian nontarget yang dikenal sebagai *dark knowledge* [31]. *Temperature* yang menentukan seberapa besar bagian nontarget ini terlihat diperlakukan sebagai *hyperparameter* penting yang dapat dipelajari [32].

Student untuk klasifikasi teks hampir selalu berupa *transformer* seperti DistilBERT [11] atau MiniLMv2 [10]. Pola yang sama berlaku untuk distilasi lintas bahasa yang memindahkan pengetahuan *teacher* ke bahasa dengan sedikit data [33]. Sparse Distillation dari Ye dkk. [14] adalah pengecualian karena *student*-nya bukan *transformer*. Metode ini menunjukkan bahwa *transformer* besar seperti RoBERTa-large dapat didistilasi menjadi representasi *bag-of-embeddings* nonkontekstual dengan meminimalkan divergensi KL terhadap *soft prediction* dari *teacher*. *Student* tersebut mempertahankan 97% akurasi *teacher* pada enam tugas klasifikasi berbahasa Inggris dan berjalan hingga 600 kali lebih cepat. Kelemahannya ada pada tabel *embedding* kata dan n-gram yang menampung sekitar satu miliar parameter dan memerlukan penyimpanan berukuran gigabyte.

Student Sparse Distillation berupa *deep averaging network* [34] dengan *head* nonlinear. Representasi hasil *pooling* $\mathbf{h}(d)$ pada jaringan ini melewati dua lapisan *fully connected* dengan *rectified linear unit* (ReLU) di antaranya:

$$\mathbf{z}^S(d) = W_2 \cdot \max(0, W_1\mathbf{h}(d) + \mathbf{b}_1) + \mathbf{b}_2. \qquad (1)$$

Operator nonlinear $\max(0,\cdot)$ mencegah *head* dilipat ke dalam tabel *embedding*. *Student* ini tetap memerlukan dua perkalian matriks padat saat inferensi.

Keberhasilan distilasi bergantung pada kesenjangan kapasitas antara *teacher* dan *student*. Ukuran *teacher* yang optimal untuk model bahasa mengikuti hukum empiris terhadap ukuran *student* [35] dan KL mendistorsi peringkat kelas ketika kapasitas *teacher* dan *student* tidak sepadan [36]. Hampir semua temuan ini berasal dari *student* berarsitektur dalam sedangkan StaticKD menghadapi kesenjangan dari 559.9 juta parameter ke satu lapisan linear di atas *embedding* yang dirata-ratakan. Studi ini menguji perilaku *temperature* dan *soft label* pada kesenjangan sebesar ini (Bagian VI-D).

Keberhasilan distilasi juga tidak selalu tercermin pada *agreement* atau proporsi dokumen yang label teratasnya sama pada *student* dan *teacher*. *Agreement* yang tinggi tidak selalu disertai generalisasi yang lebih baik [37]. Studi ini karena itu menilai *student* dengan label yang tidak berasal dari *teacher* (Bagian IV-C).

C. KOMPRESI *EMBEDDING* STATIS MULTIBAHASA (MODEL2VEC)

Embedding statis memberikan eksekusi CPU yang cepat dengan merepresentasikan dokumen sebagai rata-rata vektor tokennya tetapi kemampuan transfer lintas bahasanya bergantung pada cara vektor itu diperoleh. Vektor *embedding* statis klasik seperti fastText [12] dipelajari dari awal tanpa penyelarasan lintas bahasa sehingga buruk dalam transfer ke bahasa lain. Kerangka kerja Model2Vec [16] memperkenalkan teknik distilasi pascapemrosesan yang mengompresi *sentence transformer* menjadi *embedding* token statis. Wada dkk. [15] mengusulkan metode terkait yang menyempurnakan *embedding* statis hasil ekstraksi dari *sentence transformer*. Model multibahasa potion-multilingual-128M dari Model2Vec didistilasi dari BGE-M3 [38] dan memuat matriks *embedding* yang selaras $E \in \mathbb{R}^{|V|\times d_e}$ dengan $d_e = 256$ dan $|V| = 500{,}353$ untuk 101 bahasa. Padanan terjemahan terletak berdekatan dalam ruang ini karena penyelarasannya diwarisi dari *sentence encoder* multibahasa. *Embedding* statis seperti ini biasanya dievaluasi sebagai *embedding* serbaguna dan bukan sebagai *student* distilasi untuk taksonomi tertentu.

Pengklasifikasi pada pustaka Model2Vec (`StaticModelForClassification`) secara bawaan menambahkan lapisan tersembunyi nonlinear berisi 512 unit [16]. *Head*-nya memiliki bentuk yang sama dengan (1) dan dilatih dengan *cross-entropy* pada *hard label*. Lapisan tersembunyi ini mempertahankan dua perkalian matriks pada setiap langkah inferensi dan mencegah *folding* dengan cara yang sama seperti *head* Sparse Distillation.

D. *FOLDING* ANALITIS PADA PENGKLASIFIKASI TEKS LINEAR

Singh dkk. [17] menunjukkan dalam kerangka kerja Aug-Linear bahwa model linear atas *embedding* n-gram dapat dikonversi menjadi kamus koefisien aditif sehingga inferensi hanya memerlukan satu *lookup* per n-gram dan satu penjumlahan. Konversi ini mungkin karena *head* linear bersifat komutatif terhadap perataan *embedding* token sehingga dapat diterapkan pada setiap *embedding* sekali sebelum model dipakai. *Folding* karena itu memerlukan *head* pengklasifikasi yang linear. Inferensi model hasil *folding* tereduksi menjadi pengambilan dan perataan baris dari tabel yang dihitung sebelumnya (Bagian III-E). Aug-Linear menerapkan *folding* pada kosakata n-gram dengan *hard label* dalam pengaturan klasifikasi biner. Formulasi tersebut tidak memakai distilasi dari *teacher* dan dievaluasi pada *dataset* berbahasa Inggris.

E. *TEST SET* DENGAN LABEL EDITORIAL, KONTAMINASI, DAN KETERGANTUNGAN SAMPEL

Sumber label topik untuk *test set* dari artikel web dapat berupa label editorial yang mencatat kategori situs atau rubrik tempat redaksi menaruh artikel saat terbit. Penelitian sebelumnya memakai kategori situs penerbit sebagai label topik terutama untuk satu penerbit atau satu wilayah [3]. Banyak situs berita juga mencatat rubrik setiap artikel dalam kolom `articleSection` pada metadata halaman schema.org [19]. Kolom ini menyediakan label editorial lintas penerbit tetapi belum dipetakan ke taksonomi standar lintas puluhan bahasa.

Test set semacam itu juga harus bebas dari kebocoran data pelatihan dan diuji dengan memperhitungkan ketergantungan antarartikel. Penghapusan dokumen hampir duplikat dengan MinHash [39] telah menjadi praktik standar untuk mengendalikan kebocoran [40]. Uji signifikansi dalam pemrosesan bahasa alami seperti *bootstrap* berpasangan [41] biasanya mengasumsikan sampel yang independen [42] padahal artikel dari situs yang sama saling bergantung. *Cluster bootstrap* [43] menangani ketergantungan ini melalui *resample* pada tingkat klaster alih-alih dokumen.

F. SINTESIS ARSITEKTUR STATICKD

StaticKD menggabungkan unsur dari empat alur penelitian.

- *Teacher* beserta distribusinya atas 17 topik IPTC berasal dari Kuzman dan Ljubešić (Bagian II-A).
- Distilasi KL ke *student bag-of-embeddings* mengikuti Sparse Distillation (Bagian II-B) tanpa tabel n-gram berisi satu miliar parameter dan *head* nonlinear dari metode tersebut.
- Ruang *embedding* potion-multilingual yang selaras ($d_e = 256$) berasal dari Model2Vec (Bagian II-C) tanpa pengklasifikasi nonlinearnya.
- Identitas *folding* berasal dari Singh dkk. (Bagian II-D) dan diterapkan pada kosakata *subword* multibahasa yang tertutup ($|V| = 500{,}353$).

Head yang sepenuhnya linear memungkinkan bobot hasil pelatihan dilipat secara eksak ke dalam satu tabel *half-precision*. Inferensi atas tabel ini berjalan di NumPy dan tidak memerlukan perkalian matriks padat, GPU, maupun pustaka *deep learning*. Tabel 1 membandingkan StaticKD dengan pendekatan terkait pada lima sifat yang dibahas dalam bagian ini. Hanya StaticKD yang memenuhi kelima sifat tersebut sedangkan nilai ‘‘sebagian’’ menandai sifat yang hanya berlaku pada sebagian varian atau sebagian laporan suatu pendekatan.

III. METODE STATICKD

A. GAMBARAN UMUM STUDI

Studi ini terdiri atas tiga tahap: membangun *student* StaticKD melalui distilasi, mengukur dan membandingkan akurasi pada artikel berlabel yang belum pernah dilihat oleh *teacher* maupun *student*, dan mengukur biaya inferensi pada CPU. Gambar 1 menunjukkan bahwa *teacher* hanya dipakai satu kali sebelum pelatihan sehingga biaya inferensinya tidak terbawa ke model hasil *folding*. *Pipeline* ini dimulai ketika *teacher* mengklasifikasikan 285,999 artikel tak berlabel dalam 69 bahasa dan menghasilkan logit untuk 17 topik IPTC tingkat atas (Bagian IV-B dan III-C). Model StaticKD kemudian dilatih untuk meniru distribusi *teacher* tersebut (Bagian III-D). Akurasi prediksi dievaluasi pada *test set* terpadu yang labelnya tidak berasal dari *teacher* (Bagian IV-C) karena label *teacher* bukan *ground truth* dalam studi ini. *Benchmark* CPU pada tahap ketiga menjalankan setiap model pada sampel artikel *test set* yang sama (Bagian V-C).

B. FORMULASI MASALAH

Model memprediksi satu label $y \in \mathcal{Y}$ dari 17 topik IPTC tingkat atas untuk artikel berita d dalam bahasa apa pun. Input berupa judul dan isi artikel yang dipotong hingga 512 kata pertama seperti pada [6]. Setiap model kemudian menerapkan batas tokennya sendiri pada input ini (Bagian III-C dan III-D). *Teacher* f_T mengeluarkan logit $\mathbf{z}^T(d) \in \mathbb{R}^{17}$ untuk input tersebut. Studi ini mencari *student* f_S yang akurasinya terhadap label independen sedekat mungkin dengan akurasi f_T. Inferensi f_S dibatasi pada $O(n)$ penjumlahan untuk n token tanpa perkalian matriks maupun pustaka *deep learning*.

C. *TEACHER* DAN LABEL DISTILASI

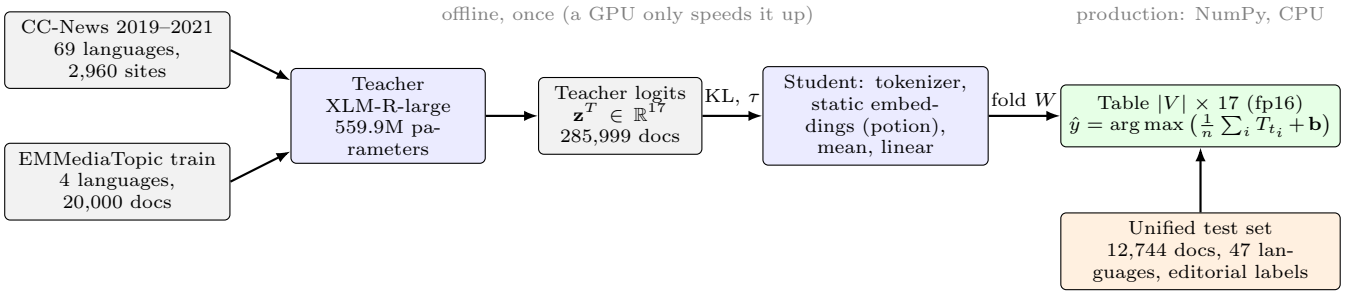
Teacher adalah pengklasifikasi IPTC dari [6] yang dipublikasikan sebagai classla/multilingual-IPTC-news-topic-classifier. Pengklasifikasi ini adalah model XLM-RoBERTa-large dengan 24 lapisan, 559.9 juta parameter, dan batas input 512 token XLM-R. *Teacher* melabeli seluruh data distilasi dengan biaya satu kali sekitar 1.6 jam GPU dan menghasilkan vektor logit lengkap $\mathbf{z}^T(d) \in \mathbb{R}^{17}$ yang disimpan untuk setiap dokumen distilasi.

D. *STUDENT* STATICKD

Student dibangun di atas model *embedding* statis multibahasa potion-multilingual-128M (potion) dari Model2Vec [16]. Matriks *embedding* E *student* diinisialisasi dari potion sehingga token dari 101 bahasa berada dalam satu ruang bersama sebelum pelatihan dimulai. Dokumen d ditokenisasi

TABEL 1. Posisi StaticKD terhadap Pendekatan Terkait

Pendekatan	Model saat inferensi	Tanpa transformer saat inferensi	Multibahasa dengan embedding selaras	Student belajar dari prediksi teacher pada tugas yang sama	Head dilipat ke tabel token	Label IPTC
Kuzman & Ljubešić [6]	XLM-R-large (559.9M parameter)	tidak	ya	ya (label keras GPT-4o)	tidak	ya
DistilBERT [11]	transformer 6 lapisan	tidak	tidak (en)	sebagian (hanya SQuAD)	tidak	tidak
MiniLMv2 [10]	transformer 6 atau 12 lapisan	tidak	sebagian (varian dari XLM-R)	tidak	tidak	tidak
Sparse Distillation [14]	deep averaging network + tabel n-gram	ya	tidak (en)	ya (distribusi, KL)	tidak (MLP)	tidak
Model2Vec [16]	embedding statis + head MLP	ya	ya	tidak	tidak (MLP bawaan)	tidak
Wada dkk. [15]	embedding kata statis	ya	sebagian (en–de/zh/ja)	tidak	–	tidak
Aug-Linear [17]	kamus koefisien n-gram	ya	tidak (en)	tidak	ya	tidak
fastText [12]	bag of n-grams, head linear	ya	tidak	tidak	tidak	tidak
StaticKD (usulan)	tabel 17 logit per token	ya	ya	ya (distribusi, KL)	ya	ya



GAMBAR 1. ***Pipeline* StaticKD.** ***Teacher* melabeli korpus berita tak berlabel satu kali dalam langkah *offline*. *Student* belajar meniru distribusi *teacher*. *Head* linear *student* kemudian dilipat ke dalam tabel token. Inferensi tereduksi menjadi *lookup* dan rata-rata baris tabel. Evaluasi akhir memakai *test set* yang labelnya tidak berasal dari *teacher*.**

menjadi $t_1, \ldots, t_n$ dengan Unigram *tokenizer* milik potion yang berisi 500,353 token sehingga setiap token memiliki *embedding* hasil prapelatihan. Token khusus tidak dipakai dan token yang tidak dikenal dibuang. Perataan tidak bergantung pada posisi sehingga model tidak memiliki batas panjang bawaan dan panjang dokumen dipotong pada 1,024 token hanya untuk membatasi biaya. Hanya 5.4% artikel *test set* yang melampaui batas ini. *Student* menghitung logit dokumen dari rata-rata *embedding* token $\mathbf{e}_t \in \mathbb{R}^{256}$:

$$\mathbf{h}(d) = \frac{1}{n}\sum_{i=1}^{n} \mathbf{e}_{t_i}, \qquad \mathbf{z}^S(d) = W\,\mathrm{drop}(\mathbf{h}(d)) + \mathbf{b}, \quad (2)$$

dengan $W \in \mathbb{R}^{17\times 256}$ dan *dropout* 0.1 pada $\mathbf{h}(d)$ selama pelatihan.

Student belajar dari logit *teacher* yang tersimpan dengan *loss*

$$\mathcal{L}_{\mathrm{KD}} = \tau^2\,\mathrm{KL}\big(p^T \,\|\, p^S\big), \qquad \tau = 1, \quad (3)$$

dengan $p^T = \mathrm{softmax}(\mathbf{z}^T/\tau)$ dan $p^S = \mathrm{softmax}(\mathbf{z}^S/\tau)$ sebagai distribusi *teacher* dan *student*. Nilai $\tau = 1$ ditetapkan bersama pilihan resep lainnya (Bagian IV-A) dan hasil untuk nilai lain $\tau \in \{0.5, 2, 4\}$ dilaporkan pada Bagian VI-D. Parameter E, W, dan $\mathbf{b}$ dilatih bersama. AdamW ($\eta = 3 \cdot 10^{-3}$, *weight decay* 10^{-4}) memperbarui W dan $\mathbf{b}$ sedangkan SparseAdam ($\eta = 10^{-3}$) memperbarui matriks *embedding* E hanya pada baris token yang muncul dalam *batch* saat ini. Token yang tidak pernah muncul dalam dokumen pelatihan karena itu tetap memakai *embedding* potion. Pelatihan berjalan selama 6 *epoch* dengan ukuran *batch* 64. *Token dropout* menjadi augmentasi yang murah dengan membuang setiap token dalam dokumen pelatihan dengan probabilitas 0.2 pada setiap langkah agar model tidak bergantung pada segelintir kata kunci. Augmentasi ini berbeda dari *dropout* 0.1 pada $\mathbf{h}(d)$ dalam Persamaan (2). Validasi internal memakai 3% data distilasi (8,579 dokumen) untuk menyimpan *epoch* dengan *agreement* tertinggi terhadap *teacher*.

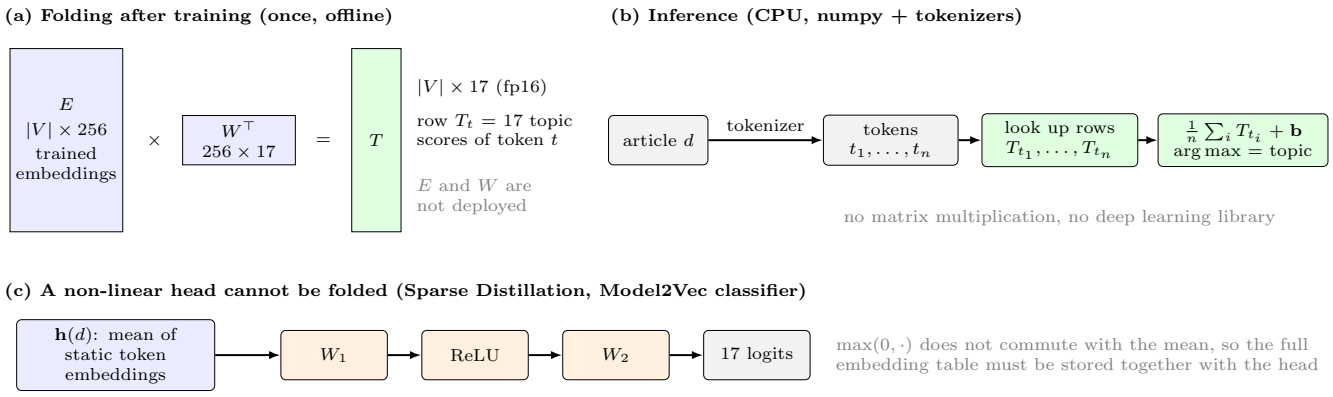
E. FOLDING, ENSEMBLE TABEL, DAN VARIAN RINGKAS

Head klasifikasi yang linear memungkinkan (2) ditulis ulang sebagai

$$W\Big(\frac{1}{n}\sum_i \mathbf{e}_{t_i}\Big) + \mathbf{b} = \frac{1}{n}\sum_i T_{t_i} + \mathbf{b}, \quad (4)$$

dengan tabel $T = EW^\top \in \mathbb{R}^{|V|\times 17}$ yang dihitung satu kali setelah pelatihan dalam langkah *folding*. Baris T_t pada tabel T memuat 17 skor topik yang disumbangkan token t ke setiap artikel yang mengandungnya. Gambar 2 memperlihatkan bahwa matriks E berdimensi 256 hanya diperlukan selama pelatihan sehingga model hasil *folding* untuk penerapan hanya terdiri atas T dalam *half-precision* (fp16), $\mathbf{b}$, dan *tokenizer*. Argumen *folding* yang sama berlaku untuk *ensemble* karena Persamaan (4) linear terhadap T. Perataan logit dari K *student* yang dilatih dengan *seed* berbeda memberikan hasil yang sama dengan satu *student* bertabel $\bar{T} = \frac{1}{K}\sum_k T^{(k)}$ dan berbias $\bar{\mathbf{b}}$.

Model StaticKD akhir merata-ratakan tabel dari tiga *student* ($K = 3$) dan memiliki 8.5 juta parameter. Berkas model ini berukuran 34 MB dan tabel hasil perataan menyumbang 16 MB dari ukuran tersebut. Sebagian besar *random-access memory* (RAM) yang dipakai model ini saat inferensi diisi struktur internal Unigram *tokenizer*. Varian ringkas memperkecil struktur tersebut dengan menghapus potongan token



GAMBAR 2. **Mekanisme *folding*. (a) *Embedding E* dan *head* linear *W* dilipat satu kali setelah pelatihan menjadi tabel *T*. (b) Inferensi hanya memerlukan tokenisasi, *lookup* baris *T*, dan perataan. (c) *Head* nonlinear mencegah *folding* sehingga *E* harus tetap disimpan.**

TABEL 2. **Set Data Studi dan Perannya**

Set	Dok.	Bahasa	Label	Dipakai untuk
Data distilasi	285,999	69	teacher	melatih student
validasi internal	8,579	–	teacher	memilih epoch
Development (EMMediaTopic)	1,000	4	GPT-4o	memilih resep
CC-News held-out	12,554	63	teacher	agreement, situs di luar distilasi
Test set terpadu	12,744	47	manusia, editorial	semua hasil akurasi
Sampel rubrik bahasa Inggris	754	1	JSON-LD	hanya validitas label

yang muncul kurang dari 10 kali dalam data distilasi tetapi tetap menyimpan karakter tunggal. Kosakata varian ini berisi 335,441 token dan berkasnya berukuran 23 MB.

IV. DATA DAN *TEST SET*

A. SET DATA DAN PERANNYA

Tabel 2 menunjukkan bahwa *development set* dan validasi internal yang dipakai untuk memilih pengaturan model terpisah dari *test set* terpadu. *Development set* adalah set data berlabel yang dipakai untuk memilih pengaturan model sebelum pengukuran akhir sehingga *test set* tidak ikut memengaruhi pilihan tersebut. *Development set* studi ini adalah *split* pengembangan EMMediaTopic (Bagian IV-B). Pengaturan parameter dan pilihan resep StaticKD ditentukan sebelum *test set* dibangun. *Development set* juga dipakai untuk menguji empat komponen tambahan: fitur bigram, *pooling* berbobot idf, pembobotan dokumen menurut keyakinan *teacher*, dan *loss* tambahan pada label GPT-4o. Keempatnya tidak dimasukkan ke resep karena tidak mengubah skor *development set* secara signifikan.

B. DATA DISTILASI DAN *DEVELOPMENT SET*

Development set dan sebagian data distilasi bersumber dari EMMediaTopic 1.0 [6], [26]. EMMediaTopic berisi artikel berlabel GPT-4o dalam empat bahasa (Katalan, Yunani, Kroasia, dan Slovenia). Sebanyak 21,000 artikel beranotasi diambil dan dibagi menjadi *split* pelatihan berisi 20,000 artikel dan *split* pengembangan berisi 1,000 artikel. Kuzman dan Ljubešić melatih *teacher* pada *split* pelatihan dan menyetel *hyperparameter teacher* pada *split* pengembangan [6]. *Split* pelatihan juga menjadi bagian dari data distilasi untuk *student*. Baik *teacher* maupun *student* tidak pernah dilatih pada *split* pengembangan.

Sebagian besar data distilasi berasal dari *dataset* multibahasa CC-News 2019–2021 [44] yang dibangun dari arsip berita Common Crawl. CC-News 2019–2021 diolah dengan langkah-langkah berikut.

1) Periksa bahasa dengan model identifikasi bahasa fastText [12] dan pertahankan hanya dokumen yang bahasa metadatanya sesuai dengan bahasa hasil identifikasi.
2) Pertahankan dokumen yang judul dan isinya mencapai total 75 kata dan potong teks menjadi 512 kata. Dokumen dalam bahasa Jepang, Mandarin, Thai, dan Burma memakai batas 200 dan 2,000 karakter sebagai gantinya.
3) Sisihkan semua dokumen dari sebagian situs ke dalam *held-out set* yang tidak dipakai untuk pelatihan dan memuat paling banyak 20% dari tiap bahasa.
4) Batasi jumlah dokumen pelatihan per situs untuk menghindari bias dari konten serupa dalam satu situs.

Data distilasi akhir berisi 285,999 dokumen dalam 69 bahasa dari 2,960 situs dengan median panjang dokumen 269 kata dan paling banyak 400 dokumen per situs. Data ini terdiri atas versi dasar berisi sekitar 130 ribu dokumen dengan paling banyak 150 dokumen per situs dan 156,157 dokumen tambahan dari situs pelatihan saja (paling banyak 5,000 per bahasa). Versi dasar juga dipakai sebagai varian ablasi (Bagian V-D).

Held-out set berisi 12,554 dokumen dalam 63 bahasa dari 217 situs yang tidak pernah muncul dalam data distilasi. Set ini hanya dapat mengukur *agreement* dengan *teacher* karena tidak memiliki label kategori independen.

C. PEMBENTUKAN *TEST SET* TERPADU

Sumber terbesar *test set* terpadu adalah *dataset* CC-NEWS 2024–2026 [45] yang disampel sebagai satu berkas arsip (WARC) per bulan dari Januari 2024 hingga Agustus 2026 (32 berkas). Setiap halaman artikel memuat metadata terstruktur schema.org [19] dalam format JSON-LD yang menyediakan rubrik artikel dan metadata lain dalam kolom seperti `articleSection`,

`BreadcrumbList`, `inLanguage`, `datePublished`, `isAccessibleForFree`, dan `articleBody`. Teks diambil dari `articleBody` hanya bila kolom itu berisi paling sedikit 30 kata. Teks artikel lain diekstrak dari konten HTML dengan pustaka Trafilatura [46].

Artikel *test set* lainnya berasal dari kelima *dataset* publik pada Bagian II-A. Artikel L3Cube-IndicNews diambil dari *split* LDC yang berisi dokumen panjang. Kategori penerbit pada *dataset* ini dan rubrik JSON-LD sama-sama termasuk label editorial.

Label editorial tidak mengikuti standar IPTC sehingga nama rubrik harus diterjemahkan ke pohon IPTC Media Topic resmi (1,085 *node* aktif). Nama rubrik dinormalisasi untuk huruf besar-kecil dan diakritik lalu dipetakan secara konservatif oleh LLM (Claude Opus 5.5). LLM hanya membaca nama rubrik tanpa teks artikel dan memetakan sebuah nama hanya jika pokok bahasan yang dinyatakan nama itu berada di bawah satu topik tingkat atas dalam pohon IPTC. Pemeriksaan otomatis memastikan bahwa setiap *node* tujuan ada dalam pohon IPTC, masih aktif, dan berada di bawah topik tingkat atas yang dimaksud. Tabel pemetaan yang disusun LLM kemudian dievaluasi dan dikoreksi secara manual oleh peninjau manusia. Tabel akhir menghubungkan 814 nama rubrik ke 79 *node* IPTC. Artikel yang rubrik-rubriknya dalam kolom `articleSection` dan `BreadcrumbList` terpetakan ke label berbeda ditolak agar setiap artikel memiliki satu label.

Filter kualitas dan kebocoran diterapkan secara berurutan.

1) Situs belum muncul dalam data distilasi maupun dalam *held-out set* (hanya CC-NEWS).
2) Tanggal terbit pada atau setelah 1 Januari 2024 (hanya CC-NEWS).
3) Teks artikel lengkap dan tidak berupa cuplikan (*teaser*).
4) Bahasa yang dinyatakan sesuai dengan identifikasi bahasa fastText bila fastText mendukung bahasa tersebut.
5) Paling sedikit 75 kata.
6) Deduplikasi *uniform resource locator* (URL), teks identik, dan teks hampir duplikat (MinHash [39], Jaccard ≥ 0.7 [40]) di seluruh sumber.
7) Kontaminasi: artikel dibuang bila $\geq 30\%$ dari 8-gram katanya muncul dalam salah satu dari sekitar 300 ribu dokumen pelatihan atau evaluasi.

Artikel yang lolos semua filter disampel dengan paling banyak 50 artikel untuk setiap pasangan bahasa dan label dengan mendahulukan sumber berlabel manusia. *Test set* akhir berisi 12,744 artikel dalam 47 bahasa dari 1,227 situs atau sumber dengan median panjang artikel 313 kata. Seluruh 17 label muncul dalam *test set* ini meskipun artikel suatu bahasa mencakup median 7 dari 17 label. *Asal label* artikel adalah anotasi manusia untuk 4,094 artikel (32.1%), kategori penerbit untuk 2,600 artikel (20.4%), dan rubrik JSON-LD untuk 6,050 artikel (47.5%). Tabel 3 menunjukkan bahwa keragaman penerbit terutama berasal dari CC-NEWS yang mencakup 1,092 situs dalam 29 bahasa.

Jumlah data distilasi berbeda antarbahasa *test set* dan dipakai untuk analisis subkelompok (Bagian V-B). Data distilasi tidak tersedia untuk 13 bahasa sedangkan 9 bahasa lain memiliki kurang dari 500 dokumen distilasi dan 25 bahasa sisanya memiliki paling sedikit 500. Gambar 3 memperlihatkan bahwa label bahasa tanpa data distilasi atau dengan sedikit data distilasi hampir seluruhnya berasal dari anotasi manusia atau kategori penerbit sedangkan rubrik JSON-LD terutama mencakup bahasa dengan paling sedikit 500 dokumen distilasi.

TABEL 3. Komposisi *Test Set* Terpadu menurut Sumber

Sumber	Asal label	Artikel	Bahasa	Situs/sumber
CC-NEWS 2024–2026	rubrik JSON-LD	6,050	29	1,092
MasakhaNEWS [2]	anotasi manusia	3,339	16	6
L3Cube-IndicNews [3]	kategori penerbit	2,361	10	1
MN-DS [20]	anotasi manusia	755	1	127
Bangla news [21]	kategori penerbit	139	1	1
IndoNews	kategori penerbit	100	1	1
Total		12,744	47	1,227

Satu situs (jpost.com) muncul di CC-NEWS dan di MN-DS sehingga total situs satu lebih kecil daripada jumlah kolom.

D. PEMERIKSAAN VALIDITAS LABEL

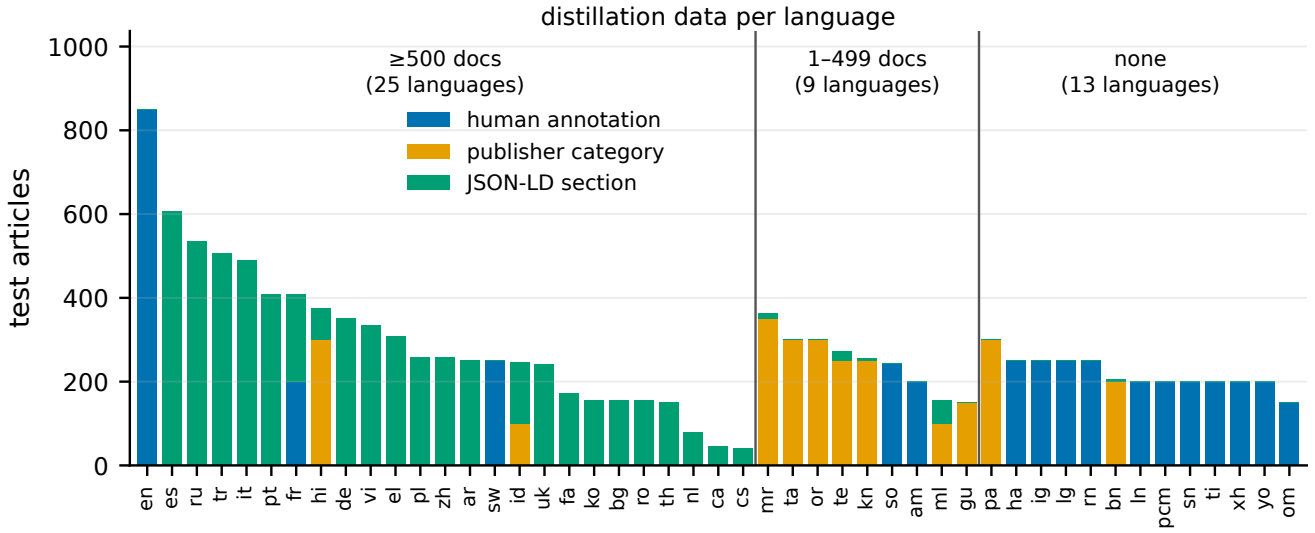
Dua pertiga label pada *test set* adalah label rubrik dan kategori yang mencatat keputusan redaksi dan bukan anotasi yang mengikuti pedoman pelabelan. Pemeriksaan validitas label menguji apakah label semacam itu berperilaku seperti label manusia dalam bahasa yang sama (Bagian VI-A). *Teacher* yang sama hanya menjadi acuan tetap bagi kedua jenis label sehingga label rubrik dengan *noise* yang jauh lebih banyak akan membuat *teacher* lebih jarang cocok dengan label rubrik daripada dengan label manusia. Kecocokan ini diukur dengan akurasi dan macro-F1 *teacher* pada tiap jenis label, uji Wilcoxon *signed-rank* atas akurasi per label, dan korelasi Spearman antara peringkat kesulitan label pada kedua jenis label. Analisis per kategori sumber juga memeriksa pemetaan dengan membandingkan prediksi *teacher* dan label hasil pemetaan pada tiap kategori sumber dalam bahasa yang tercakup dalam prapelatihan XLM-R.

Perbandingan antarjenis label memerlukan label rubrik dan label manusia dalam bahasa yang sama. *Test set* sendiri menyediakan label rubrik dan label manusia MasakhaNEWS dalam bahasa Prancis. Bagian bahasa Inggris dari *test set* hanya berisi label manusia karena penyampelan mendahulukan sumber berlabel manusia (Bagian IV-C). Perbandingan di dalam bahasa Inggris harus memakai sampel artikel yang tidak termasuk dalam *test set*. Sampel ini berisi 754 artikel CC-NEWS berbahasa Inggris dari 306 situs dengan label rubrik JSON-LD dan paling banyak 50 artikel per label.

V. PENGATURAN EKSPERIMEN

A. BASELINE

Semua *baseline* bertanda + KD belajar dari data distilasi yang sama (285,999 dokumen) dan dari *teacher* yang sama. Tabel 4 menunjukkan bahwa hanya kedua *baseline transformer* yang belajar dari distribusi penuh *teacher*. Tiga *baseline* ringan



GAMBAR 3. **Jumlah artikel *test set* terpadu per bahasa menurut asal label. Bahasa dikelompokkan menurut jumlah dokumen distilasinya.**

dilatih pada label teratas *teacher* karena prosedur pelatihan standarnya menerima label kelas tetapi tidak menerima distribusi probabilitas. Ketiga *baseline* ringan itu adalah fastText + KD [12], *term frequency–inverse document frequency* (TF-IDF) + *support vector machine* (SVM) + KD, dan pengklasifikasi Model2Vec + KD [16]. TF-IDF + SVM + KD mengadaptasi *baseline* nonneural dari Kuzman dan Ljubešić ke label *teacher*. Pengklasifikasi Model2Vec + KD menerapkan *fine-tuning* pada *embedding* potion yang juga menjadi titik awal StaticKD serta mempelajari bobot untuk tiap token. Dua model fastText lain dilatih hanya pada label GPT-4o dari *split* pelatihan EMMediaTopic sebagai acuan tanpa KD yang memakai data berlabel yang sama dengan *teacher* [6].

MiniLM-L6 + KD dan DistilmBERT + KD adalah *baseline transformer* yang dilatih dengan *loss* (3) pada distribusi penuh *teacher*. MiniLM-L6 + KD memakai mMiniLMv2-L6-H384 yang didistilasi dari XLM-R-large [10] sedangkan DistilmBERT + KD memakai `distilbert-base-multilingual-cased` [11]. Batas 256 token memotong 91.1% artikel *test* menjadi sekitar 142 kata untuk MiniLM-L6 dan 93.2% menjadi sekitar 116 kata untuk DistilmBERT. Pemeriksaan sensitivitas terhadap batas ini melatih ulang kedua model dengan 512 token (Bagian VI-B).

Sparse Distillation [14] adalah metode terdahulu yang paling dekat dengan StaticKD tetapi tidak dijalankan sebagai *baseline* tersendiri (Bagian VII-E). Sebagian dari metode tersebut tetap tercakup dalam dua eksperimen lain. *Baseline* fastText + KD melatih model *bag-of-n-grams* dengan perataan dan *head* linear pada label *teacher* yang sama. Ablasi inisialisasi acak (Bagian V-D) melatih tabel *embedding* dari awal seperti Sparse Distillation.

B. PROTOKOL EVALUASI DAN UJI STATISTIK

Tabel 5 menempatkan macro-F1 sebagai metrik utama karena distribusi label tidak seimbang. Metrik ini adalah rata-rata F1 tak tertimbang atas label yang ada dalam referensi sesuai protokol evaluasi [6]. Macro-F1 per bahasa dirata-ratakan atas bahasa agar bahasa besar tidak mendominasi. Kalibrasi diukur dengan *expected calibration error* (ECE) [47] karena mode *cascade* pada Bagian V-C mengarahkan artikel menurut tingkat keyakinan StaticKD.

Interval kepercayaan dan uji berpasangan memakai *bootstrap* dengan unit *resampling* yang berbeda pada kedua set evaluasi. *Development set* di-*resample* per dokumen sedangkan *test set* memakai *site-cluster bootstrap* [43] yang menarik situs secara utuh sebagai unit *resampling* agar artikel yang berkaitan dari satu situs tidak membuat interval kepercayaan terlalu sempit. Artikel tanpa URL dikelompokkan menurut *dataset* sumber.

Klaster pada *test set* tidak seimbang sehingga dua pemeriksaan tambahan menguji ketahanan perbandingan model. Dua klaster terbesar dari 1,227 klaster (bbc.com dan L3Cube-IndicNews) memuat 37.3% artikel dan jumlah efektif klaster $1/\sum_c q_c^2$ dengan q_c sebagai proporsi klaster c hanya 13.8. Pemeriksaan *leave-one-source-out* menghitung ulang macro-F1 *teacher* dan StaticKD beserta ketujuh *baseline* + KD dengan membuang tiap sumber dari enam sumber *test set* satu per satu. Pemeriksaan lain mengulang perbandingan model pada *subset* dengan paling banyak lima artikel per situs dan pasangan bahasa–label.

Perbedaan yang tidak signifikan pada uji berpasangan tidak menunjukkan bahwa dua model setara sehingga klaim kesetaraan bertumpu pada *two one-sided tests* (TOST) atas distribusi *bootstrap* yang sama. Margin 0.01 macro-F1 diperlakukan sebagai perbedaan yang dapat diabaikan untuk penyaringan topik. Koreksi Holm diterapkan terpisah pada *development set* dan *test set* atas semua perbandingan StaticKD

TABEL 4. ***Baseline*** **dan Cara Pelatihannya**

Model	Representasi saat inferensi	Target pelatihan	Penyetelan
fastText + KD, kata	rata-rata vektor kata dan n-gram karakter, head linear	label teratas teacher	grid search pada development set
fastText + KD, subword	rata-rata vektor subword XLM-R, head linear	label teratas teacher	grid search pada development set
fastText + KD, subword, terkuantisasi	varian subword dalam format `.ftz`	label teratas teacher	dari varian subword
TF-IDF + SVM + KD	TF-IDF atas subword XLM-R, SVM linear	label teratas teacher	grid search pada development set
Pengklasifikasi Model2Vec + KD	embedding potion hasil fine-tuning dengan bobot per token, lapisan tersembunyi 512 unit	label teratas teacher	pengaturan bawaan pustaka
MiniLM-L6 + KD	transformer 6 lapisan, input 256 token	distribusi penuh teacher	$\tau \in \{1, 2\}$ pada development set
DistilmBERT + KD	transformer 6 lapisan, input 256 token	distribusi penuh teacher	$\tau = 1$
fastText, label GPT-4o (kata, subword)	seperti fastText + KD	label GPT-4o EMMediaTopic	pengaturan tetap

dengan model lain pada Tabel 8.

Perbandingan tiap varian ablasi dengan resep akhir memakai *bootstrap* berpasangan yang sama. Setiap *resample* menilai semua *seed* varian dan resep akhir pada artikel yang sama dan menghasilkan selisih antara kedua rata-rata *seed* sebagai besaran yang diuji. Skor *ensemble* berisi K *student* adalah rata-rata skor atas semua kombinasi K dari sepuluh *seed* resep akhir. Koreksi Holm untuk perbandingan ini mencakup 10 varian pada Bagian V-D dan keempat komponen tambahan dari Bagian IV-A yang masing-masing dijalankan dengan tiga *seed*.

Analisis per bahasa memakai dua besaran. *Selisih akurasi* adalah akurasi StaticKD dikurangi akurasi *teacher*. *Cakupan token* suatu bahasa adalah proporsi dari semua kemunculan token dalam artikel *test* bahasa tersebut yang tokennya muncul paling sedikit 10 kali dalam data distilasi. Ambang ini dipakai karena pelatihan jarang memperbarui *embedding* token yang lebih jarang muncul (Bagian III-D).

Analisis subkelompok membagi hasil menurut bahasa, aksara, wilayah, label, asal label, keragaman situs, jumlah data distilasi per bahasa, dan cakupan prapelatihan *teacher*. Keragaman situs suatu bahasa diukur dengan jumlah efektif situs $1/\sum_s q_s^2$ dengan q_s sebagai proporsi artikel bahasa itu yang berasal dari situs s. Cakupan prapelatihan menyatakan apakah suatu bahasa termasuk dalam 100 bahasa yang dipakai untuk prapelatihan XLM-R [18].

Tujuh uji memeriksa apakah sifat suatu bahasa menjelaskan kinerja StaticKD pada bahasa itu dengan nilai p yang dikoreksi Holm bersama-sama. Empat uji memeriksa kemiripan StaticKD dengan *teacher* pada 53 bahasa dengan paling sedikit 20 dokumen *held-out*. Tiga korelasi Spearman di antaranya mengaitkan *agreement held-out* dengan log jumlah data distilasi, jumlah situs pelatihan, dan tingkat keyakinan *teacher* sedangkan uji Kruskal–Wallis membandingkan *agreement* antaraksara. Tiga uji lain memeriksa ketertinggalan StaticKD dari *teacher* pada *test set* melalui korelasi Spearman antara selisih akurasi dan log jumlah data distilasi, antara akurasi StaticKD dan cakupan token, serta antara selisih akurasi dan cakupan token.

Analisis tabel token mengukur *spesifisitas* sebuah token sebagai selisih terbesar antara satu entri pada baris tabelnya dan rata-rata 16 entri lainnya. Uji pemangkasan hanya mempertahankan 10% token paling spesifik dari tiap artikel dan membandingkan hasilnya dengan hasil dari 10% token acak untuk mengukur seberapa banyak sinyal topik dibawa token yang paling spesifik.

TABEL 5. **Ringkasan Protokol Evaluasi dan Uji Statistik**

Pertanyaan	Metrik atau uji
Akurasi terhadap label independen	macro-F1 (utama), akurasi, dan macro-F1 per bahasa
Kemiripan dengan teacher	agreement pada held-out set
Kalibrasi	ECE dengan 15 bin
Ketidakpastian skor	interval kepercayaan 95% dari bootstrap persentil dengan 1,000 resample
Beda dua model	bootstrap berpasangan dengan 2,000 resample untuk Δmacro-F1 [41], McNemar eksak untuk akurasi [48], dan koreksi Holm [49]
Kesetaraan dua model	TOST [50] dengan interval 90% dalam ± 0.01
Konsistensi antarbahasa	Wilcoxon signed-rank pada macro-F1 dan akurasi per bahasa [42]
Efek komponen resep	ablasi dengan lima seed per varian dan sepuluh seed untuk resep akhir
Sifat bahasa	enam korelasi Spearman dan satu uji Kruskal–Wallis dengan koreksi Holm bersama
Ketahanan terhadap klaster	leave-one-source-out dan subset dengan paling banyak lima artikel per situs dan pasangan bahasa–label

C. PROTOKOL EFISIENSI

Tabel 6 menunjukkan bahwa semua model diukur dengan pengaturan yang sama sehingga rasio kecepatan antarmodel dapat dibandingkan. CPU laptop tersebut bersifat hibrida dan memiliki 6 *performance core* (P-core), 8 *efficiency core* (E-core) yang lebih lambat, dan 2 E-core berdaya rendah. Sistem operasi memindahkan *thread* yang tidak dipatok ke *core* yang lambat sehingga setiap proses dipatok ke P-core fisik dan pengaturannya menyerupai server kecil dengan *core* yang seragam. *Throughput* satu *core* setiap model menyimpang paling banyak 7% dari median tiga sesi pengukuran. Profil satu *thread* terpisah memecah waktu prediksi StaticKD menjadi waktu tokenisasi dan waktu perataan tabel pada 1,280 artikel untuk mengetahui langkah yang membatasi kecepatannya.

Kedua *baseline transformer* diekspor ke format Open Neural Network Exchange (ONNX) dalam fp32 untuk *benchmark* CPU. *Teacher* juga diekspor ke ONNX dengan kuantisasi dinamis ke bilangan bulat 8-bit (int8). Versi ONNX int8 ini adalah konfigurasi *teacher* tercepat pada CPU.

Perbandingan kecepatan tidak menguntungkan StaticKD karena StaticKD membaca input yang lebih panjang. StaticKD membaca hingga 1,024 token per artikel sedangkan *teacher* berhenti pada 512 token XLM-R. Batas *teacher* ini terlampaui pada 60.7% artikel *test set* dan pada artikel tersebut *teacher* membaca sekitar 287 dari 438 kata (median).

TABEL 6. Pengaturan *Benchmark* CPU

Aspek	Pengaturan
Mesin	laptop Intel Core Ultra 7 155H, RAM 32 GB, Windows 11, GPU dinonaktifkan
Proses	proses baru per model, jumlah thread dipatok di setiap pustaka, satu atau empat P-core fisik
Sampel	sampel teks acak yang sama dari test set terpadu
Latensi	median (p50) dan persentil ke-95 (p95) dengan satu artikel per panggilan (skenario streaming); 100 dokumen untuk teacher dan transformer, 500 dokumen untuk model ringan
Throughput	batch 64 (8 untuk transformer); 96 dokumen untuk teacher dan transformer, 3,000 dokumen untuk model ringan
RAM model	kenaikan resident set size setelah model dimuat
Pengulangan	tiga sesi pada mesin yang menganggur, median dilaporkan

Mode *cascade* menggabungkan StaticKD dan *teacher* untuk pekerjaan yang memerlukan akurasi setingkat *teacher*. Mode ini membiarkan StaticKD memutuskan artikel yang probabilitas teratasnya paling sedikit sebesar ambang θ. Artikel sisanya diteruskan ke *teacher* ONNX int8. Misalkan s adalah proporsi artikel yang diputuskan oleh StaticKD serta r_S dan r_T adalah *throughput* satu *core* StaticKD dan *teacher*. *Throughput* efektif *cascade* adalah $1/(1/r_S + (1-s)/r_T)$.

D. RANCANGAN ABLASI

Tiap varian ablasi mengubah satu faktor dari resep akhir. Satu varian mengganti *soft label* dengan *hard label* dan dua varian mengurangi data pelatihan menjadi EMMediaTopic saja (4 bahasa, 10 *epoch*) atau menjadi 130 ribu dokumen tanpa data tambahan CC-News 2019–2021. Varian lain membekukan *embedding* atau mengambil *embedding* acak dengan simpangan baku yang sama dengan potion. Varian sisanya dilatih tanpa *token dropout*, memakai *head* MLP 512 unit, atau menetapkan $\tau \in \{0.5, 2, 4\}$. Tabel 10 memuat resep akhir dan seluruh varian ini.

E. DETAIL IMPLEMENTASI

Satu *run* StaticKD rata-rata memakan waktu 5.2 menit pada NVIDIA RTX 4050 Laptop GPU. Implementasi memakai Python 3.12, NumPy 2.5, PyTorch 2.6, transformers 5.17, `tokenizers` 0.23, ONNX Runtime 1.30, scikit-learn 1.9, dan fastText 0.9.2.

VI. HASIL

A. VALIDITAS LABEL EDITORIAL

Kecocokan *teacher* dengan kedua jenis label menunjukkan bahwa label rubrik bahasa Inggris tidak mengandung *noise* lebih banyak daripada label manusia. *Teacher* mencapai akurasi 0.646 pada 754 artikel bahasa Inggris berlabel rubrik (macro-F1 0.617) dan 0.559 pada label manusia bahasa Inggris dari MN-DS dan MasakhaNEWS (macro-F1 0.565). *Teacher* lebih akurat pada label rubrik untuk 12 dari 17 label (Wilcoxon $p = 0.033$). Peringkat kesulitan label juga berkorelasi antara kedua jenis label ($\rho = 0.63$, $p = 0.007$) dan label sulit yang sama pada keduanya adalah *society*, *human interest*, dan *religion*. Data bahasa Prancis dalam *test set* juga memuat kedua jenis label dan menunjukkan arah yang sama dengan akurasi *teacher* 0.716 pada 208 artikel berlabel rubrik dibandingkan 0.500 pada 200 artikel MasakhaNEWS berlabel manusia.

Kecocokan per kategori antara *teacher* dan label hasil pemetaan terendah pada kategori sumber yang lebih luas daripada target IPTC dan pada label dengan batas yang tidak jelas. Median kecocokan per kategori lebih tinggi untuk L3Cube (0.81) dan rubrik CC-NEWS (0.87) daripada untuk MasakhaNEWS (0.46) dan MN-DS (0.50). Kategori *politics* pada MasakhaNEWS hanya memiliki 45% artikel yang diprediksi sebagai *politics* dengan *conflict* (29%) sebagai alternatif utama. Label *society* pada MN-DS adalah contoh label dengan batas yang tidak jelas.

B. AKURASI SEMUA MODEL

Tabel 7 menunjukkan bahwa StaticKD mempertahankan 91.1% macro-F1 *teacher* pada *test set* terpadu dan 92.6% pada *development set*. Macro-F1 *test* StaticKD adalah 0.545 [0.490–0.605] dan macro-F1 *test teacher* 0.598 [0.546–0.643]. Skor *test* kedua model lebih rendah daripada skor *development set* (0.761 dan 0.822) karena sebagian besar *test set* berada di luar bahasa, sumber, dan periode data pelatihan *teacher*. Prediksi StaticKD sama dengan prediksi *teacher* pada 81.1% dokumen *held-out* dalam 63 bahasa.

Macro-F1 *test* StaticKD berada di antara skor kedua *transformer* hasil distilasi dan di atas skor fastText + KD serta TF-IDF + SVM + KD. Skor MiniLM-L6 (0.566) lebih tinggi daripada StaticKD sedangkan skor DistilmBERT (0.534) sedikit lebih rendah. Pengklasifikasi Model2Vec mencapai 0.547 atau hampir sama dengan StaticKD. Model fastText yang dilatih hanya pada label GPT-4o dari empat bahasa memperlihatkan akibat ketiadaan label *teacher* untuk bahasa lain (dua baris terakhir pada Tabel 7). Skor model ini mencapai 0.665 pada *development set* tetapi hanya 0.086 pada *test set*.

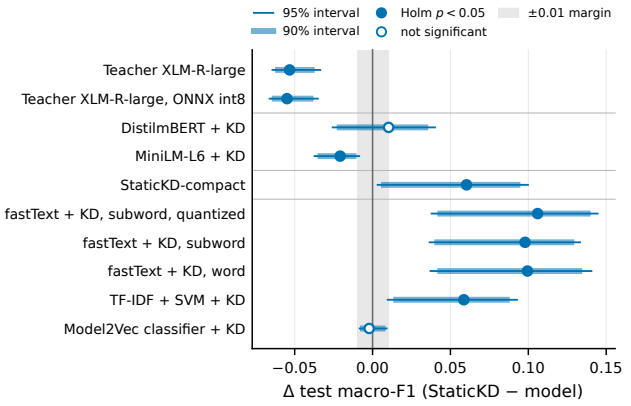
Uji berpasangan pada Tabel 8 mengonfirmasi peringkat ini. Gambar 4 memperlihatkan bahwa interval 95% selisih StaticKD terhadap semua model ringan kecuali pengklasifikasi Model2Vec berada di atas nol sedangkan interval terhadap *teacher* dan MiniLM-L6 berada di bawah nol. Δmacro-F1 StaticKD terhadap *teacher* adalah -0.053 [-0.065, -0.033] dan StaticKD mengungguli *teacher* hanya pada 7 dari 47 bahasa. MiniLM-L6 juga mempertahankan keunggulan yang signifikan atas StaticKD (-0.021 [-0.038, -0.008], $p = 0.005$). StaticKD dan DistilmBERT tidak berbeda signifikan (+0.010, $p = 1.000$) dan interval 90% [-0.023, +0.036] dari selisih ini terlalu lebar untuk menunjukkan kesetaraan (TOST $p = 0.428$). Uji Wilcoxon per bahasa juga tidak menemukan perbedaan yang konsisten antara kedua model ($p = 0.604$ untuk macro-F1 dan 0.322 untuk akurasi). Uji McNemar mengunggulkan StaticKD atas DistilmBERT dalam akurasi ($p < 0.001$) tetapi memperlakukan artikel dari situs yang sama sebagai independen.

TABEL 7. Hasil Utama. Macro-F1 [95% CI] dan Akurasi pada *Development Set* (EMMediaTopic Dev, Label GPT-4o), *Agreement* dengan *Teacher* pada CC-News *Held-Out*, dan Hasil pada *Test Set* Terpadu (47 Bahasa, Label Independen). CI *Test* dari *Site-Cluster Bootstrap*

	dev (4 bahasa)		held-out	test terpadu (47 bahasa)			
Model	Macro-F1 [95% CI]	Akurasi	Agreement	Macro-F1 [95% CI]	Akurasi	Macro-F1/bahasa	% teacher
Teacher XLM-R-large	0.822 [0.779–0.851]	0.859	–	0.598 [0.546–0.643]	0.700	0.705	100.0%
Teacher XLM-R-large, ONNX int8	0.823 [0.781–0.852]	0.858	–	0.600 [0.547–0.646]	0.699	0.702	100.3%
DistilmBERT + KD	0.753 [0.710–0.785]	0.801	0.799	0.534 [0.481–0.618]	0.623	0.602	89.4%
MiniLM-L6 + KD	0.785 [0.737–0.815]	0.820	0.825	0.566 [0.511–0.624]	0.667	0.661	94.6%
StaticKD (usulan)	**0.761 [0.717–0.792]**	0.800	0.811	**0.545 [0.490–0.605]**	0.641	0.622	91.1%
StaticKD ringkas	0.754 [0.710–0.786]	0.797	0.802	0.484 [0.421–0.597]	0.544	0.507	81.0%
fastText + KD, subword, terkuantisasi	0.729 [0.688–0.760]	0.768	0.740	0.439 [0.370–0.561]	0.515	0.465	73.4%
fastText + KD, subword	0.737 [0.701–0.765]	0.772	0.754	0.447 [0.385–0.566]	0.527	0.480	74.7%
fastText + KD, kata	0.750 [0.713–0.779]	0.791	0.758	0.445 [0.380–0.563]	0.515	0.474	74.5%
TF-IDF + SVM + KD	0.755 [0.719–0.786]	0.798	0.776	0.486 [0.431–0.585]	0.567	0.522	81.3%
Pengklasifikasi Model2Vec + KD	0.744 [0.701–0.772]	0.780	0.805	0.547 [0.495–0.599]	0.642	0.619	91.5%
fastText, label GPT-4o, subword	0.665 [0.613–0.700]	0.729	0.260	0.086 [0.069–0.119]	0.150	0.118	14.4%
fastText, label GPT-4o, kata	0.651 [0.601–0.693]	0.738	0.307	0.106 [0.085–0.150]	0.181	0.142	17.7%

TABEL 8. Uji Berpasangan StaticKD terhadap Model Lain pada *Test Set* Terpadu. ′ = StaticKD − Model Pembanding. *p* Dikoreksi Holm pada Perbandingan Ini. *b*/*c* = Dokumen yang Benar Hanya untuk StaticKD / Hanya untuk Model Pembanding

StaticKD vs	Δmacro-F1 [95% CI]	*p* bootstrap	Δakurasi	McNemar *b*/*c*	*p* McNemar
Teacher XLM-R-large	−0.053 [−0.065, −0.033]	<0.001	−0.059	654/1400	<0.001
Teacher XLM-R-large, ONNX int8	−0.055 [−0.067, −0.035]	<0.001	−0.058	644/1386	<0.001
DistilmBERT + KD	+0.010 [−0.026, +0.041]	1.000	+0.018	1372/1143	<0.001
MiniLM-L6 + KD	−0.021 [−0.038, −0.008]	0.005	−0.026	866/1197	<0.001
StaticKD ringkas	+0.060 [+0.003, +0.100]	0.042	+0.097	1345/110	<0.001
fastText + KD, subword, terkuantisasi	+0.106 [+0.037, +0.145]	<0.001	+0.126	2135/532	<0.001
fastText + KD, subword	+0.098 [+0.036, +0.134]	<0.001	+0.114	1979/529	<0.001
fastText + KD, kata	+0.099 [+0.037, +0.141]	<0.001	+0.126	2140/536	<0.001
TF-IDF + SVM + KD	+0.059 [+0.009, +0.093]	0.040	+0.074	1667/719	<0.001
Pengklasifikasi Model2Vec + KD	−0.002 [−0.009, +0.010]	1.000	−0.001	438/447	0.788
fastText, label GPT-4o, subword	+0.458 [+0.415, +0.496]	<0.001	+0.491	6597/344	<0.001
fastText, label GPT-4o, kata	+0.439 [+0.393, +0.475]	<0.001	+0.460	6252/391	<0.001



GAMBAR 4. Selisih berpasangan macro-F1 *test* antara StaticKD dan tiap model lain (StaticKD dikurangi model). Garis tipis menunjukkan interval *site-cluster bootstrap* 95%. Batang tebal menunjukkan interval 90%. Penanda terisi berbeda signifikan setelah koreksi Holm. Pita berarsir adalah margin kesetaraan ±0.01. Dua model fastText yang dilatih pada label GPT-4o berada di atas +0.4 dan tidak ditampilkan.

Pengklasifikasi Model2Vec adalah satu-satunya model ringan yang menyamai StaticKD. Δmacro-F1 antara kedua model adalah −0.002 [−0.009, +0.010] dengan interval 90% sebesar [−0.008, +0.008] di dalam margin kesetaraan ±0.01 (TOST $p = 0.025$). Perbandingan per bahasa dengan pengklasifikasi Model2Vec juga tidak menunjukkan perbedaan yang konsisten pada kedua metrik (Wilcoxon $p = 0.358$ untuk macro-F1 dan 0.534 untuk akurasi).

StaticKD unggul atas fastText + KD terkuantisasi sebesar +0.106 [+0.037, +0.145] dan atas TF-IDF + SVM sebesar +0.059 [+0.009, +0.093] ($p = 0.040$). Macro-F1 StaticKD lebih tinggi daripada fastText + KD pada 40 dari 47 bahasa (Wilcoxon $p < 0.001$). Keunggulan atas TF-IDF + SVM lebih sempit dengan macro-F1 StaticKD yang lebih tinggi pada 31 dari 47 bahasa (Wilcoxon $p = 0.003$). Gambaran yang berbeda muncul dari akurasi per bahasa terhadap TF-IDF + SVM karena StaticKD lebih tinggi pada 24 bahasa dan lebih rendah pada 22 (Wilcoxon $p = 0.127$).

Peringkat model hampir tidak berubah pada pemeriksaan terhadap struktur klaster *test set*. *Subset* dengan paling banyak lima artikel per situs dan pasangan bahasa–label menyisakan 8,139 artikel dengan skor 0.587 untuk StaticKD dan 0.627 untuk *teacher*. Hanya urutan StaticKD dan pengklasifikasi Model2Vec (0.583) yang berubah pada *subset* tersebut. Pembuangan sumber satu per satu menempatkan StaticKD di antara peringkat ketiga dan kelima dari sembilan model dan hanya pengklasifikasi Model2Vec serta DistilmBERT yang bertukar posisi dengannya. Setiap model fastText dan TF-IDF tetap paling sedikit 0.028 di bawah StaticKD.

Hasil uji berpasangan juga tidak berubah ketika kedua

transformer membaca input yang lebih panjang. Pelatihan ulang dengan input 512 token menaikkan macro-F1 *test* MiniLM-L6 dan DistilmBERT menjadi 0.580 dan 0.547. MiniLM-L6 tetap unggul atas StaticKD (-0.035 [-0.049, -0.021], $p < 0.001$) dan DistilmBERT tetap tidak berbeda signifikan dari StaticKD (-0.002 [-0.029, $+0.022$], $p = 0.779$).

C. EFISIENSI CPU

Tabel 9 menunjukkan bahwa *teacher* terlalu lambat di CPU untuk aliran artikel yang besar dan StaticKD menghilangkan biaya ini hampir seluruhnya. *Teacher* PyTorch fp32 memerlukan 2,816 ms per artikel pada satu *core* dan mencapai *throughput* 0.34 artikel per detik. Konfigurasi CPU terbaik untuk *teacher* adalah ONNX int8 (1,190 ms per artikel dan 0.79 artikel per detik). Kecepatan kedua konfigurasi ini berarti klasifikasi satu juta artikel per hari akan memerlukan 14.7 *core* (ONNX int8) hingga 33.7 *core* (PyTorch) untuk langkah ini saja. Beban yang sama memerlukan 0.02 *core* pada StaticKD.

Kecepatan StaticKD pada satu *core* melampaui semua model berbasis *transformer* dan mirip dengan model ringan lain. StaticKD memerlukan 2.01 ms per artikel dan dapat memproses 539 artikel per detik per *core* atau sekitar 682 kali kecepatan *teacher* ONNX int8 dan 1,572 kali kecepatan *teacher* PyTorch. MiniLM-L6 dan DistilmBERT hasil distilasi masih sekitar 32 dan 107 kali lebih lambat daripada StaticKD. Kecepatan satu *core* model ringan lain berkisar dari 433 artikel per detik untuk TF-IDF + SVM hingga 601 untuk varian ringkas. Tokenisasi membatasi kecepatan StaticKD karena memakan 98% waktu prediksi satu *thread* dengan rata-rata 579 token per artikel sedangkan langkah merata-ratakan baris tabel yang menyusul tokenisasi mencapai 26,843 artikel per detik bila diukur sendiri.

StaticKD juga memerlukan berkas yang lebih kecil daripada *teacher* serta berkas dan RAM yang lebih kecil daripada pengklasifikasi Model2Vec. Berkas StaticKD 16 kali lebih kecil daripada berkas *teacher* ONNX int8. Pengklasifikasi Model2Vec yang menyamai akurasi StaticKD memerlukan 507 MB di *disk* dan 1,091 MB RAM dibandingkan dengan 501 MB RAM pada StaticKD. Gambar 5 memperlihatkan bahwa StaticKD dan pengklasifikasi Model2Vec hampir berimpit pada panel (a) tetapi terpisah pada sumbu RAM di panel (b). RAM StaticKD tersebut sebagian besar diisi struktur *tokenizer* dan turun menjadi 277 MB pada varian ringkas. Model fastText + KD terkuantisasi lebih kecil (18 MB) dan memakai lebih sedikit RAM (300 MB) daripada StaticKD tetapi hanya mencapai macro-F1 *test* 0.439.

D. ABLASI, TEMPERATURE, DAN ENSEMBLE

Tabel 10 menunjukkan bahwa sebagian besar akurasi berasal dari dua komponen: data distilasi multibahasa dan *embedding* hasil prapelatihan. *Student* yang didistilasi pada EMMediaTopic saja (4 bahasa) sebagai pengganti data distilasi multibahasa kehilangan 0.051 pada macro-F1 *test* dan 0.077 pada *agreement held-out*. Penggantian *embedding* potion hasil prapelatihan dengan inisialisasi acak menurunkan macro-F1 *test* lebih banyak daripada varian lain mana pun (0.120, $p < 0.001$). Gambar 6 memperlihatkan bahwa hanya kedua varian ini yang berbeda signifikan dari resep akhir pada macro-F1 *test*.

Pembekuan *embedding* membatasi pelatihan pada *head* linear di atas potion dan memberikan hasil yang tidak searah. Skor *development set* turun sebesar 0.035 ($p = 0.040$) dan *agreement held-out* turun sebesar 0.020 ($p < 0.001$). Macro-F1 *test* justru naik sebesar 0.014 dengan interval yang mencakup nol ([-0.004, $+0.024$], $p = 1.000$). Tabel 11 menelusuri kenaikan ini ke bahasa dengan sedikit data distilasi (+0.059) dan ke bahasa tanpa data distilasi (+0.037). Bahasa dengan paling sedikit 500 dokumen menunjukkan arah sebaliknya dengan *embedding* beku yang sedikit lebih lemah pada kelompok ini (-0.007).

Tidak ada varian lain yang mengubah macro-F1 *test* secara signifikan. *Hard label* dari *teacher* menaikkan macro-F1 *test* sebesar 0.005 ($p = 1.000$) dan menurunkan skor *development set* sebesar 0.006 ($p = 1.000$). Interval 90% dari selisih *test* berada di dalam margin kesetaraan ([-0.001, $+0.009$], TOST $p = 0.017$). Uji ini menunjukkan bahwa *hard label* bekerja sebaik *soft label*. Pengurangan data menjadi 130 ribu dokumen menurunkan skor *test* sebesar 0.002 ($p = 1.000$) dan *agreement held-out* sebesar 0.009 ($p < 0.001$) tetapi selisih *test*-nya tetap lolos uji kesetaraan. Menghilangkan *token dropout* menaikkan macro-F1 *test* sebesar 0.001 ($p = 1.000$) dan juga lolos uji kesetaraan. *Head* MLP yang tidak dapat dilipat menaikkan macro-F1 *test* sebesar 0.009 ($p = 0.780$) tetapi tidak lolos uji kesetaraan karena interval 90%-nya mencapai +0.012.

Temperature yang lebih tinggi tidak membantu. Pilihan umum $\tau = 2$ [28] menurunkan *agreement held-out* sebesar 0.007 ($p < 0.001$) dibandingkan dengan $\tau = 1$. Macro-F1 *test* dan skor *development set* pada pilihan ini tidak berubah signifikan (-0.005 dan -0.006, keduanya $p = 1.000$). Selisih *test* lolos uji kesetaraan pada $\tau = 2$ maupun $\tau = 0.5$. Nilai $\tau = 4$ menurunkan skor *development set* dan *agreement held-out* secara signifikan serta skor *test* sebesar 0.014 yang tidak signifikan ($p = 0.836$).

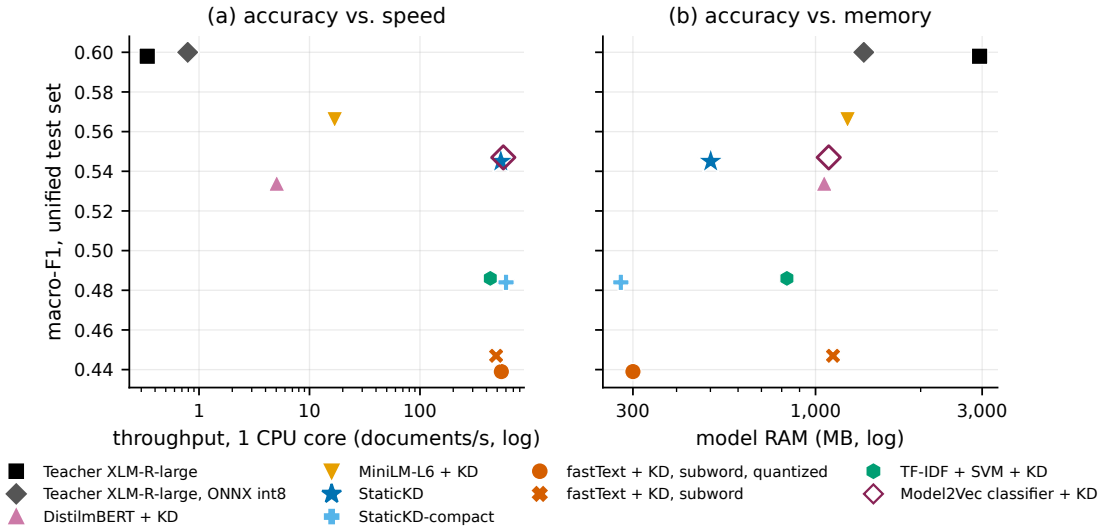
Memperbesar *ensemble* memberi kenaikan kecil. Tiga *seed* sebagai ganti satu *seed* menaikkan macro-F1 *test* dari 0.542 menjadi 0.544 dan *agreement held-out* dari 0.808 menjadi 0.810. Sepuluh *seed* menaikkan macro-F1 *test* menjadi 0.546. Kenaikan ini diperoleh tanpa biaya pada waktu inferensi karena *ensemble* berukuran berapa pun dilipat menjadi satu tabel.

E. ANALISIS PER BAHASA, LABEL, SUMBER, DAN TOKEN

Tabel 12 menunjukkan bahwa porsi skor *teacher* yang dipertahankan StaticKD lebih bervariasi menurut jumlah data distilasi dalam bahasa artikel daripada menurut asal label. Porsi per asal label berada antara 89.5% untuk kategori penerbit dan 95.8% untuk rubrik JSON-LD. Pengelompokan menurut data distilasi menunjukkan porsi yang turun dari 97.5% pada bahasa dengan paling sedikit 500 dokumen distilasi menjadi

TABEL 9. Efisiensi CPU pada P-Core yang Dipatok (Sampel dari *Test Set* Terpadu, 1c/4c = 1/4 *Core*)

Model	Latensi p50 / p95, 1c (ms)	Throughput 1c (dok/s)	Throughput 4c (dok/s)	RAM Model (MB)	Berkas (MB)	Dependensi
Teacher XLM-R-large	2,816 / 2,894	0.34	0.97	2,950	2,136	torch, transformers
Teacher XLM-R-large, ONNX int8	1,190 / 1,229	0.79	2.53	1,375	537	onnxruntime, transformers
DistilmBERT + KD	193 / 202	5.05	15.6	1,059	516	onnxruntime, transformers
MiniLM-L6 + KD	56.5 / 61.9	16.9	48.8	1,235	408	onnxruntime, transformers
StaticKD	2.01 / 3.31	539	1,827	501	34	numpy, tokenizers
StaticKD ringkas	1.78 / 3.17	601	2,005	277	23	numpy, tokenizers
fastText + KD, subword, terkuantisasi	1.93 / 3.21	545	1,393	300	18	fasttext, tokenizers
fastText + KD, subword	2.07 / 3.62	489	1,184	1,122	839	fasttext, tokenizers
TF-IDF + SVM + KD	2.96 / 4.49	433	865	828	166	scikit-learn, tokenizers
Pengklasifikasi Model2Vec + KD	1.99 / 3.22	568	1,822	1,091	507	model2vec, scikit-learn



GAMBAR 5. Macro-F1 *test* pada *test set* terpadu terhadap (a) *throughput* CPU satu *core* dan (b) RAM model (skala log).

TABEL 10. Ablasi dan *Temperature* (Satu *Student*, Tanpa *Ensemble*). Rata-Rata ± Simpangan Baku atas *Seed*. * = Berbeda dari Resep Akhir (*Bootstrap* Berpasangan, Holm, $p < 0.05$). ´ = Macro-F1 *Test* Dikurangi Macro-F1 *Test* Resep Akhir [95% CI]. † = Setara dalam ±0.01 (TOST)

Varian	Seed	Macro-F1 dev	Agreement held-out	Macro-F1 test	Δ macro-F1 test [95% CI]
Resep akhir					
Resep akhir (satu seed)	10	0.755±0.010	0.808±0.001	0.542±0.004	–
Ablasi komponen					
Hard label teacher (cross-entropy)	5	0.749±0.007	0.805±0.001	0.547±0.004	+0.005 [−0.002, +0.010]†
EMMediaTopic saja (4 bahasa, 20k)	5	0.723±0.006*	0.730±0.001*	0.491±0.002*	−0.051 [−0.064, −0.036]
130k dokumen (tanpa CC-News tambahan)	5	0.736±0.009*	0.799±0.002*	0.541±0.002	−0.002 [−0.008, +0.002]†
Embedding diinisialisasi acak	5	0.715±0.005*	0.739±0.004*	0.422±0.006*	−0.120 [−0.166, −0.047]
Embedding beku (hanya head linear)	5	0.720±0.001*	0.788±0.001*	0.557±0.002	+0.014 [−0.004, +0.024]
Tanpa token dropout	5	0.757±0.004	0.808±0.001	0.544±0.002	+0.001 [−0.001, +0.003]†
Head MLP 512 unit (tidak dapat dilipat)	5	0.762±0.009	0.813±0.002*	0.551±0.006	+0.009 [−0.000, +0.012]
Temperature					
$\tau = 0.5$	5	0.750±0.004	0.807±0.002	0.546±0.005	+0.004 [−0.002, +0.007]†
$\tau = 2$	5	0.748±0.003	0.801±0.001*	0.537±0.001	−0.005 [−0.010, +0.008]†
$\tau = 4$	5	0.723±0.004*	0.791±0.001*	0.529±0.002	−0.014 [−0.020, +0.001]

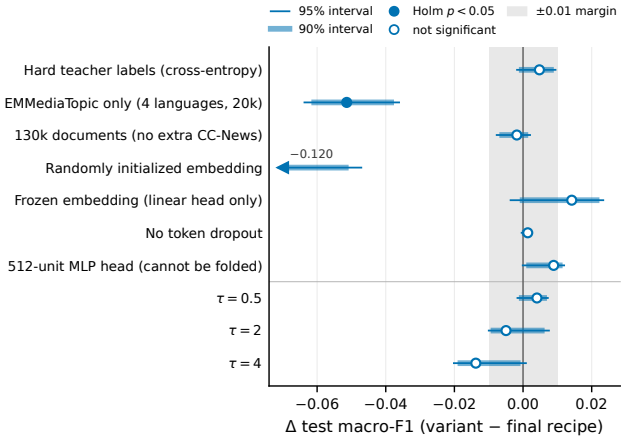
72.3% pada bahasa tanpa data distilasi. Subkelompok tanpa data distilasi ini juga satu-satunya subkelompok di Tabel 12 tempat pengklasifikasi Model2Vec unggul atas StaticKD dengan selisih lebih dari 0.011 (0.429 berbanding 0.402).

Porsi ini juga berbeda menurut sumber artikel. MN-DS adalah satu-satunya sumber yang dianotasi langsung dengan topik IPTC dan StaticKD mempertahankan 97.4% skor *teacher* pada sumber ini (0.535 berbanding 0.549). Porsi yang tinggi ini dicapai pada sumber tempat macro-F1 *teacher* sendiri lebih rendah daripada pada sumber lain mana pun. Porsi terkecil terdapat pada MasakhaNEWS (80.0%) yang label manusianya mengikuti skema non-IPTC dan 11 dari 16 bahasanya tidak ada dalam data distilasi.

Panel kiri Gambar 7 menunjukkan bahwa selisih akurasi StaticKD terhadap *teacher* kecil pada bahasa yang tipikal dengan median -0.024 per bahasa. Selisih ini menyempit seiring bertambahnya jumlah data distilasi ($\rho = 0.52$, $p < 0.001$). *Agreement held-out* StaticKD dengan *teacher*

TABEL 11. Macro-F1 Varian Terpilih menurut Jumlah Data Distilasi dalam Bahasa Artikel (*Test Set*, Rata-Rata atas *Seed*)

Varian	Dev	Cukup (≥500)	Sedikit (<500)	Tidak Ada (0)
Resep akhir (satu seed)	0.755	0.615	0.482	0.403
Embedding beku (hanya head linear)	0.720	0.607	0.541	0.440
Embedding diinisialisasi acak	0.715	0.567	0.182	0.161
EMMediaTopic saja (4 bahasa, 20k)	0.723	0.559	0.466	0.351
Hard label teacher (cross-entropy)	0.749	0.617	0.482	0.410
Head MLP 512 unit (tidak dapat dilipat)	0.762	0.613	0.484	0.421
$\tau = 2$	0.748	0.612	0.476	0.363



GAMBAR 6. Selisih macro-F1 *test* antara setiap varian ablasi dan resep akhir (varian dikurangi resep akhir). Pengodean mengikuti Gambar 4. Sebuah garis memisahkan ablasi komponen dari nilai *temperature*.

naik seiring tingkat keyakinan *teacher* ($\rho = 0.71$, $p < 0.001$) tetapi hubungannya dengan log jumlah data distilasi ($\rho = 0.31$) tidak signifikan setelah koreksi Holm ($p = 0.067$). *Agreement* juga tidak berbeda signifikan antaraksara (Kruskal–Wallis $H = 10.37$, $p = 0.067$). Panel kanan Gambar 7 memperlihatkan bahwa *agreement held-out* StaticKD lebih tinggi daripada *agreement* fastText + KD terkuantisasi pada 52 dari 53 bahasa.

Titik lemah StaticKD adalah sekelompok bahasa Afrika. StaticKD hanya mencapai rata-rata akurasi 0.407 pada bahasa yang berada di luar prapelatihan XLM-R dan juga tidak ada dalam data distilasi (Igbo, Luganda, Lingala, Pidgin Nigeria, Kirundi, Shona, Tigrinya, dan Yoruba). *Teacher* mencapai 0.643 pada bahasa yang sama. StaticKD lebih akurat pada bahasa India yang tidak atau hampir tidak ada dalam data distilasi daripada pada bahasa Afrika tersebut.

Empat bahasa India (Bangla, Malayalam, Odia, dan Punjabi) menunjukkan perilaku StaticKD pada teks yang token-tokennya hampir tidak pernah muncul dalam pelatihan. StaticKD mencapai 0.748 pada berita Bangla meskipun bahasa ini tidak ada dalam data distilasi. Baik fastText + KD maupun TF-IDF + SVM anjlok pada artikel yang sama (0.191 dan 0.010). Paling sedikit 67% kemunculan token dalam bahasa-bahasa ini berasal dari token yang muncul kurang dari 10 kali dalam data distilasi. StaticKD masih mencapai rata-rata akurasi 0.624 pada bahasa tersebut dibandingkan dengan 0.738 untuk *teacher*. Varian ringkas menghapus token langka ini dari *tokenizer* dan akurasinya pada keempat bahasa ini turun menjadi 0.013. Akurasi kedua model pada bahasa lainnya adalah 0.578 untuk varian ringkas dan 0.640 untuk StaticKD penuh.

Kinerja StaticKD berbeda antarlabel dan empat label tersulitnya juga termasuk label tersulit bagi *teacher*. Skor StaticKD pada keempat label ini adalah *society* (0.16), *disaster* (0.29), *human interest* (0.32), dan *conflict* (0.37). Kekeliruan yang paling sering adalah prediksi *human interest* untuk *society*, *arts* untuk *human interest*, dan *politics* untuk *society* dengan porsi masing-masing 20%. StaticKD paling baik pada *sport* (0.88), *weather* (0.84), dan *education* (0.75). Selisih terbesar terhadap *teacher* terjadi pada *environment* (−0.17), *religion* (−0.15), dan *arts* (−0.08).

Tabel token StaticKD juga menunjukkan token mana yang membawa sinyal topik artikel. Menyisakan hanya 10% token paling spesifik pada setiap artikel membuat macro-F1 *test* hampir tidak berubah (0.543 dengan sekitar 58 token per artikel berbanding 0.545 dengan semua token). Pilihan acak 10% token hanya menghasilkan 0.435.

F. KALIBRASI DAN MODE *CASCADE*

Tingkat keyakinan StaticKD lebih terkalibrasi daripada tingkat keyakinan *teacher*. ECE StaticKD adalah 0.041 pada *development set* dan 0.139 pada *test set* berbanding 0.090 dan 0.245 untuk *teacher*. Kedua model menjadi terlalu yakin pada *test set* di luar distribusi. Mode *cascade* memakai tingkat keyakinan ini untuk menentukan artikel yang diputuskan StaticKD. Tabel 13 menunjukkan bahwa ambang θ yang lebih tinggi menyerahkan lebih banyak artikel kepada *teacher*. Akurasi pada porsi StaticKD karena itu naik dari 0.732 menjadi 0.839 tetapi *throughput* efektif turun dari 4.09 menjadi 1.63 artikel per detik. Mode *cascade* pada $\theta = 0.8$ mencapai akurasi keseluruhan 0.703 dan macro-F1 0.602 berbanding 0.699 dan 0.600 untuk *teacher* saja. StaticKD sendiri memutuskan 60.3% artikel dalam *cascade* ini dengan akurasi 0.813. *Throughput* efektif *cascade* ini adalah 1.98 artikel per detik per *core* atau 2.5 kali *throughput teacher* (0.79).

VII. PEMBAHASAN

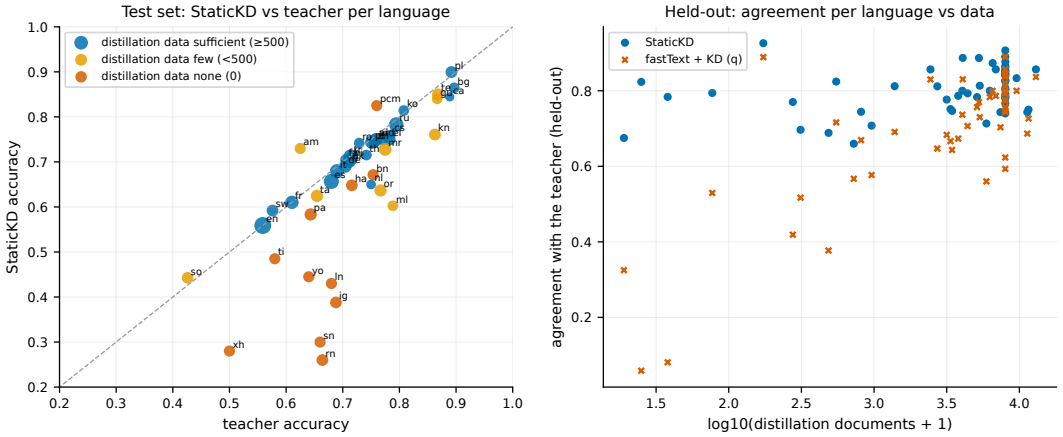
A. INFORMASI YANG DIPERTAHANKAN TABEL TOKEN

Lookup tabel mempertahankan sekitar sembilan per sepuluh macro-F1 *teacher* dan memangkas waktu inferensi sekitar tiga orde besaran (Bagian VI-B dan VI-C). Sebuah tabel sudah cukup karena sebagian kecil token yang spesifik untuk topik membawa hampir seluruh sinyal topik dalam artikel (Bagian VI-E). Temuan ini sesuai dengan pengamatan [13] bahwa representasi tanpa urutan sudah kompetitif untuk klasifikasi topik.

Skor StaticKD terendah terjadi pada *society*, *disaster*, *human interest*, dan *conflict* tetapi skor rendah ini tidak khas bagi *student*. Label yang sama termasuk label tersulit bagi *teacher* (Bagian VI-E) dan *society* serta *human interest* sulit bahkan bagi anotator manusia [6]. Selisih yang tersisa terhadap *teacher* terletak pada label lain dan pada bahasa yang kurang terwakili dalam data distilasi (Bagian VI-E).

TABEL 12. Macro-F1 *Test* per Subkelompok. Kolom Terakhir: Macro-F1 StaticKD sebagai Persentase Macro-F1 *Teacher* pada Subkelompok yang Sama

Subkelompok	n	Teacher	DistilmBERT	MiniLM	**StaticKD**	Model2Vec	fastText (q)	TF-IDF+SVM	fastText GPT	% teacher
Asal label										
anotasi manusia	4,094	0.463	0.436	0.436	0.414	0.414	0.328	0.393	0.027	90%
kategori penerbit	2,600	0.702	0.498	0.674	0.629	0.632	0.300	0.330	0.063	90%
rubrik JSON-LD	6,050	0.651	0.629	0.634	0.624	0.618	0.582	0.609	0.136	96%
Data distilasi bahasa										
cukup (≥500)	7,644	0.633	0.617	0.616	0.618	0.611	0.575	0.593	0.116	98%
sedikit (<500)	2,243	0.537	0.344	0.496	0.478	0.475	0.195	0.227	0.037	89%
tidak ada (0)	2,857	0.557	0.452	0.502	0.402	0.429	0.176	0.230	0.048	72%
Wilayah										
Afrika	3,044	0.697	0.532	0.576	0.542	0.550	0.325	0.408	0.085	78%
Asia Selatan	2,681	0.575	0.410	0.544	0.509	0.510	0.241	0.276	0.046	88%
Asia Timur/Tenggara & Timur Tengah	1,574	0.636	0.620	0.621	0.622	0.612	0.555	0.629	0.085	98%
Eropa	5,445	0.653	0.637	0.638	0.638	0.631	0.598	0.610	0.136	98%
Cakupan prapelatihan teacher										
di luar prapelatihan XLM-R	1,750	0.719	0.586	0.620	0.501	0.495	0.346	0.457	0.086	70%
dalam prapelatihan XLM-R	10,994	0.609	0.549	0.585	0.576	0.572	0.471	0.503	0.096	95%
Keragaman situs										
beragam (≥10)	5,225	0.657	0.642	0.643	0.642	0.637	0.601	0.616	0.134	98%
satu penerbit (<3)	6,204	0.517	0.387	0.475	0.433	0.435	0.224	0.287	0.045	84%
sedang (3–10)	1,315	0.559	0.556	0.539	0.543	0.532	0.503	0.533	0.089	97%



GAMBAR 7. Kiri: akurasi StaticKD terhadap akurasi *teacher* per bahasa *test* (warna menunjukkan data distilasi bahasa, ukuran menunjukkan jumlah artikel). Kanan: *agreement held-out* per bahasa terhadap jumlah data distilasi untuk StaticKD dan fastText + KD terkuantisasi.

TABEL 13. *Cascade* StaticKD → *Teacher* ONNX Int8 pada *Test Set* (*Throughput* Efektif Satu *Core*)

θ	Porsi StaticKD	Akurasi pada porsi	Macro-F1	Akurasi	dok/s
0 (StaticKD saja)	100.0%	0.641	0.545	0.641	539
0.5	80.8%	0.732	0.586	0.690	4.09
0.6	74.0%	0.760	0.593	0.697	3.02
0.7	67.4%	0.788	0.600	0.702	2.41
0.8	60.3%	0.813	0.602	0.703	1.98
0.9	51.7%	0.839	0.602	0.703	1.63
Teacher saja	0.0%	–	0.600	0.699	0.79

B. SUMBER AKURASI

Kontribusi terbesar berasal dari inisialisasi multibahasa hasil prapelatihan dan kontribusi terbesar kedua dari data distilasi multibahasa yang dilabeli *teacher*. Inisialisasi acak mengurangi macro-F1 *test* sebesar 0.120 berbanding 0.051 untuk penghapusan data multibahasa. Bukti paling langsung tentang peran inisialisasi berasal dari varian ringkas pada empat bahasa India yang hampir tidak muncul dalam data distilasi (Bagian VI-E). *Embedding* token langka dalam bahasa-bahasa ini tetap dekat dengan nilai potion karena pelatihan jarang atau tidak pernah memperbaruinya. Akurasi StaticKD dalam bahasa-bahasa ini masih mendekati akurasinya pada bahasa lain tetapi turun hampir ke nol setelah *tokenizer* ringkas menghapus token-token ini. Penurunan ini mengungkap bahwa transfer ke bahasa tanpa data bergantung pada *embedding* yang hampir tidak diubah pelatihan. *Head* linear yang dipelajari dari bahasa kaya data tetap berlaku untuk *embedding* tersebut karena *embedding* ini berada dalam ruang yang sama dengan *embedding* yang telah dilatih. Peran inisialisasi ini juga membedakan StaticKD dari Sparse Distillation [14] yang melatih tabel n-gram dari awal. *Embedding* multibahasa hasil prapelatihan yang dilipat menjadi 17 logit per token memungkinkan transfer ke bahasa yang tidak ada dalam data distilasi.

Pembekuan *embedding* menaikkan rata-rata skor bahasa dengan data distilasi yang sedikit atau tidak ada (Tabel 11). *Fine-tuning* menggeser *embedding* token milik bahasa pelatihan sedangkan token dari bahasa lain tetap berada pada posisi yang diberikan oleh potion. *Head* model telah menye-

suaikan diri dengan *embedding* yang bergeser dan kurang cocok dengan token yang tidak bergeser. Pergeseran yang sama membuat model lebih cocok dengan bahasa pelatihan sehingga *embedding* beku memberikan skor *development set* yang lebih rendah. *Fine-tuning* dan pembekuan karena itu mungkin mempertukarkan kecocokan dengan bahasa pelatihan dan penyelarasan lintas bahasa yang diwarisi dari potion. *Development set* dalam bahasa pelatihan hanya mengukur sisi pertama pertukaran ini sehingga resep akhir yang dipilih pada set tersebut memakai *fine-tuning*. Pembekuan tidak memberikan kenaikan signifikan pada seluruh *test set* tetapi layak diuji untuk penerapan yang menyasar bahasa tanpa data distilasi.

Perbandingan MiniLM-L6 dan DistilmBERT sebagai dua *student transformer* juga menunjuk pada peran representasi multibahasa awal. Kedua model ini belajar dari data distilasi yang sama dan sama-sama memiliki enam lapisan tetapi representasi awal keduanya berbeda karena MiniLM berasal dari distilasi XLM-R-large dan DistilmBERT dari mBERT. Hanya MiniLM-L6 yang menutup sebagian selisih terhadap *teacher* (Tabel 8).

Akurasi StaticKD dan pengklasifikasi Model2Vec kemungkinan terutama berasal dari *embedding* yang dipakai bersama dan data yang dilabeli *teacher* alih-alih dari *head*. Pengklasifikasi Model2Vec memakai *embedding* dan data yang sama dengan StaticKD tetapi belajar dari label teratas *teacher* dan menambahkan bobot per token serta lapisan tersembunyi (Tabel 4). Model ini tetap mencapai macro-F1 *test* yang sama dengan StaticKD dalam margin kesetaraan ± 0.01. Margin ini kurang dari separuh selisih antara StaticKD dan MiniLM-L6 (Tabel 8). Ablasi di Bagian VI-D juga tidak menunjukkan kenaikan signifikan pada macro-F1 *test* dari *head* MLP.

Soft label menambah sedikit atau tidak menambah apa pun. *Hard label teacher* setara dengan *soft label* pada $\tau = 1$ dalam ± 0.01 macro-F1 dan *temperature* yang lebih tinggi tidak pernah mengungguli $\tau = 1$ (Bagian VI-D). Pola ini sesuai dengan literatur tentang kesenjangan kapasitas [35], [36]. Satu lapisan linear di atas *embedding* yang dirata-ratakan mungkin tidak mampu merepresentasikan struktur antarkelas pada ekor distribusi *teacher* (*dark knowledge*) [31]. Nilai τ yang tinggi menuntut *student* meniru bentuk distribusi di luar kapasitasnya.

Agreement dengan *teacher* juga tidak selalu memprediksi akurasi pada label independen sehingga tidak cukup untuk memilih *student* [37]. Pemangkasan data menjadi 130 ribu dokumen menurunkan *agreement* secara signifikan tetapi membiarkan macro-F1 *test* tetap setara dengan resep akhir. Varian *embedding* beku memperoleh *agreement held-out* yang lebih rendah tetapi macro-F1 *test* yang lebih tinggi meskipun kenaikan ini tidak signifikan (Bagian VI-D). Pemilihan *student* karena itu sebaiknya memakai label yang tidak berasal dari *teacher* dan *development set* di luar distribusi pelatihan.

C. BAHASA YANG LEMAH

Kinerja per bahasa naik seiring seberapa baik suatu bahasa terwakili dalam data distilasi dan data prapelatihan. Kelompok terlemah terdiri atas bahasa Afrika di luar prapelatihan XLM-R yang juga tidak ada dalam data distilasi (Bagian VI-E). *Subword* yang dipakai bersama dengan bahasa lain dan konteks kalimat mungkin menjelaskan mengapa *teacher* tetap lebih akurat daripada StaticKD pada bahasa-bahasa ini. Perbaikan termurah tidak memerlukan perubahan arsitektur karena *teacher* dapat melabeli berita dalam bahasa-bahasa ini untuk ditambahkan ke data distilasi. Ablasi data dan korelasi antara selisih akurasi dan jumlah data ($\rho = 0.52$) mendukung penambahan berita semacam ini.

D. IMPLIKASI PRAKTIS

StaticKD cocok untuk *pipeline real-time* pada server tanpa GPU dan dapat disesuaikan bila pekerjaan menuntut akurasi lebih tinggi atau RAM lebih kecil. Pengklasifikasi Model2Vec dan StaticKD berjalan dengan kecepatan serupa tetapi StaticKD dilipat menjadi satu tabel sehingga berkas dan RAM-nya lebih kecil dan model ini hanya memerlukan pustaka `numpy` dan `tokenizers` (Tabel 9). Probabilitas keluaran StaticKD lebih terkalibrasi daripada probabilitas *teacher* sehingga memungkinkan mode *cascade* yang cocok untuk pekerjaan *batch* yang memerlukan akurasi setingkat *teacher*. Varian ringkas StaticKD menurunkan RAM tetapi hanya disarankan bila semua bahasa sasaran sudah tercakup dalam data distilasi.

E. KETERBATASAN

Skor *test* seharusnya dibaca dengan memperhatikan sifat label. Artikel tentang kasus kriminal yang melibatkan seorang atlet dapat secara sah berada di rubrik olahraga sedangkan sebuah model dapat melabeli artikel yang sama sebagai *crime*. Kedua jawaban masuk akal karena IPTC memungkinkan beberapa topik per artikel. Perbandingan antarmodel tetap adil karena semua model dinilai terhadap label yang sama. Cakupan studi ini terbatas pada klasifikasi label tunggal pada label IPTC tingkat atas sehingga artikel multitopik dan label pada tingkat yang lebih dalam belum diuji.

Label rubrik dan kategori penerbit mengikuti cara penerbit mengategorikan artikel sehingga skor absolut pada label ini mengukur kesesuaian dengan cara tersebut. Konvensi rubrik berbeda dari satu penerbit ke penerbit lain dan sebuah rubrik mencerminkan satu pandangan editorial atas artikel yang mungkin mencakup beberapa topik. Keterbatasan label editorial ini terutama berlaku untuk *society*, *human interest*, *lifestyle*, dan label lain dengan batas yang tidak jelas.

Sebagian besar label *test set* tidak dianotasi langsung dengan topik IPTC sehingga validitasnya bergantung pada pemetaan. Anotasi langsung dengan topik IPTC hanya ada di MN-DS dan hanya mencakup bahasa Inggris sedangkan *test set* IPTC multibahasa dari Kuzman dan Ljubešić [6] tidak tersedia untuk publik. Label MasakhaNEWS juga berasal dari anotator manusia tetapi mengikuti skema non-IPTC dan kemudian dipetakan ke IPTC. Label rubrik dipetakan dengan

tabel yang disusun secara konservatif dan divalidasi terhadap pohon IPTC sebelum dievaluasi dan dikoreksi secara manual tetapi evaluasi manual ini tidak menghasilkan ukuran kesepakatan antarpeninjau.

Cakupan label tidak merata antarbahasa. Median jumlah label yang muncul dalam setiap bahasa adalah 7 dan bahasa-bahasa Afrika hanya mencakup tiga sampai lima topik umum. Skor per bahasa tidak dapat dibandingkan secara langsung antara bahasa dengan cakupan label yang berbeda karena macro-F1 dihitung atas label yang ada.

Keragaman situs juga terbatas. Dua puluh tujuh bahasa memiliki kurang dari 3 situs efektif. Artikel dalam bahasa tersebut sebagian besar berasal dari MasakhaNEWS, L3Cube-IndicNews, *dataset* berita Bangla, atau satu atau dua situs CC-NEWS. Klaim tentang bahasa-bahasa ini hanya berlaku untuk sumber-sumber tersebut. *Site-cluster bootstrap* melebarkan interval kepercayaan bahasa-bahasa ini secara sepadan. Semua interval *test set* bertumpu pada sejumlah kecil sumber independen karena seluruh *test set* hanya memiliki jumlah efektif 13.8 klaster.

Pilihan pembanding, anggaran penyetelan, dan panjang input *transformer* membatasi perbandingan StaticKD dengan model lain. Sparse Distillation [14] tidak dijalankan sebagai *baseline*. Metode ini berbeda dari fastText + KD dan dari ablasi inisialisasi acak dalam lapisan tersembunyi *deep averaging network*-nya, target *soft-logit*-nya, dan tabel n-gram berskala miliar parameter yang dirancang untuk bahasa Inggris. Anggaran penyetelan tidak sama untuk semua model. Resep StaticKD ditetapkan pada *development set* sebelum *test set* dibangun dan *baseline* fastText serta TF-IDF disetel pada set yang sama dengan *grid* kecil. Pengklasifikasi Model2Vec memakai pengaturan bawaan pustaka dan model *transformer* mengikuti resep *fine-tuning* standar yang hanya mencari τ untuk MiniLM-L6. MiniLM-L6 dan DistilmBERT juga membaca paling banyak 256 token dalam perbandingan utama sehingga kedua model hanya mendapat kurang dari separuh teks sebagian besar artikel *test*. Pelatihan ulang kedua model dengan 512 token menaikkan macro-F1 *test* sebesar 0.014 dan 0.012 tanpa mengubah hasil perbandingan dengan StaticKD (Bagian VI-B).

Pengukuran efisiensi bergantung pada satu mesin. Seluruh *benchmark* dijalankan pada satu laptop (Bagian V-C) dan latensi *teacher* serta model *transformer* hanya diukur pada 100 dokumen. Angka absolut akan berbeda pada server tetapi rasio antarmodel yang diukur dengan protokol yang sama tetap informatif.

Kelemahan StaticKD pada bahasa Afrika yang tidak ada dalam data distilasi maupun data prapelatihan (Bagian VI-E) berarti filter topik yang berbasis model ini dapat lebih sering salah mengklasifikasikan atau membuang berita dalam bahasa-bahasa ini. Akurasi seharusnya dipantau per bahasa selama penerapan. Artikel dengan tingkat keyakinan rendah seharusnya diarahkan ke *teacher* melalui mode *cascade*.

Teacher membatasi kinerja *student* dari atas dan mewariskan kesalahan serta biasnya kepada *student*. Kesalahan warisan ini tidak terlihat pada *held-out set* karena set ini mengukur *agreement* dengan *teacher* dan bukan kebenaran.

VIII. KESIMPULAN

Pengklasifikasi IPTC multibahasa terbuka memerlukan 1.2 hingga 2.8 detik per artikel pada satu *core* CPU. StaticKD mendistilasi pengklasifikasi ini menjadi tabel berisi 17 logit per token. *Student* yang menghasilkan tabel ini diinisialisasi dari *embedding* statis multibahasa dan kemudian dilatih pada 285,999 artikel berlabel *teacher* dalam 69 bahasa. Evaluasi memakai 12,744 artikel *test* dalam 47 bahasa yang labelnya tidak berasal dari *teacher*. *Test set* ini dapat dipakai ulang untuk mengevaluasi pengklasifikasi IPTC lain.

StaticKD mencapai macro-F1 0.545 pada *test set* tersebut (91.1% dari skor *teacher*) dan memproses 539 artikel per detik per *core* CPU. Kecepatan ini sekitar 682 kali kecepatan *teacher* ONNX int8. Model berukuran 34 MB ini juga tidak memerlukan pustaka *deep learning*. Pengklasifikasi Model2Vec yang dilatih pada label *teacher* yang sama setara dengan StaticKD pada macro-F1 *test* tetapi memiliki berkas 15 kali lebih besar dan memerlukan memori dua kali lipat.

Ablasi menunjukkan bahwa akurasi *student* kecil ini terutama berasal dari data distilasi multibahasa dan *embedding* multibahasa hasil prapelatihan sedangkan *soft label* tidak lebih baik daripada *hard label*. *Embedding* beku menurunkan skor *development set* tetapi memberikan rata-rata skor yang lebih tinggi pada bahasa dengan data distilasi yang sedikit atau tidak ada meskipun kenaikan pada seluruh *test set* tidak signifikan.

StaticKD paling lemah pada label *society*, *disaster*, *human interest*, dan *conflict* serta pada bahasa yang tidak muncul dalam data distilasi maupun data prapelatihan *teacher*. Kelemahan pada bahasa ini menuntut perluasan data distilasi ke bahasa yang lemah dan terutama ke bahasa Afrika di luar prapelatihan XLM-R. *Fine-tuning* juga dapat memakai *regularizer* yang menjaga *embedding* tetap dekat dengan ruang hasil prapelatihan. *Regularizer* semacam ini mungkin memberikan akurasi dalam distribusi dan transfer lintas bahasa sekaligus.

Penelitian berikutnya juga dapat menekan biaya StaticKD dan memperluas tugas serta evaluasinya. *Tokenizer* yang lebih cepat seperti *lookup* langsung dari kata ke tabel menjadi sumber kecepatan berikutnya karena tokenisasi memakan 98% waktu inferensi StaticKD. Pemangkasan kosakata untuk memperkecil model harus mempertahankan token langka yang menjadi sandaran bahasa dengan data distilasi yang sedikit atau tidak ada. Masalah lain yang masih terbuka adalah *head* nonlinear murah dengan *embedding* terkuantisasi, klasifikasi hierarkis hingga IPTC tingkat 2, klasifikasi multilabel, dan anotasi IPTC oleh manusia pada sampel multibahasa dari *test set*.

KETERSEDIAAN KODE, MODEL, DAN DATA

Kode untuk studi ini tersedia di [TODO: URL GitHub dan DOI Zenodo] dan mencakup pengumpulan data, penyusunan

test set, pelabelan oleh *teacher*, pelatihan, evaluasi, dan *benchmarking*. Lokasi yang sama menyediakan *notebook* yang mereproduksi setiap angka, tabel, dan gambar dalam makalah ini. Tabel pemetaan rubrik ke IPTC juga dirilis bersama kode. Model StaticKD tersedia di [TODO: URL Hugging Face]. *Test set* dirilis bersama skrip rekonstruksinya sebagai manifes berisi URL atau ID artikel, label, asal label, dan *hash* teks. Teks artikel tidak didistribusikan ulang karena hak cipta penerbit dan lisensi *dataset* sumber. EMMediaTopic tersedia dari repositori CLARIN.SI [26]. Lisensi aset yang dipakai dan dirilis dalam studi ini dicantumkan bersama kode.

UCAPAN TERIMA KASIH

Para penulis berterima kasih kepada Departemen Teknik Informatika, Institut Teknologi Sepuluh Nopember, atas dukungannya terhadap penelitian ini. Para penulis memakai Claude Opus 5.5 (Anthropic) di bawah arahan mereka untuk menjajaki pilihan desain metode dan untuk menjalankan eksperimen eksploratif dan eksperimen akhir. Model ini juga menulis kode eksperimen, mengolah data (termasuk draf pertama tabel pemetaan rubrik ke IPTC), dan menyusun draf sebagian teks naskah. Para penulis menulis dan merevisi naskah sendiri, meninjau dan memverifikasi semua kode, data, dan hasil, serta bertanggung jawab penuh atas isi dan klaim naskah.

REFERENCES

[1] O. Razuvayevskaya, B. Wu, J. A. Leite, F. Heppell, I. Srba, C. Scarton, K. Bontcheva, and X. Song, "Comparison between parameter-efficient techniques and full fine-tuning: A case study on multilingual news article classification," *PLOS ONE*, vol. 19, no. 5, p. e0301738, 2024.

[2] D. I. Adelani, M. Masiak, I. A. Azime, J. Alabi, A. L. Tonja, C. Mwase, O. Ogundepo, B. F. P. Dossou, A. Oladipo, D. Nixdorf *et al.*, "MasakhaNEWS: News topic classification for African languages," in *Proc. 13th Int. Joint Conf. Natural Language Process. and 3rd Conf. Asia-Pacific Chapter Assoc. Comput. Linguistics (IJCNLP-AACL), Vol. 1: Long Papers*, 2023, pp. 144–159.

[3] A. Mirashi, S. Sonavane, P. Lingayat, T. Padhiyar, and R. Joshi, "L3Cube-IndicNews: News-based short text and long document classification datasets in Indic languages," in *Proc. 20th Int. Conf. Natural Language Process. (ICON)*, 2023, pp. 442–449.

[4] International Press Telecommunications Council (IPTC), "Media topics – IPTC NewsCodes," [Online]. Available: https://iptc.org/standards/media-topics/, 2024.

[5] M. Sebők, Á. Máté, O. Ring, V. Kovács, and R. Lehoczki, "Leveraging open large language models for multilingual policy topic classification: The Babel machine approach," *Social Science Computer Review*, vol. 43, no. 2, pp. 295–317, 2025.

[6] T. Kuzman and N. Ljubešić, "LLM teacher-student framework for text classification with no manually annotated data: A case study in IPTC news topic classification," *IEEE Access*, vol. 13, pp. 35 621–35 633, 2025.

[7] J. Zschache and T. Hartwig, "Comparing energy consumption and accuracy in text classification inference," *Scientific Reports*, vol. 16, p. 12717, 2026.

[8] M. Treviso, J.-U. Lee, T. Ji, B. van Aken, Q. Cao, M. R. Ciosici, M. Hassid, K. Heafield, S. Hooker, C. Raffel, P. H. Martins, A. F. T. Martins, J. Z. Forde, P. Milder, E. Simpson, N. Slonim, J. Dodge, E. Strubell, N. Balasubramanian, L. Derczynski, I. Gurevych, and R. Schwartz, "Efficient methods for natural language processing: A survey," *Trans. Assoc. Comput. Linguistics*, vol. 11, pp. 826–860, 2023.

[9] S. Minaee, N. Kalchbrenner, E. Cambria, N. Nikzad, M. Chenaghlu, and J. Gao, "Deep learning–based text classification: A comprehensive review," *ACM Computing Surveys*, vol. 54, no. 3, pp. 1–40, 2021.

[10] W. Wang, H. Bao, S. Huang, L. Dong, and F. Wei, "MiniLMv2: Multi-head self-attention relation distillation for compressing pretrained transformers," in *Findings Assoc. Comput. Linguistics: ACL-IJCNLP 2021*, 2021, pp. 2140–2151.

[11] V. Sanh, L. Debut, J. Chaumond, and T. Wolf, "DistilBERT, a distilled version of BERT: Smaller, faster, cheaper and lighter," arXiv:1910.01108 (NeurIPS 2019 EMC^2 Workshop), 2019.

[12] A. Joulin, E. Grave, P. Bojanowski, and T. Mikolov, "Bag of tricks for efficient text classification," in *Proc. 15th Conf. European Chapter Assoc. Comput. Linguistics (EACL), Vol. 2: Short Papers*, 2017, pp. 427–431.

[13] L. Galke and A. Scherp, "Bag-of-words vs. graph vs. sequence in text classification: Questioning the necessity of text-graphs and the surprising strength of a wide MLP," in *Proc. 60th Annu. Meeting Assoc. Comput. Linguistics (ACL), Vol. 1: Long Papers*, 2022, pp. 4038–4051.

[14] Q. Ye, M. Khabsa, M. Lewis, S. Wang, X. Ren, and A. Jaech, "Sparse distillation: Speeding up text classification by using bigger student models," in *Proc. Conf. North American Chapter Assoc. Comput. Linguistics: Human Language Technologies (NAACL-HLT)*, 2022, pp. 2361–2375.

[15] T. Wada, Y. Hirakawa, R. Shimizu, T. Kawashima, and Y. Saito, "Static word embeddings for sentence semantic representation," in *Proc. Conf. Empirical Methods Natural Language Process. (EMNLP)*, 2025, pp. 6195–6211.

[16] S. Tulkens and T. van Dongen, "Model2Vec: Fast state-of-the-art static embeddings," Software, Zenodo, 2024, concept DOI (all versions); version 0.9.0 was used. [Online]. Available: https://github.com/MinishLab/model2vec.

[17] C. Singh, A. Askari, R. Caruana, and J. Gao, "Augmenting interpretable models with large language models during training," *Nature Communications*, vol. 14, p. 7913, 2023.

[18] A. Conneau, K. Khandelwal, N. Goyal, V. Chaudhary, G. Wenzek, F. Guzmán, E. Grave, M. Ott, L. Zettlemoyer, and V. Stoyanov, "Unsupervised cross-lingual representation learning at scale," in *Proc. 58th Annu. Meeting Assoc. Comput. Linguistics (ACL)*, 2020, pp. 8440–8451.

[19] R. V. Guha, D. Brickley, and S. Macbeth, "Schema.org: Evolution of structured data on the web," *Commun. ACM*, vol. 59, no. 2, pp. 44–51, 2016.

[20] A. Petukhova and N. Fachada, "MN-DS: A multilabeled news dataset for news articles hierarchical classification," *Data*, vol. 8, no. 5, p. 74, 2023.

[21] T. Hossain, A.-R. Islam, M. H. K. Mehedi, A. A. Rasel, M. Abdullah-Al-Wadud, and J. Uddin, "BanglaNewsClassifier: A machine learning approach for news classification in Bangla newspapers using hybrid stacking classifiers," *PLOS ONE*, vol. 20, no. 6, p. e0321291, 2025.

[22] Jakarta Artificial Intelligence Research, "IndoNews: Indonesian news topic classification dataset (liputan6)," Hugging Face dataset `jakartaresearch/indonews`, 2021.

[23] M. Heseltine and B. Clemm von Hohenberg, "Large language models as a substitute for human experts in annotating political text," *Research & Politics*, vol. 11, no. 1, 2024.

[24] L. Bojić, O. Zagovora, A. Zelenkauskaite, V. Vuković, M. Čabarkapa, S. Veseljević Jerković, and A. Jovančević, "Comparing large language models and human annotators in latent content analysis of sentiment, political leaning, emotional intensity and sarcasm," *Scientific Reports*, vol. 15, p. 11477, 2025.

[25] B. Fatemi, F. Rabbi, and A. L. Opdahl, "Evaluating the effectiveness of GPT large language model for news classification in the IPTC news ontology," *IEEE Access*, vol. 11, 2023.

[26] T. Kuzman and N. Ljubešić, "News topic dataset EMMediaTopic 1.0," Slovenian language resource repository CLARIN.SI, http://hdl.handle.net/11356/1991, 2025.

[27] T. Kuzman Pungeršek, P. Rupnik, I. Porupski, V. Dinić, and N. Ljubešić, "State of the art in text classification for South Slavic languages: Fine-tuning or prompting?" in *Proc. Workshop Shaping Multilingual, Multimodal AI for the Social Sciences and Humanities (LLMs4SSH) at LREC 2026*, 2026, pp. 1–17.

[28] G. Hinton, O. Vinyals, and J. Dean, "Distilling the knowledge in a neural network," NIPS Deep Learning and Representation Learning Workshop, arXiv:1503.02531, 2015.

[29] J. Gou, B. Yu, S. J. Maybank, and D. Tao, "Knowledge distillation: A survey," *International Journal of Computer Vision*, vol. 129, no. 6, pp. 1789–1819, 2021.

[30] M. Gupta and P. Agrawal, "Compression of deep learning models for text: A survey," *ACM Transactions on Knowledge Discovery from Data*, vol. 16, no. 4, pp. 1–55, 2022.

[31] B. Zhao, Q. Cui, R. Song, Y. Qiu, and J. Liang, "Decoupled knowledge distillation," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2022, pp. 11 943–11 952.

[32] Z. Li, X. Li, L. Yang, B. Zhao, R. Song, L. Luo, J. Li, and J. Yang, "Curriculum temperature for knowledge distillation," in *Proc. AAAI Conf. Artif. Intell.*, vol. 37, no. 2, 2023, pp. 1504–1512.
[33] R. Piperno, L. Bacco, F. Dell'Orletta, M. Merone, and L. Pecchia, "Cross-lingual distillation for domain knowledge transfer with sentence transformers," *Knowledge-Based Systems*, vol. 311, p. 113079, 2025.
[34] M. Iyyer, V. Manjunatha, J. Boyd-Graber, and H. Daumé III, "Deep unordered composition rivals syntactic methods for text classification," in *Proc. 53rd Annu. Meeting Assoc. Comput. Linguistics and 7th Int. Joint Conf. Natural Language Process. (ACL-IJCNLP), Vol. 1: Long Papers*, 2015, pp. 1681–1691.
[35] C. Zhang, Q. Li, D. Song, Z. Ye, Y. Gao, and Y. Hu, "Towards the law of capacity gap in distilling language models," in *Proc. 63rd Annu. Meeting Assoc. Comput. Linguistics (ACL), Vol. 1: Long Papers*, 2025, pp. 22 504–22 528.
[36] Y. Wang, W. Niu, X. Yao, L. You, and W. Fei, "Rethinking the dark knowledge and Kullback-Leibler divergence loss in knowledge distillation under capacity mismatching," in *Proc. AAAI Conf. Artif. Intell.*, vol. 40, no. 31, 2026, pp. 26 688–26 696.
[37] S. Stanton, P. Izmailov, P. Kirichenko, A. A. Alemi, and A. G. Wilson, "Does knowledge distillation really work?" in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 34, 2021, pp. 6906–6919.
[38] J. Chen, S. Xiao, P. Zhang, K. Luo, D. Lian, and Z. Liu, "M3-Embedding: Multi-linguality, multi-functionality, multi-granularity text embeddings through self-knowledge distillation," in *Findings Assoc. Comput. Linguistics: ACL 2024*, 2024, pp. 2318–2335.
[39] A. Z. Broder, "On the resemblance and containment of documents," in *Proc. Compression and Complexity of SEQUENCES*, 1997, pp. 21–29.
[40] K. Lee, D. Ippolito, A. Nystrom, C. Zhang, D. Eck, C. Callison-Burch, and N. Carlini, "Deduplicating training data makes language models better," in *Proc. 60th Annu. Meeting Assoc. Comput. Linguistics (ACL), Vol. 1: Long Papers*, 2022, pp. 8424–8445.
[41] P. Koehn, "Statistical significance tests for machine translation evaluation," in *Proc. Conf. Empirical Methods Natural Language Process. (EMNLP)*, 2004, pp. 388–395.
[42] R. Dror, G. Baumer, S. Shlomov, and R. Reichart, "The hitchhiker's guide to testing statistical significance in natural language processing," in *Proc. 56th Annu. Meeting Assoc. Comput. Linguistics (ACL), Vol. 1: Long Papers*, 2018, pp. 1383–1392.
[43] C. A. Field and A. H. Welsh, "Bootstrapping clustered data," *J. Roy. Statist. Soc. B*, vol. 69, no. 3, pp. 369–390, 2007.
[44] CloverSearch, "cc-news-mutlilingual: Common Crawl news split by language and year," Hugging Face Datasets. [Online]. Available: https://huggingface.co/datasets/CloverSearch/cc-news-mutlilingual.
[45] Common Crawl Foundation, "CC-NEWS: News crawl archive," https://commoncrawl.org/blog/news-dataset-available, WARC files 2024-01 to 2026-08, accessed Sep. 2026, 2026.
[46] A. Barbaresi, "Trafilatura: A web scraping library and command-line tool for text discovery and extraction," in *Proc. 59th Annu. Meeting Assoc. Comput. Linguistics and 11th Int. Joint Conf. Natural Lang. Process.: System Demonstrations*, 2021, pp. 122–131.
[47] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, "On calibration of modern neural networks," in *Proc. 34th Int. Conf. Mach. Learn. (ICML)*, ser. Proc. Mach. Learn. Res., vol. 70, 2017, pp. 1321–1330.
[48] Q. McNemar, "Note on the sampling error of the difference between correlated proportions or percentages," *Psychometrika*, vol. 12, no. 2, pp. 153–157, 1947.
[49] S. Holm, "A simple sequentially rejective multiple test procedure," *Scand. J. Statist.*, vol. 6, no. 2, pp. 65–70, 1979.
[50] D. J. Schuirmann, "A comparison of the two one-sided tests procedure and the power approach for assessing the equivalence of average bioavailability," *J. Pharmacokinetics Biopharmaceutics*, vol. 15, no. 6, pp. 657–680, 1987.

OBI KASTANYA [TODO: biografi penulis]

ANANTA DWI PRAYOGA ALWY [TODO: biografi penulis]