StaticKD: Distilasi Classifier Topik Berita IPTC Multibahasa menjadi Tabel Logit Token Statis untuk Inference Ringan di CPU

Versi bacaan bahasa Indonesia (terjemahan makna, bukan naskah resmi)

Obi Kastanya, Ananta Dwi Prayoga Alwy

Abstrak

Menyaring berita dengan taksonomi IPTC Media Topic butuh classifier yang murah dijalankan pada aliran artikel multibahasa. Classifier IPTC multibahasa terbuka yang ada, berbasis XLM-RoBERTa-large, butuh 1,239 sampai 2,971 milidetik per artikel pada satu core prosesor. Model itu di-distill menjadi StaticKD: student berbasis static embedding multibahasa yang kepala linearnya dilipat ke dalam tabel embedding, sehingga seluruh model hanyalah satu tabel berisi 17 logit per token. Teacher melabeli 285,999 artikel tak berlabel dalam 69 bahasa. Test set berisi 12,744 artikel dalam 47 bahasa, berlabel dari anotator manusia atau dari rubrik (section) yang ditetapkan redaksi lalu dipetakan ke pohon IPTC; jadi evaluasi tidak memakai label dari model apa pun. Di test set ini StaticKD mencapai macro-F1 0.545, atau 91.1% dari skor teacher 0.598. StaticKD mengklasifikasi 473 artikel per detik per core, sekitar 616 kali lebih cepat daripada teacher yang dikuantisasi 8-bit, dengan model 34 megabyte, dan lebih akurat daripada fastText serta linear support vector machine yang di-distill dengan data yang sama. Ablasi dengan lima seed per varian menunjukkan akurasi berasal dari data distilasi multibahasa dan embedding yang selaras lintas bahasa, sedangkan hard label setara dengan soft label. Transfer ke bahasa yang tidak ada di data distilasi dibawa oleh baris embedding yang tidak pernah di-update saat training, dan fine-tuning embedding menukar transfer ini dengan kecocokan in-distribution. StaticKD paling lemah pada bahasa yang tidak ada di data distilasi maupun di data pre-training teacher.

Kata kunci: efficient inference, knowledge distillation, multilingual text classification, news topic classification, static embeddings.

I. Pendahuluan

Pipeline analitik berita memberi topik standar pada artikel sejak awal, supaya tahap-tahap yang lebih mahal hanya memproses topik yang relevan. Taksonomi yang paling banyak dipakai kantor berita adalah Media Topic dari International Press Telecommunications Council (IPTC). Level teratasnya berisi 17 topik, misalnya politics, economy, business and finance, dan sport [1], [2].

Kuzman dan Ljubešić [2] merilis classifier IPTC multibahasa terbuka yang pertama. Mereka melabeli artikel dalam empat bahasa dengan GPT-4o, lalu memakai label itu untuk fine-tune XLM-RoBERTa-large [3]. Model hasilnya setara GPT-4o pada test set beranotasi manusia. Studi lanjutan dari kelompok yang sama menyimpulkan encoder hasil fine-tuning lebih praktis daripada large language model (LLM) untuk anotasi skala besar [4]. Tetapi encoder dengan 559.9 juta parameter tetap mahal tanpa GPU: di satu core CPU butuh 2,971 ms per artikel, dan konfigurasi CPU tercepatnya (export ONNX yang dikuantisasi ke bilangan bulat 8-bit, int8) masih butuh 1,239 ms (Bagian IV-D). Kedua studi tidak melaporkan biaya inference ini, padahal inference menyumbang porsi besar kebutuhan komputasi dan energi machine learning di produksi;

contohnya 60% energi machine learning yang dilaporkan Google [5].

Yang dituju: classifier topik yang mencakup banyak bahasa, berjalan dalam hitungan milidetik per artikel di CPU biasa, kecil, dan dependensinya sedikit. Pilihan yang ada belum memenuhi ini. Transformer kecil hasil distilasi [6], [7] hanya mempercepat sekitar satu orde besaran; di benchmark CPU studi ini, MiniLM-L6 21 kali lebih cepat daripada teacher ONNX int8. Kuantisasi int8 saja memberi faktor 2.3 dibanding PyTorch fp32. fastText [8] jauh lebih cepat, tetapi embedding-nya dipelajari dari nol sehingga tidak bisa transfer antarbahasa. Ini penting karena data IPTC berlabel hanya ada untuk empat bahasa.

Paper ini mengusulkan StaticKD, yang men-distill [9] classifier IPTC XLM-R-large menjadi student yang setelah training hanyalah satu tabel berisi 17 logit per token. Alasannya: (a) teacher yang bekerja lintas bahasa bisa melabeli berita tak berlabel dalam bahasa apa pun tanpa biaya anotasi; (b) static embedding multibahasa yang di-distill dari sentence encoder [10], [11], [12] menempatkan padanan terjemahan berdekatan, dan mencarinya hampir tanpa biaya; (c) topik berita sangat leksikal, sehingga representasi bag-of-words tetap kompetitif untuk klasifikasi topik [13]. Karena kepala klasifikasi StaticKD linear, embedding rata-rata dan kepala itu bisa dilipat menjadi tabel token. Inference lalu tinggal tokenisasi dan merata-rata baris tabel, yang cukup dikerjakan NumPy.

Klaim multibahasa butuh evaluasi multibahasa dengan label yang tidak berasal dari teacher. Test set manusia milik Kuzman dan Ljubešić tidak publik dan hanya mencakup empat bahasa. SIB-200 [14] mencakup 205 bahasa, tetapi isinya kalimat pendek dengan taksonomi non-IPTC. Untuk mengisi celah ini dibangun unified test set berisi 12,744 artikel dalam 47 bahasa. Isinya gabungan artikel CC-NEWS 2024 sampai 2026 yang membawa rubrik redaksinya di metadata schema.org [15], dengan dataset publik yang dilabeli manusia atau kategori penerbit [16], [17], [18], [19]. Labelnya adalah keputusan redaksi penerbit atau anotator, diterjemahkan ke pohon IPTC resmi. Tidak ada model yang membaca teks artikel yang terlibat dalam pelabelan.

studi ini menjawab empat research question (RQ).

- RQ1 (biaya): berapa biaya inference CPU teacher IPTC, dan seberapa besar StaticKD menguranginya?
- RQ2 (akurasi): berapa bagian akurasi teacher yang dipertahankan StaticKD pada label yang tidak berasal dari teacher, dibandingkan baseline berbiaya serupa (fastText, dan support vector machine/SVM di atas fitur TF-IDF) dan baseline berbiaya lebih tinggi (MiniLM-L6 dan DistilmBERT)?
- RQ3 (komponen): komponen distilasi mana yang menentukan akurasi student berkapasitas sangat rendah ini: soft label, data multibahasa, inisialisasi embedding, fine-tuning embedding, token dropout, temperature, atau ensemble?
- RQ4 (generalisasi): pada bahasa, label, dan sumber label mana StaticKD lemah, dan faktor apa yang menjelaskannya?

Distilasi ke student berkapasitas sangat rendah juga memperlihatkan dari mana akurasinya berasal. Pengetahuan yang penting berasal dari cakupan transfer set dan inisialisasi yang selaras, bukan dari bentuk soft label. Hard label setara soft label, dan temperature tinggi merugikan. Transfer ke bahasa yang tidak pernah muncul di data distilasi dibawa oleh baris embedding yang tidak pernah di-update saat training; ini berhasil karena baris itu berada di ruang yang sama dengan baris yang dilatih. Fine-tuning embedding menukar transfer ini dengan kecocokan in-distribution, yaitu representation drift yang tidak terdeteksi oleh development set dalam bahasa training.

kontribusi paper ini adalah sebagai berikut.

- test set IPTC multibahasa berisi 12,744 artikel dalam 47 bahasa yang label editorialnya tidak berasal dari teacher. Dilengkapi tabel pemetaan rubrik ke IPTC yang divalidasi otomatis dan ditinjau penulis

pertama, deduplikasi lintas sumber, pemeriksaan kontaminasi terhadap seluruh data training, dan confidence interval site-cluster bootstrap. Test set ini bisa dipakai ulang untuk mengevaluasi classifier IPTC lain.

- temuan-temuan di atas, didukung ablasi dengan lima seed per varian dan analisis per bahasa, label, asal label, dan sumber, termasuk bahasa yang tidak ada di data distilasi.
- StaticKD, resep yang men-distill teacher transformer multibahasa menjadi tabel logit per token yang diinisialisasi dari static embedding lintas bahasa. Model final berukuran 34 MB, hanya butuh numpy dan tokenizers, dan memproses 473 artikel per detik per core. Ensemble beberapa seed bisa dilipat ke tabel yang sama tanpa biaya inference tambahan. Trade-off akurasi dan biayanya dibandingkan dengan sembilan konfigurasi dari enam keluarga model, diukur hanya di CPU dengan core pinning untuk CPU hybrid.
- rilis kode, notebook yang mereproduksi setiap angka di paper, model, dan manifest test set.

Bagian II membahas penelitian terkait, Bagian III menjelaskan data, test set, metode, dan protokol evaluasi, Bagian IV menyajikan hasil, Bagian V membahasnya, Bagian VI memuat keterbatasan, dan Bagian VII menyimpulkan.

II. Penelitian Terkait

Klasifikasi topik berita multibahasa dan skema IPTC

Sumber data klasifikasi topik berita biasanya punya taksonomi sendiri dan hanya satu bahasa atau wilayah. MasakhaNEWS mencakup 16 bahasa yang banyak dipakai di Afrika, termasuk Inggris dan Prancis, dengan tujuh kategori beranotasi manusia [16]. L3Cube-IndicNews memakai kategori situs penerbit untuk 10 bahasa India [18], dan dataset berita Bangla juga memakai kategori penerbit [19]. MN-DS adalah satu-satunya dataset publik yang dianotasi langsung dengan topik IPTC level atas, dan hanya bahasa Inggris [17]. SIB-200 mencakup 205 bahasa, tetapi isinya kalimat Flores-200 dengan tujuh topik non-IPTC [14]. Kuzman dan Ljubešić [2] menunjukkan label GPT-4o bisa menggantikan anotasi manusia untuk melatih classifier IPTC, dan studi lanjutannya menemukan encoder hasil fine-tuning lebih praktis daripada LLM untuk anotasi skala besar [4]. Akibatnya, satu-satunya classifier IPTC multibahasa terbuka adalah encoder 559.9 juta parameter, dan belum ada classifier IPTC murah yang dievaluasi pada berita nyata dalam banyak bahasa.

Men-distill classifier transformer menjadi student kecil

Knowledge distillation (KD) melatih model murah untuk meniru distribusi output model mahal yang dilunakkan dengan temperature [9]. Survei terbaru membahas perkembangannya untuk language model [20]. Di klasifikasi teks, student hampir selalu transformer, misalnya DistilBERT [6] atau MiniLMv2 [7], termasuk distilasi lintas bahasa yang memindahkan pengetahuan teacher ke bahasa dengan data sedikit [21]. Karya terdekat adalah Sparse Distillation [22], yang men-distill RoBERTa-large menjadi deep averaging network [23] dengan tabel n-gram sangat besar, dan ratusan kali lebih cepat pada tugas klasifikasi kalimat tunggal bahasa Inggris. StaticKD berbeda dalam tiga hal: (1) tabelnya dimulai dari static embedding multibahasa yang sudah selaras lintas bahasa, bukan dilatih dari nol; (2) kepala linearnya dilipat sehingga tiap token hanya menyimpan 17 angka; (3) menargetkan dokumen berita dalam 69 bahasa dan dievaluasi pada bahasa yang tidak ada di data distilasi.

Temperature dan capacity gap

Keberhasilan distilasi bergantung pada capacity gap antara teacher dan student. Untuk language model, ukuran teacher optimal bahkan mengikuti hukum empiris terhadap ukuran student [24]. Temperature diperlakukan sebagai hyperparameter penting yang bisa dipelajari [25]. Divergensi Kullback–Leibler (KL) bisa dipecah menjadi bagian kelas target dan bagian non-target (dark knowledge) [26], dan analisis terbaru menunjukkan KL pada kapasitas yang tidak seimbang merusak urutan kelas [27]. Kesetiaan (fidelity) pada teacher juga tidak selalu sejalan dengan generalisasi [28]. Hampir semua temuan ini berasal dari student yang dalam (deep). Perilaku temperature dan soft label pada gap ekstrem, dari 559.9 juta parameter ke satu layer linear di atas embedding rata-rata, belum pernah dikarakterisasi.

Static embedding dan inference CPU yang efisien

Model2Vec [10] dan Wada dkk. [11] mengekstrak static word embedding dari sentence transformer; merata-ratakannya menghasilkan sentence embedding yang kompetitif. Varian potion-multilingual di-distill dari BGE-M3 [12] untuk 101 bahasa. Library Model2Vec juga punya trainer untuk mengubah model seperti ini menjadi classifier: trainer itu fine-tune embedding dan bobot per token, menambah hidden layer 512 unit, dan dilatih dengan cross-entropy pada hard label [10]. Embedding seperti ini biasanya dievaluasi sebagai embedding serbaguna, bukan sebagai student distilasi untuk taksonomi tertentu. Representasi bag-of-words sederhana tetap kompetitif untuk klasifikasi topik [13]. Survei metode NLP yang efisien menganjurkan melaporkan biaya inference di samping akurasi [29], karena inference menyumbang porsi besar penggunaan energi model yang sudah di-deploy [5]. Namun hanya sedikit studi yang melaporkan latency CPU dengan jumlah thread kecil terhadap teacher yang dikuantisasi.

Test set dengan label editorial, kontaminasi, dan dependensi sampel

Kategori situs penerbit sudah pernah dipakai sebagai label topik [18], biasanya untuk satu penerbit atau satu wilayah. Metadata schema.org articleBagian [15] belum pernah dipetakan ke taksonomi standar lintas puluhan bahasa. Kebocoran antara data training dan test juga harus dikendalikan, dan penghapusan near-duplicate dengan MinHash [30] sudah menjadi praktik standar [31]. Uji signifikansi di NLP seperti paired bootstrap [32] biasanya mengasumsikan sampel independen [33], padahal artikel dari situs yang sama saling bergantung. Cluster bootstrap [34] menangani dependensi ini dengan me-resample klaster, bukan dokumen. Tabel I merangkum posisi StaticKD terhadap pendekatan-pendekatan ini.

> **Tabel I** — Posisi StaticKD dibanding pendekatan terkait (kolom: pendekatan, model saat inference, multibahasa, transfer lintas bahasa, tanpa library deep learning, biaya CPU dilaporkan, label IPTC). *(isi tabel: lihat PDF bahasa Inggris)*

III. Metodologi

Desain studi

Gambar 1 merangkum studi. Teacher melabeli korpus distilasi, lalu StaticKD dan semua baseline dilatih pada data itu. Test set terpisah yang labelnya tidak berasal dari teacher dipakai untuk evaluasi akurasi dengan uji statistik dan analisis subgrup, dan biaya inference diukur di CPU. Resep StaticKD sudah ditetapkan pada development set SEBELUM test set dibangun, dan tidak ada hyperparameter yang dipilih memakai test set. Selama eksplorasi itu, check set kecil berisi 320 artikel CC-News dalam 16 bahasa, dilabeli Claude dengan prompt dan deskripsi label dari [2], juga dipakai sebagai sinyal sekunder di samping development set dan held-out agreement. Check set ini ikut menyertai pemilihan tau=1 dan ensemble tabel tiga seed

(dari tiga seed yang dijalankan di fase itu). Label LLM terlalu dekat dengan setting teacher untuk dijadikan uji independen, sehingga check set ini dibuang dari evaluasi final.

Gambar 1. Pipeline StaticKD. Teacher melabeli korpus berita tak berlabel satu kali, secara offline. Student belajar meniru distribusi teacher, lalu kepala linearnya dilipat ke tabel token, sehingga inference hanya mencari dan merata-rata baris tabel. Evaluasi final memakai test set yang labelnya tidak berasal dari teacher. (Diagram TikZ di main.tex; tidak perlu digambar ulang.)

Formulasi masalah

Diberikan artikel berita d dalam bahasa apa pun (judul dan isi, dipotong ke 512 kata pertama seperti di [2]), model memprediksi satu label y dari 17 topik IPTC level atas. Teacher f_T mengeluarkan logit z^T(d) berdimensi 17. Tujuannya student f_S yang biaya inference-nya O(n) penjumlahan untuk n token, tanpa perkalian matriks dan tanpa library deep learning, dan akurasinya terhadap label independen sedekat mungkin dengan f_T.

Data distilasi dan development set

EMMediaTopic 1.0 [35] [2] berisi artikel berbahasa Katalan, Yunani, Kroasia, dan Slovenia yang dilabeli GPT-4o. Split training-nya (20,000 artikel) menjadi bagian data distilasi. Split development-nya (1,000 artikel, median 218 kata) tidak pernah dipakai untuk melatih teacher maupun student, dan menjadi development set untuk memilih resep.

korpus CC-News multibahasa [36] dari arsip 2019-2021 diproses dengan langkah-langkah berikut.

- simpan hanya dokumen yang bahasa di metadatanya sama dengan hasil identifikasi bahasa fastText [8].
- ambil judul dan isi dengan minimal 75 kata (200 karakter untuk ja, zh, th, my), lalu potong ke 512 kata.
- simpan paling banyak 150 dokumen per situs.
- bentuk split held-out berdasarkan domain: semua dokumen dari sebagian situs disisihkan, paling banyak 20% per bahasa.
- tambahkan 156,157 dokumen hanya dari situs training (paling banyak 5,000 per bahasa dan 400 per situs).

Data distilasi berisi 285,999 dokumen dalam 69 bahasa dari 2,960 situs, dengan median 269 kata. Split held-out terpisah domain di setiap bahasa. Beberapa situs multibahasa (misalnya bbc.com) juga muncul di bahasa lain dalam data distilasi, jadi artikelnya dibuang. Fidelity set yang tersisa berisi 12,554 dokumen dalam 63 bahasa dari 217 situs yang tidak pernah muncul di data distilasi.

Konstruksi unified test set

Sumber pertama adalah CC-NEWS 2024-2026: satu file WARC per bulan dari Januari 2024 sampai Agustus 2026 (32 file) dari arsip Common Crawl CC-NEWS [37]. Dari setiap halaman diekstrak blok JSON-LD schema.org [15] bertipe NewsArticle dan subtipenya, dengan field articleSection, BreadcrumbList, inLanguage, datePublished, isAccessibleForFree, dan articleBody. Teks diambil dari articleBody bila minimal 30 kata; kalau tidak, diekstrak dengan Trafilatura [38]. Situs yang muncul di data distilasi atau di set evaluasi lain dibuang, sehingga tersisa 399,468 artikel dari situs baru.

Sumber kedua adalah dataset publik. MasakhaNEWS [16] dan MN-DS [17] dilabeli manusia. L3Cube-IndicNews (split LDC) [18], berita Bangla [19], IndoNews [39], berita Amharik [40], dan berita Swahili [41] membawa kategori penerbit. Dua yang terakhir diproses dengan cara yang sama tetapi tidak terpilih saat sampling, karena sel bahasanya sudah diisi MasakhaNEWS dengan label manusia. Total sumber kedua berisi 312,551 artikel.

Label rubrik (section) dan kategori mewakili topik editorial, yaitu keputusan redaksi tentang di mana artikel ditempatkan saat diterbitkan. Label ini tidak berasal dari model yang membaca teks artikel, jadi tidak sirkular terhadap teacher. Satu-satunya langkah tambahan adalah menerjemahkan nama rubrik ke pohon IPTC Media Topic resmi (1,085 node aktif). Nama rubrik dinormalisasi (huruf besar-kecil, diakritik) dan dipetakan secara konservatif: sebuah nama hanya dipetakan bila isi yang biasa ada di rubrik itu masuk ke satu topik level atas. Hasilnya 814 nama dipetakan ke 79 node. Tabel pemetaan sengaja membiarkan 62 nama ambigu tidak dipetakan, misalnya tech (bisa science and technology, atau industri teknologi informasi di bawah economy); begitu juga entertainment (arts atau lifestyle) dan terrorism (conflict atau crime). Rubrik astrologi ditolak. Pemeriksaan otomatis memastikan setiap node tujuan ada di pohon IPTC, tidak retired, dan leluhur level-1-nya adalah label tujuan. Artikel yang rubrik-rubriknya terpetakan ke label berbeda ditolak. MN-DS tidak perlu dipetakan karena labelnya sudah topik IPTC. Tabel pemetaan disusun dengan bantuan artificial intelligence, dan penulis pertama meninjau seluruh 916 aturannya (814 nama terpetakan dan 102 aturan ambigu, khusus bahasa, dan penolakan) lalu menerimanya tanpa perubahan.

filter kualitas dan kebocoran diterapkan secara berurutan.

- tanggal terbit pada atau setelah 1 Januari 2024 (hanya CC-NEWS). Tulis tanggal dalam format IEEE: 1 January 2024.
- tidak berada di balik paywall.
- bahasa yang dideklarasikan sama dengan identifikasi bahasa fastText, bila bahasanya didukung fastText.
- minimal 75 kata.
- deduplikasi URL, teks identik, dan near-duplicate (MinHash [30], Jaccard >= 0.7 [31]) lintas semua sumber. Singkatan URL didefinisikan di sini (uniform resource locator).
- Filter 6, kontaminasi: artikel dibuang bila >= 30% word 8-gram-nya muncul di salah satu dari sekitar 300 ribu dokumen training atau evaluasi. Filter ini membuang 50 artikel, sebagian besar dari MasakhaNEWS, yang juga mengambil dari BBC.

Sampling mengambil paling banyak 50 artikel per sel bahasa x label, dengan urutan prioritas: sumber berlabel manusia, lalu kategori penerbit, lalu rubrik JSON-LD. Bahasa dengan kurang dari 30 artikel dibuang. Jumlah artikel per situs tidak dibatasi, karena kebanyakan sel hanya berasal dari sedikit situs, dan batas seperti itu hanya membuang data tanpa menambah keragaman. Evaluasi menangani dependensi antarartikel dari situs yang sama dengan site-cluster bootstrap, dan Bagian IV-A melaporkan uji sensitivitas dengan paling banyak lima artikel per situs.

Test set final berisi 12,744 artikel dalam 47 bahasa, dengan 17 label dan 1,227 situs atau sumber, median 313 kata. Dari jumlah itu, 4,094 artikel (32.1%) berlabel anotasi manusia, 2,600 (20.4%) kategori penerbit, dan 6,050 (47.5%) rubrik JSON-LD. Menurut data distilasi di bahasanya: 13 bahasa sama sekali tidak ada di data distilasi (misalnya ha, yo, ig, bn, pa), 9 bahasa punya kurang dari 500 dokumen, dan 25 bahasa punya lebih. Menurut keragaman situs: 13 bahasa punya minimal 10 situs efektif, sedangkan 27 bahasa praktis hanya dari satu penerbit. Tabel II merangkum sumbernya dan Gambar 2 menunjukkan cakupan bahasa x label.

Tabel II — Komposisi unified test set per sumber. *(isi tabel: lihat PDF bahasa Inggris)*

Teacher dan label distilasi

Teacher adalah classifier IPTC dari [2], dipublikasikan sebagai classla/multilingual-IPTC-news-topic-classifier. Model XLM-RoBERTa-large dengan 24 layer, 559.9 juta parameter, dan input paling banyak 512 token. Arsitekturnya membatasi input ke 512 token XLM-R. Input 512 kata dari 60.7% artikel uji melebihi batas ini, dan untuk artikel tersebut teacher hanya membaca sekitar 287 dari 438 kata (median). Untuk setiap dokumen distilasi, teacher menghasilkan vektor logit z^T(d) berdimensi 17, yang disimpan utuh. Pelabelan dijalankan sekali dalam fp16 di GPU NVIDIA RTX 4050 Laptop (6 GB), dengan batch diurutkan menurut panjang teks. Pada sampel tetap 5,000 dokumen, teacher melabeli 50.1 dokumen per detik, sehingga seluruh data distilasi butuh sekitar 1.58 jam GPU. Prediksi arg-max dari run ulang ini sama dengan label tersimpan untuk 100% dokumen. Distribusi label teacher di CC-News masuk akal (politics 16.5%, economy 12.7%, sport 11.6%, weather 1.3%), dan rata-rata confidence per bahasa berkisar 0.90 sampai 1.00.

Student StaticKD

Dokumen d ditokenisasi menjadi t_1 … t_n dengan Unigram tokenizer potion-multilingual-128M [10], yang punya 500,353 token. Special token tidak dipakai, token tak dikenal dibuang, dan panjang dibatasi 1,024 token. Perataan tidak punya batas posisi, jadi batas ini hanya membatasi biaya; hanya 5.4% artikel uji yang melebihinya. Tiap token punya embedding e_t berdimensi 256, dan [kalimat berlanjut ke Persamaan (1)].

Persamaan (1): Persamaan student: h(d) = rata-rata embedding token dokumen; z^S(d) = W dikali dropout(h(d)) ditambah b.

Lanjutan setelah Persamaan (1): dengan W berukuran 17 x 256 dan dropout 0.1 saat training. Matriks embedding E diinisialisasi dari potion-multilingual, yaitu static embedding untuk 101 bahasa yang di-distill dari BGE-M3 [12].

Persamaan (2): loss di (2) memakai p^T = softmax(z^T / tau) dan p^S = softmax(z^S / tau).

Persamaan (2): Loss distilasi: L_KD = tau^2 dikali divergensi KL antara p^T dan p^S, dengan tau = 1.

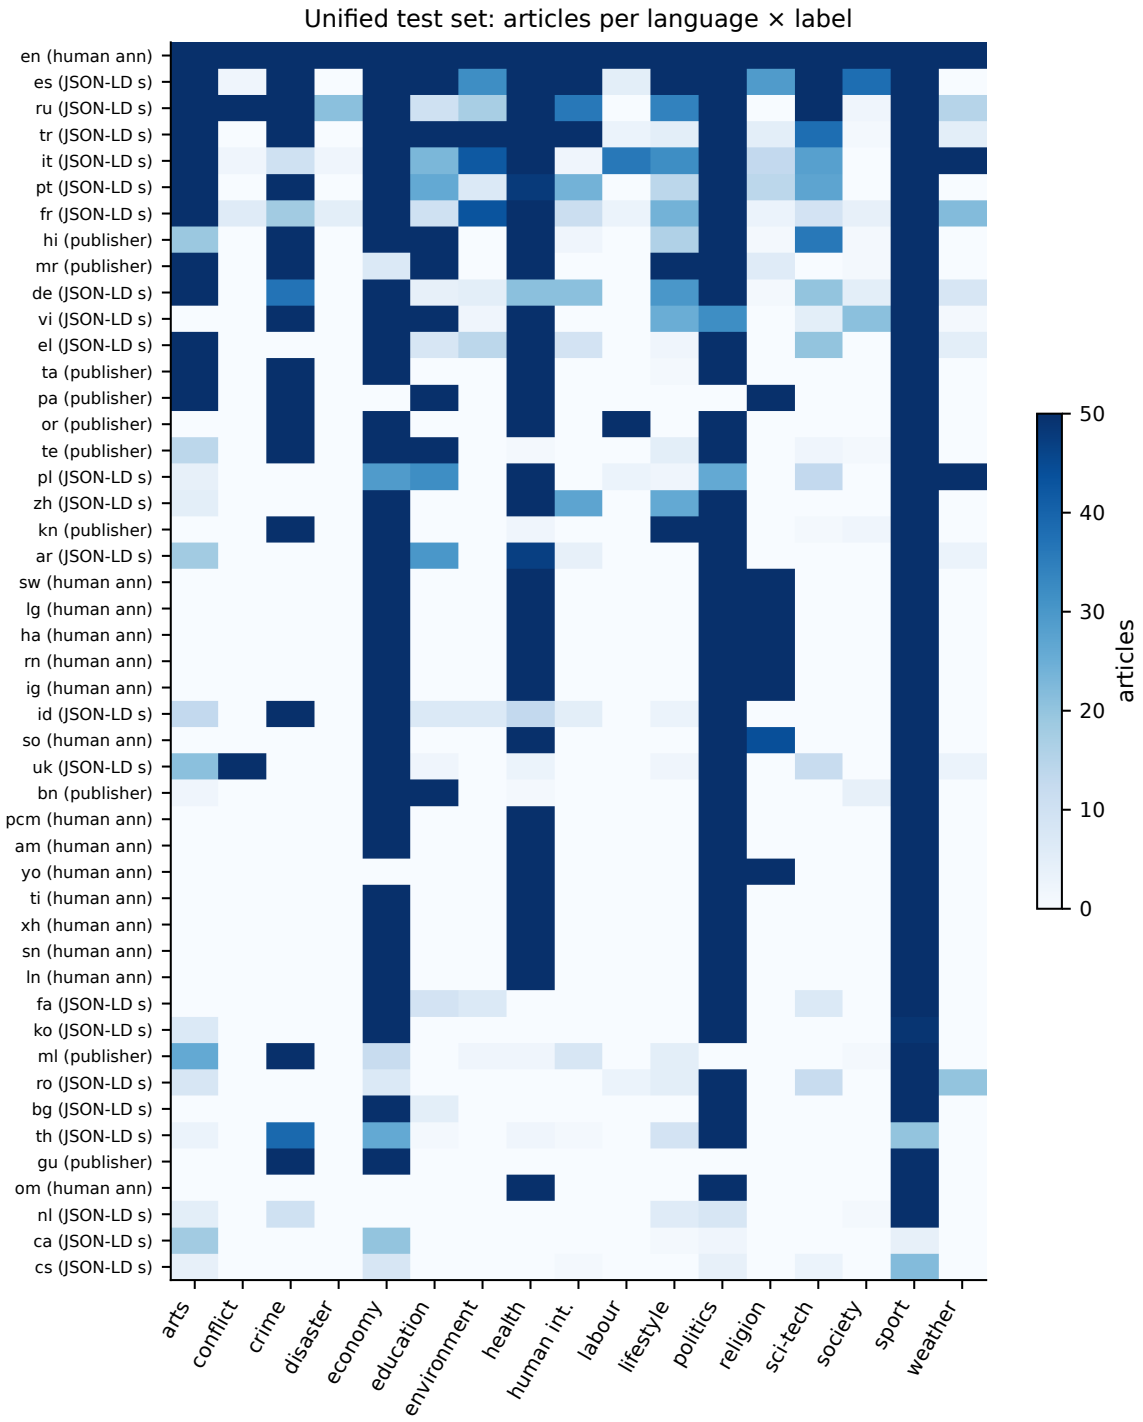
E, W, dan b dilatih end to end. E memakai SparseAdam (eta = 10^-3), sehingga hanya baris token yang ada di batch yang di-update; W dan b memakai AdamW (eta = 3 x 10^-3, weight decay 10^-4). Batch size 64 dan training berjalan 6 epoch. Sebagai augmentasi murah, setiap token dokumen training dibuang dengan probabilitas 0.2 di setiap langkah (token dropout), supaya model tidak bergantung pada sedikit kata kunci. Validasi internal memakai 3% data distilasi (8,579 dokumen), dan epoch dengan arg-max agreement tertinggi terhadap teacher yang disimpan.

Persamaan (3): karena kepala klasifikasi linear, (1) bisa ditulis ulang sebagai [Persamaan (3)].

Persamaan (3): Pelipatan kepala: W dikali rata-rata embedding ditambah b sama dengan rata-rata baris tabel T ditambah b.

Lanjutan setelah Persamaan (3): dengan tabel T = E W^T berukuran |V| x 17. Model produksi hanya terdiri dari T (fp16), b, dan tokenizer; inference = tokenisasi, merata-rata baris tabel, lalu menambahkan bias. Merata-ratakan logit dari K student dengan seed berbeda juga sama dengan logit satu student dengan tabel T-bar = (1/K) jumlah T^(k) dan bias b-bar, karena (3) linear terhadap T. Model StaticKD final adalah ensemble tabel dari seed 0, 1, dan 2 (K=3), dengan 8.5 juta parameter dan ukuran 34 MB.

Struktur internal Unigram tokenizer butuh RAM jauh lebih besar daripada tabelnya sendiri (16 MB). Varian compact mengecilkan struktur itu dengan membuang potongan token yang muncul kurang dari 10 kali di



Gambar 1: Gambar 2. Jumlah artikel di unified test set per bahasa dan label (paling banyak 50 per sel). Asal label di dalam kurung adalah asal label dominan untuk bahasa tersebut.

korpus distilasi, tetapi tetap menyimpan karakter tunggal. Vocabulary-nya 335,441 token dan modelnya 23 MB. Tabel III mencantumkan hyperparameter semua model. Singkatan RAM (random-access memory) didefinisikan di sini.

Tabel III — Hyperparameter semua model. *(isi tabel: lihat PDF bahasa Inggris)*

Baseline

Semua baseline dilatih pada data distilasi yang sama (285,999 dokumen) dengan target dari teacher yang sama. fastText + KD [8] dilatih pada label arg-max teacher dengan token kata (plus character n-gram) atau subword XLM-R, ditambah varian terkuantisasi (.ftz). Sebagai pembanding yang setara dengan data berlabel yang dimiliki [2], fastText juga dilatih hanya pada label GPT-4o dari split training EMMediaTopic. TF-IDF + SVM + KD adalah baseline non-neural milik Kuzman dan Ljubešić (fitur TF-IDF dengan support vector classifier), dilatih pada label arg-max teacher di atas subword XLM-R. Hyperparameter baseline non-transformer ini ditetapkan sekali, seperti di Tabel III, tanpa pencarian. MiniLM-L6 + KD memakai mMiniLMv2-L6-H384 (hasil distilasi dari XLM-R-large) [7], dengan temperature tau dalam {1, 2} yang dipilih pada development set. DistilmBERT + KD memakai distilbert-base-multilingual-cased [6] dengan resep yang sama. Kedua transformer hanya membaca paling banyak 256 token, sehingga memotong 91.1% (MiniLM-L6) dan 93.2% (DistilmBERT) artikel uji menjadi sekitar 142 dan 116 kata. Keduanya di-export ke ONNX fp32 untuk benchmark CPU. Teacher ONNX int8 adalah export teacher yang dikuantisasi int8 secara dinamis, dan merupakan konfigurasi CPU tercepatnya.

Sparse Distillation [22], karya terdekat, tidak direproduksi sepenuhnya. Dua eksperimen studi ini mencakup ide intinya: fastText + KD adalah model bag-of-n-grams dengan perataan dan kepala linear yang dilatih pada label teacher di transfer set yang sama; ablasi inisialisasi acak (Bagian III-J) melatih tabel embedding dari nol. Perbedaan yang tersisa: hidden layer pada deep averaging network, target berupa soft logit, dan tabel n-gram miliaran parameter yang dirancang untuk bahasa Inggris. Ablasi embedding beku (hanya melatih kepala linear di atas potion) berfungsi sebagai baseline Model2Vec siap pakai dengan kepala hasil distilasi. Trainer classifier dari library Model2Vec tidak dijalankan sebagai baseline. Konfigurasi default-nya dilatih pada hard label, menambah hidden layer 512 unit, dan juga mempelajari bobot per token. Ablasi mengganti soft label dengan hard label, dan kepala linear dengan hidden layer 512 unit, satu per satu; tidak satu pun berbeda signifikan dari resep final di development maupun test set (Tabel VIII). Kombinasi keduanya dan bobot token yang dipelajari tidak diuji. Hidden layer juga membuat model tidak bisa dilipat menjadi satu tabel.

Protokol evaluasi dan uji statistik

Metrik utama adalah macro-F1 atas label yang ada di referensi, seperti kode evaluasi [2], karena distribusi label tidak seimbang. Evaluasi juga melaporkan akurasi, macro-F1 per bahasa yang dirata-rata antarbahasa (supaya bahasa besar tidak mendominasi), dan agreement dengan teacher pada fidelity set. Pada label editorial, macro-F1 dibaca sebagai kesesuaian prediksi dengan kategorisasi penerbit.

Confidence interval 95% berasal dari percentile bootstrap dengan 1,000 resample. Di test set, unit resample-nya adalah situs, atau dataset sumber bila tidak ada URL (site-cluster bootstrap [34]); di development set, unitnya dokumen. Dua model pada dokumen yang sama dibandingkan dengan paired (cluster) bootstrap 2,000 resample untuk selisih macro-F1 [32] dan uji McNemar exact untuk akurasi [42], dengan koreksi Holm [43] di dalam setiap set. Setiap varian ablasi memakai lima seed, dan resep final sepuluh. Perbedaan antarvarian diuji dengan uji Welch di level seed, dikoreksi Holm. Konsistensi perbedaan antarbahasa diuji dengan Wilcoxon signed-rank pada macro-F1 dan akurasi per bahasa [33]. Analisis subgrup mencakup asal label, wilayah, jumlah data distilasi bahasa, keragaman situs, aksara, bahasa, dan label. Kalibrasi diukur dengan expected calibration error (ECE, 15 bin) [44].

Protokol efisiensi

Benchmark berjalan hanya di CPU dengan GPU disembunyikan. Setiap model dijalankan di proses baru, dan jumlah thread dikunci di semua library (OMP, MKL, OpenBLAS, ONNX Runtime, tokenizers). Latency diukur dengan satu artikel per panggilan seperti skenario streaming (p50 dan p95), dan throughput dengan batch 64, atau 8 untuk transformer. RAM model adalah kenaikan resident set size setelah model dimuat. Sampel teks diambil acak dari unified test set dan sama untuk semua model: 30 dokumen latency dan 48 dokumen throughput untuk teacher dan transformer, serta 500 dan 3,000 untuk model ringan. Semua model diukur dalam satu sesi pada mesin yang idle. StaticKD membaca sampai 1,024 token per artikel sementara teacher berhenti di 512, jadi perbandingan kecepatan ini tidak menguntungkan StaticKD.

Mesinnya laptop dengan Intel Core Ultra 7 155H, RAM 31 GB, dan Windows 11. CPU ini hybrid: 6 P-core, 8 E-core yang lebih lambat, dan 2 low-power E-core. Tanpa pinning, sistem operasi memindahkan thread ke core yang lambat. Karena itu setiap proses di-pin ke P-core fisik (logical CPU 0 untuk satu core; logical CPU 0, 10, 12, dan 14 untuk empat core), yang mendekati server kecil dengan core seragam.

Desain eksperimen dan detail implementasi

Tabel VIII mencantumkan seluruh 72 run StaticKD. Setiap varian ablasi mengubah satu faktor dari resep final: hard label alih-alih soft label; hanya data EMMediaTopic (4 bahasa, 10 epoch); 130 ribu dokumen tanpa data CC-News tambahan; inisialisasi acak dengan standar deviasi yang sama dengan potion; embedding beku; tanpa token dropout; kepala multilayer perceptron (MLP) 512 unit; dan tau dalam {0.5, 2, 4}. Empat varian eksplorasi juga diuji: bigram hashing (2^21 bucket), pooling berbobot idf^0.5, bobot dokumen dari confidence teacher, dan suku cross-entropy tambahan pada label GPT-4o. Satu run StaticKD rata-rata butuh 5.2 menit di GPU yang sama. Implementasinya memakai Python 3.12, NumPy 2.5, PyTorch 2.6, transformers 5.17, tokenizers 0.23, ONNX Runtime 1.30, scikit-learn 1.9, dan fastText 0.9.2. Seed, versi library, dan riwayat training setiap run disimpan bersama modelnya.

IV. Hasil

Tabel IV — Hasil utama: macro-F1 [95% CI] dan akurasi di development set (EMMediaTopic dev, label GPT-4o), agreement dengan teacher di held-out CC-News, dan hasil di unified test set (47 bahasa, label independen). CI uji dari site-cluster bootstrap. *(isi tabel: lihat PDF bahasa Inggris)*

Akurasi semua model (RQ2)

Tabel IV memuat hasil utama. Di unified test set, teacher mencapai macro-F1 0.598 [0.546-0.643] dan akurasi 0.700. Angka ini jauh di bawah skor development-nya (0.822), karena test set mencakup bahasa, sumber, dan periode waktu yang belum pernah dilihat teacher. StaticKD mencapai macro-F1 0.545 [0.490-0.605] dan akurasi 0.641, yaitu 91.1% dari macro-F1 teacher. Di development set, StaticKD mempertahankan 92.6% macro-F1 teacher (0.761 vs 0.822), dan agreement-nya dengan teacher di 63 bahasa held-out adalah 0.811. Satu student tanpa ensemble mencapai 0.542 ± 0.004 di test set dan 0.755 ± 0.010 di development set (10 seed).

Di antara transformer kecil hasil distilasi, MiniLM-L6 (0.566), yang berawal dari distilasi XLM-R-large, berada di antara StaticKD dan teacher. DistilmBERT (0.534) setara (on par) dengan StaticKD padahal jauh lebih mahal. Dua baseline berbiaya serupa, fastText + KD dan TF-IDF + SVM + KD, berada di bawah StaticKD. fastText yang hanya dilatih pada label GPT-4o dari empat bahasa gagal di luar bahasa training-nya: macro-F1 uji 0.086, padahal 0.665 di development set.

Tabel V — Uji berpasangan StaticKD terhadap model lain (delta = StaticKD dikurangi model pembanding; p dikoreksi Holm di dalam tiap set; b/c = dokumen yang benar hanya untuk StaticKD / hanya untuk model pembanding). *(isi tabel: lihat PDF bahasa Inggris)*

Tabel V melaporkan uji berpasangan dengan delta = StaticKD dikurangi model pembanding, di test set. Terhadap teacher, selisih macro-F1 -0.053 [-0.065, -0.033] ($p < 0.001$); terhadap MiniLM-L6, -0.021 [-0.038, -0.008] (p 0.004). Selisih terhadap DistilmBERT, +0.010 [-0.026, +0.041], tidak signifikan (p 0.800). StaticKD benar pada lebih banyak dokumen uji daripada DistilmBERT (McNemar $p < 0.001$), tetapi uji McNemar menganggap dokumen independen dan mengabaikan dependensi antarartikel dari situs yang sama. StaticKD mengungguli fastText + KD terkuantisasi sebesar +0.110 [+0.042, +0.151] ($p < 0.001$) dan TF-IDF + SVM sebesar +0.059 [+0.009, +0.093] (p 0.030).

Kekuatan dua keunggulan itu berbeda bila dilihat per bahasa. Terhadap fastText + KD, macro-F1 StaticKD lebih tinggi di 43 dari 47 bahasa (Wilcoxon $p < 0.001$) dan akurasinya lebih tinggi di 41 (Wilcoxon $p < 0.001$). Terhadap TF-IDF + SVM, macro-F1-nya lebih tinggi di 31 dari 47 bahasa (Wilcoxon p 0.003), tetapi akurasinya hanya lebih tinggi di 24 dan lebih rendah di 22 (Wilcoxon p 0.127). Jadi keunggulan atas TF-IDF + SVM konsisten antarbahasa pada metrik utama, sedangkan akurasi per bahasa kedua model berdekatan. Terhadap DistilmBERT, tidak ada metrik yang berbeda secara konsisten antarbahasa (Wilcoxon p 0.604 untuk macro-F1 dan 0.322 untuk akurasi). StaticKD hanya mengalahkan teacher di 7 dari 47 bahasa (Wilcoxon $p < 0.001$).

Menurut asal label (Tabel VI, Gambar 3), StaticKD mempertahankan 95.8% skor teacher pada artikel berlabel rubrik JSON-LD, 89.5% pada kategori penerbit, dan 89.6% pada anotasi manusia. Menurut data distilasi bahasanya, StaticKD mempertahankan 97.5% di bahasa dengan data cukup, 89.1% di bahasa dengan data sedikit, dan 72.3% di bahasa tanpa data distilasi sama sekali. Pada subset dengan paling banyak lima artikel per situs dan sel (8,139 artikel), urutan model tidak berubah dibanding test set penuh (StaticKD 0.587, teacher 0.627).

Tabel VI — Macro-F1 uji per subgrup. Kolom terakhir: macro-F1 StaticKD sebagai persentase macro-F1 teacher di subgrup yang sama. *(isi tabel: lihat PDF bahasa Inggris)*

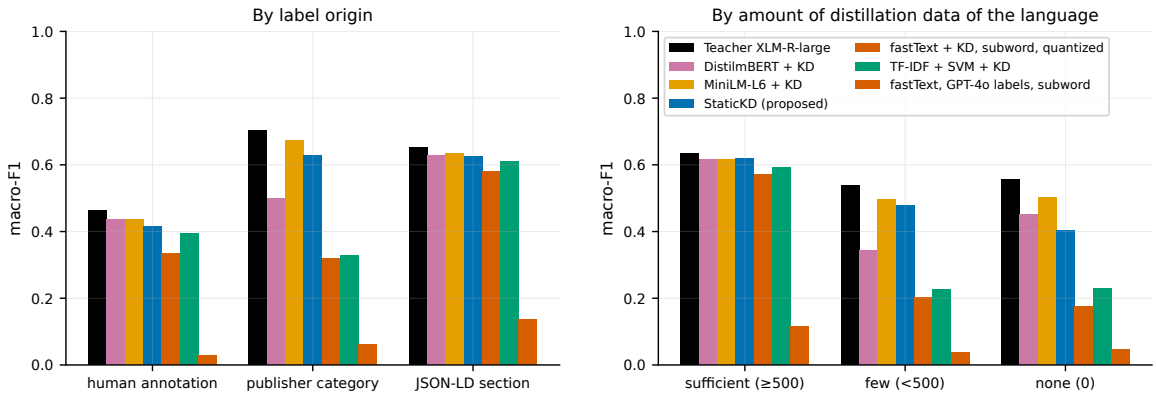
Tabel VII memecah test set menurut sumber. Di MN-DS, satu-satunya sumber yang dianotasi langsung dengan topik IPTC, StaticKD mempertahankan 97.4% skor teacher (0.535 vs 0.549), dan teacher sendiri mendapat macro-F1 terendahnya di sana dibanding sumber lain. Retensi terendah ada di MasakhaNEWS (80.0%), yang label manusianya memakai skema non-IPTC dan sebagian besar bahasa Afrikanya tidak ada di data distilasi. Bahasa Bangla juga tidak ada di data distilasi. Pada berita Bangla, fastText + KD dan TF-IDF + SVM jatuh ke 0.150 dan 0.010, sedangkan StaticKD mencapai 0.748. Selisih ini memperlihatkan transfer lintas bahasa yang tidak dimiliki baseline tanpa embedding pra-latih.

Tabel VII — Macro-F1 uji per sumber unified test set. MN-DS satu-satunya sumber yang dianotasi langsung dengan topik IPTC; MasakhaNEWS dianotasi manusia dengan skemanya sendiri. Kolom terakhir: StaticKD sebagai persentase teacher. *(isi tabel: lihat PDF bahasa Inggris)*

Validitas label editorial

Label rubrik dan kategori mencatat keputusan redaksi, jadi pertanyaannya: apakah label itu sejalan dengan label manusia dalam bahasa yang sama?

Semua sel bahasa Inggris di test set sudah diisi sumber berlabel manusia. Karena itu, sebagai pembanding dalam bahasa yang sama, diambil sampel terpisah berisi 754 artikel CC-NEWS bahasa Inggris berlabel rubrik JSON-LD dari 306 situs di luar test set, paling banyak 50 per label. Teacher mencapai akurasi 0.646 pada label rubrik (macro-F1 0.617) dan 0.559 pada label manusia MN-DS dan MasakhaNEWS (macro-F1 0.565). Akurasi pada label rubrik lebih tinggi untuk 12 dari 17 label (Wilcoxon p 0.033), dan urutan tingkat



Gambar 2: Gambar 3. Macro-F1 uji menurut asal label (kiri) dan menurut jumlah data distilasi di bahasa artikel (kanan).

kesulitan label berkorelasi antara kedua jenis label (rho = 0.63, p 0.007). Label yang sulit, yaitu society, human interest, dan religion, sulit di kedua jenis label.

Bahasa Prancis memberi perbandingan kedua di dalam test set: teacher mencapai akurasi 0.716 pada 208 artikel berlabel rubrik dan 0.500 pada 200 artikel MasakhaNEWS berlabel manusia.

Pemeriksaan terakhir melihat tiap kategori sumber, dibatasi pada bahasa yang tercakup pre-training XLM-R. Median agreement teacher dengan label hasil pemetaan per kategori adalah 0.46 untuk MasakhaNEWS, 0.50 untuk MN-DS, 0.81 untuk L3Cube, dan 0.87 untuk rubrik CC-NEWS. Agreement terendah terjadi pada kategori sumber yang lebih luas daripada target IPTC-nya; misalnya hanya 0.45 artikel politics MasakhaNEWS yang diprediksi politics, dengan conflict (29%) sebagai alternatif utama. Agreement juga rendah untuk label yang batasnya tidak jelas bahkan bagi anotator manusia, seperti society di MN-DS, sejalan dengan rendahnya inter-annotator agreement yang dilaporkan untuk label itu [2]. Ketidakcocokan seperti ini mencerminkan perbedaan skema kategori sumber dengan IPTC. Karena semua model dinilai terhadap label yang sama, perbandingan antarmodel tidak terpengaruh, dan skor absolut dibaca sebagai kesesuaian dengan kategorisasi editorial.

> **Tabel VIII** — Ablasi, temperature, dan varian eksplorasi (satu student, tanpa ensemble). Rata-rata ± standar deviasi antar-seed; tanda bintang: berbeda dari resep final (Welch, Holm, p < 0.05). *(isi tabel: lihat PDF bahasa Inggris)*
>
> **Tabel IX** — Macro-F1 varian terpilih menurut jumlah data distilasi di bahasa artikel (test set; rata-rata antar-seed). *(isi tabel: lihat PDF bahasa Inggris)*

Ablasi, temperature, dan ensemble (RQ3)

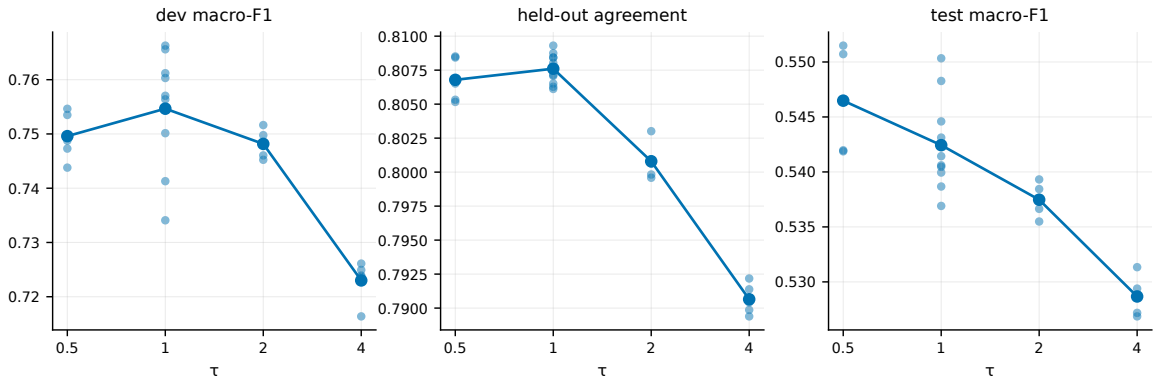
Tabel VIII memberi kontribusi tiap komponen dengan lima seed per varian. Data distilasi multibahasa paling berpengaruh: distilasi hanya dengan EMMediaTopic (4 bahasa) menurunkan macro-F1 uji sebesar -0.051 dan held-out agreement sebesar -0.077. Inisialisasi acak mengubah macro-F1 uji sebesar -0.120 (p < 0.001), jadi embedding yang selaras lintas bahasa menyumbang porsi besar akurasi.

Membekukan embedding dan hanya melatih kepala linear di atas potion menurunkan skor development sebesar -0.035 (p < 0.001) dan held-out agreement sebesar -0.020 (p < 0.001). Di test set, varian yang sama justru menaikkan macro-F1 sebesar +0.014 (p < 0.001). Tabel IX menunjukkan kenaikan ini berasal dari bahasa dengan data distilasi sedikit (+0.059) dan tanpa data (+0.037). Di bahasa yang datanya banyak, embedding beku lebih lemah (-0.007).

Hard label dari teacher mengubah macro-F1 uji sebesar +0.005 (p 0.433) dan skor development sebesar -0.006 (p 1.000), jadi tidak berbeda dari soft label. Mengurangi data menjadi 130 ribu dokumen mengubah macro-F1 uji sebesar -0.002 (p 1.000), menghapus token dropout +0.001 (p 1.000), dan kepala MLP yang tidak bisa dilipat +0.009 (p 0.281).

Gambar 4 menunjukkan efek temperature. Dibanding tau=1, pilihan umum tau=2 [9] menurunkan held-out agreement sebesar -0.007 (p < 0.001); perubahannya di macro-F1 uji (-0.005, p 0.059) dan di development set (-0.006, p 0.705) tidak signifikan. Dengan tau=4, ketiga metrik turun, dan di test set penurunannya -0.014 (p < 0.001). Tidak satu pun dari empat varian eksplorasi memperbaiki test set: bigram hashing +0.002, idf pooling -0.001, bobot confidence +0.000, dan cross-entropy pada label GPT-4o -0.004.

Memperbesar ensemble dari satu ke tiga seed menggeser macro-F1 uji dari 0.542 ke 0.544 dan held-out agreement dari 0.808 ke 0.810 (Gambar 5); sepuluh seed memberi 0.546. Kenaikannya kecil, tetapi tanpa biaya saat inference karena berapa pun ukuran ensemble-nya tetap satu tabel.



Gambar 3: Gambar 4. Efek temperature distilasi. Tiap titik adalah satu seed; garis menghubungkan rata-ratanya.

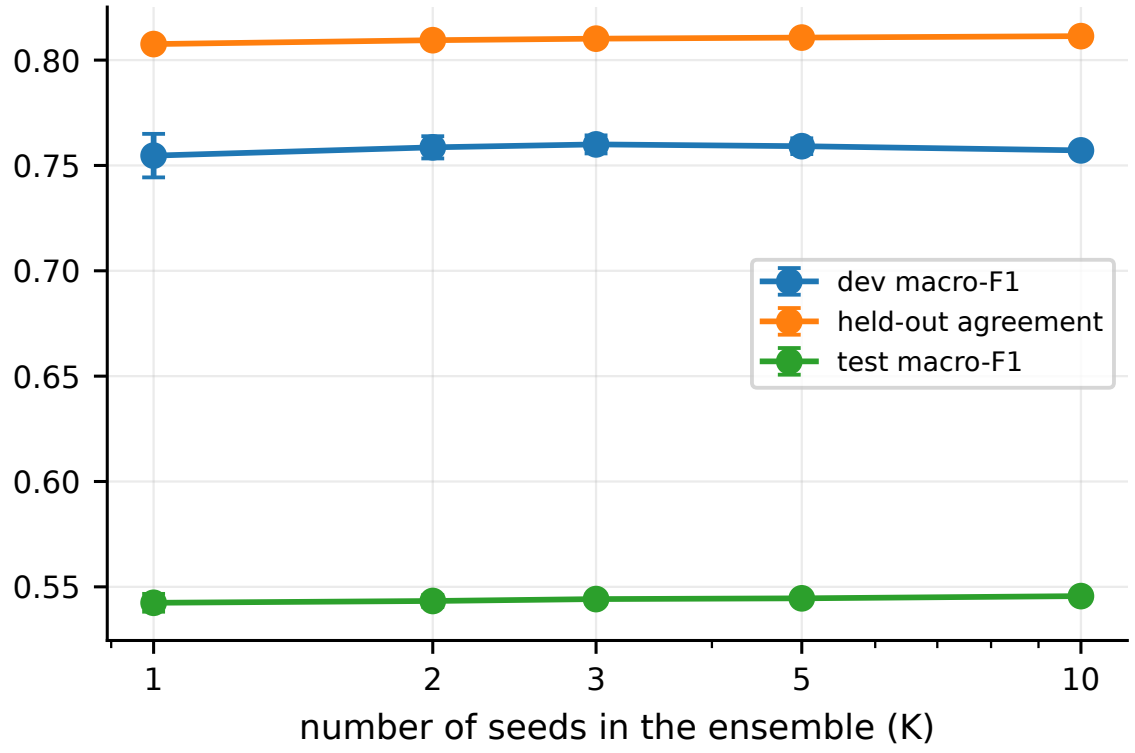
Tabel X — Efisiensi CPU (P-core di-pin; sampel dari unified test set; 1c/4c = 1/4 core). *(isi tabel: lihat PDF bahasa Inggris)*

Efisiensi CPU (RQ1)

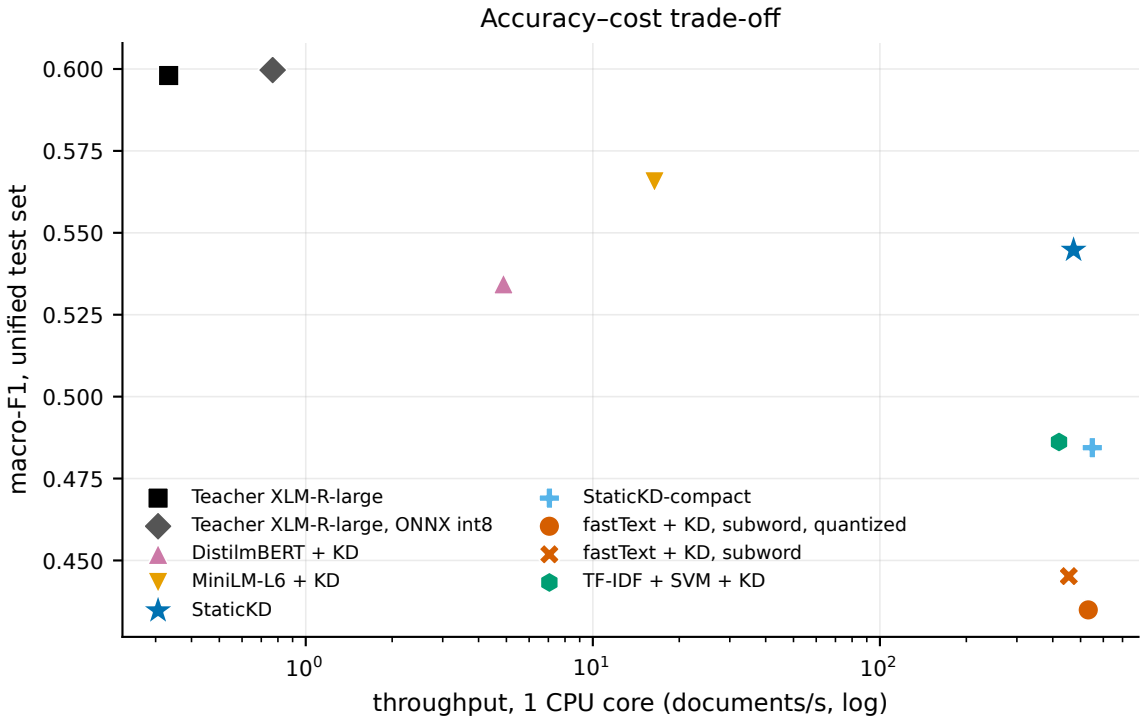
Tabel X serta Gambar 6 dan Gambar 7 menunjukkan efisiensi semua model. Dengan PyTorch fp32, teacher butuh 2,971 ms per artikel di satu core, dengan throughput 0.33 artikel per detik. Konfigurasi CPU terbaiknya, ONNX int8, butuh 1,239 ms dengan throughput 0.77 artikel per detik. Mengklasifikasi satu juta artikel per hari akan butuh 15.1 core (ONNX int8) sampai 34.8 core (PyTorch) hanya untuk langkah ini.

StaticKD butuh 2.03 ms per artikel dan memproses 473 artikel per detik per core: sekitar 616 kali lebih cepat daripada teacher ONNX int8, 1,420 kali lebih cepat daripada teacher PyTorch, dan 29 kali lebih cepat daripada MiniLM-L6. Ukuran file-nya 16 kali lebih kecil daripada teacher ONNX int8, dan satu juta artikel per hari hanya butuh 0.02 core. RAM modelnya 501 MB, sebagian besar untuk struktur tokenizer; varian compact menurunkannya ke 277 MB. Dengan satu thread, tokenisasi (rata-rata 579 token per artikel) memakan 98% waktu prediksi, sementara pooling tabel saja berjalan 28,755 artikel per detik. Jadi batas kecepatan StaticKD ditentukan oleh implementasi tokenizer.

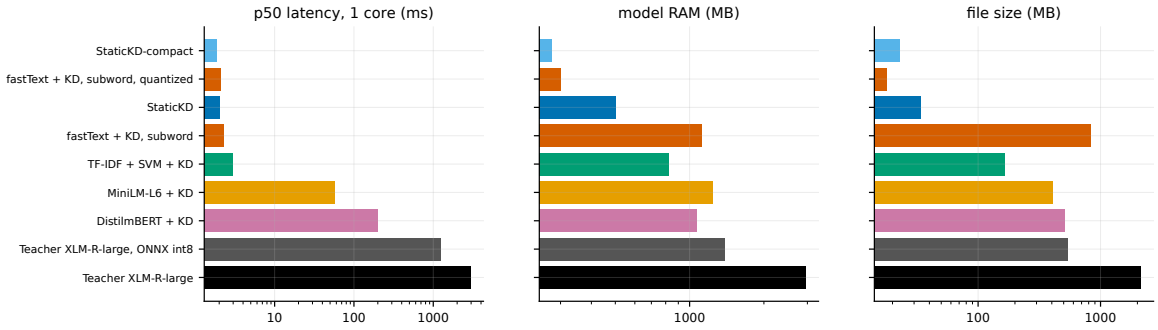
StaticKD bukan model tercepat di tabel. fastText + KD terkuantisasi sedikit lebih cepat (532 artikel per detik), lebih kecil (18 MB), dan memakai RAM lebih sedikit (300 MB), tetapi macro-F1 ujinya 0.435 dibanding 0.545 untuk StaticKD. Di antara model dengan latency sebanding (StaticKD, varian compact-nya, fastText, dan TF-IDF + SVM), StaticKD paling akurat (Gambar 6).



Gambar 4: Gambar 5. Efek ukuran ensemble tabel (rata-rata ± standar deviasi antar-kombinasi seed).



Gambar 5: Gambar 6. Macro-F1 uji di unified test set terhadap throughput CPU satu core (skala log).



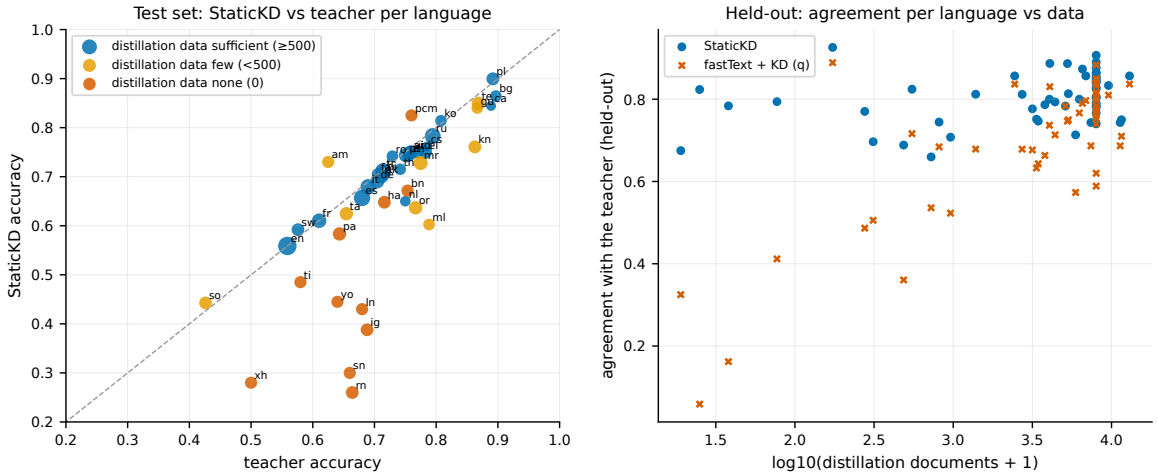
Gambar 6: Gambar 7. Latency per artikel, RAM model, dan ukuran file (skala log).

Tabel XI — Faktor-faktor di balik kinerja per bahasa. *(isi tabel: lihat PDF bahasa Inggris)*

Analisis per bahasa dan label (RQ4)

Median selisih akurasi per bahasa antara StaticKD dan teacher adalah -0.024 (Gambar 8). Di held-out set (53 bahasa dengan minimal 20 dokumen), agreement StaticKD berkorelasi dengan log jumlah data distilasi (rho = 0.31, p 0.022) dan dengan confidence teacher (rho = 0.71, p < 0.001), tetapi tidak berbeda antaraksara (Kruskal-Wallis H = 10.37, p 0.065; Tabel XI). Pada bahasa di luar pre-training XLM-R yang juga tidak ada di data distilasi (ig, lg, ln, pcm, rn, sn, ti, yo), rata-rata akurasi StaticKD hanya 0.407, sedangkan teacher 0.643.

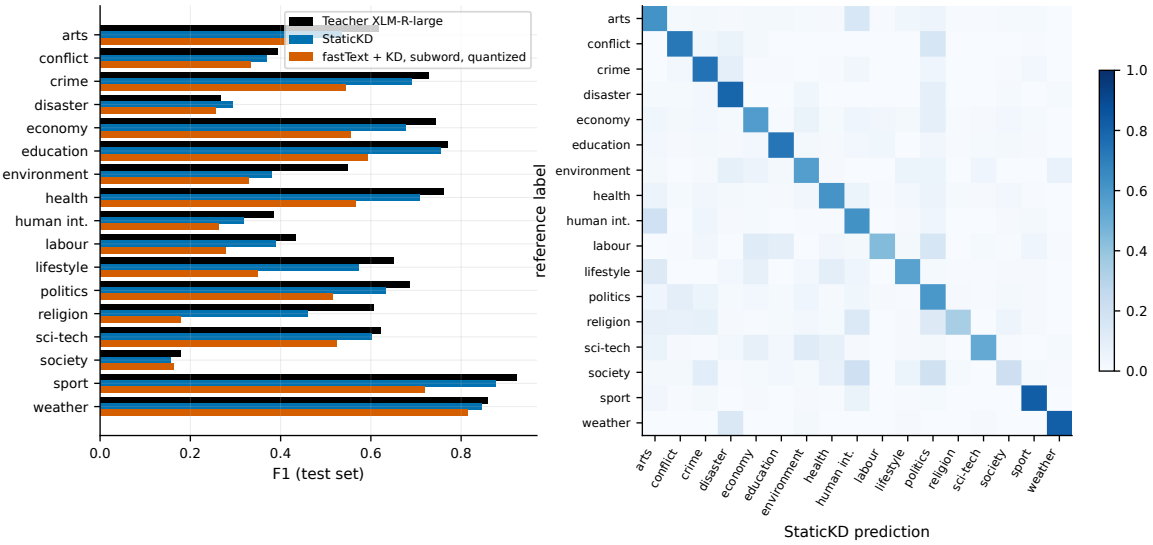
Di 4 bahasa (bn, ml, or, pa), kurang dari separuh kemunculan token berasal dari token yang muncul minimal 10 kali di data distilasi (paling banyak 32%). StaticKD tetap mencapai rata-rata akurasi 0.624 di bahasa-bahasa ini (teacher 0.738). Varian compact membuang token-token itu dari tokenizer, dan akurasinya di bahasa ini jatuh ke 0.013. Di bahasa lainnya, varian compact mencapai 0.578 dibanding 0.640 untuk StaticKD penuh. Bagian V membahas mekanisme di balik pola ini.



Gambar 7: Gambar 8. Kiri: akurasi StaticKD terhadap akurasi teacher per bahasa uji (warna = data distilasi bahasa, ukuran = jumlah artikel). Kanan: held-out agreement per bahasa terhadap jumlah data distilasi, untuk StaticKD dan fastText + KD.

Per label (Gambar 9), label tersulit bagi StaticKD adalah society (0.16), disaster (0.29), human interest (0.32), dan conflict (0.37); yang termudah sport (0.88), weather (0.84), dan education (0.75). Selisih ter-

besar terhadap teacher ada pada environment (-0.17), religion (-0.15), dan arts (-0.08), dan kebingungan paling sering adalah society -> human interest (20%), human interest -> arts (20%), dan society -> politics (20%).



Gambar 8: Gambar 9. F1 per label di test set (kiri) dan confusion matrix StaticKD yang dinormalisasi per label referensi (kanan).

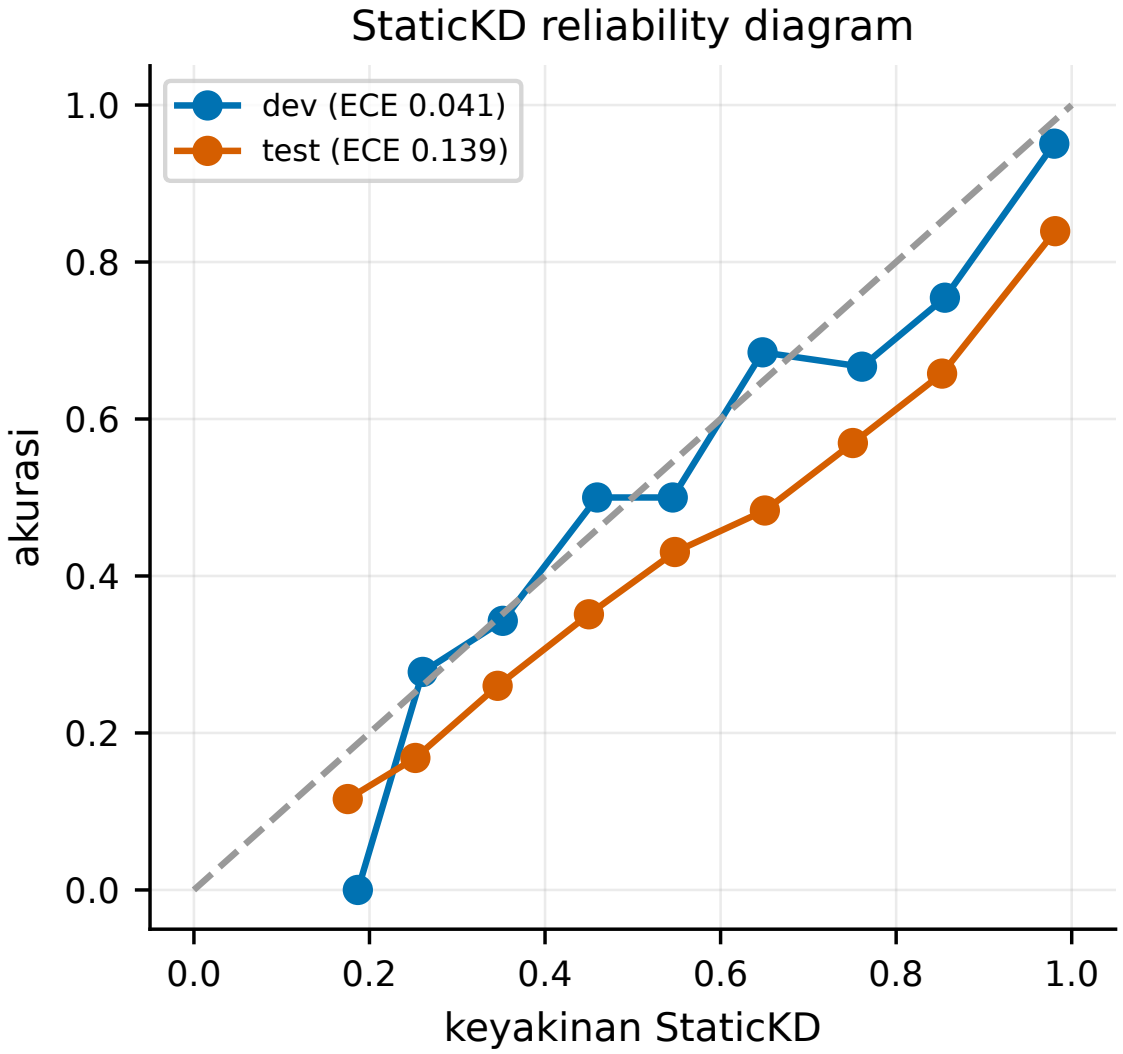
Tabel XII — Cascade StaticKD ke teacher ONNX int8 di test set (throughput efektif satu core).
(isi tabel: lihat PDF bahasa Inggris)

Kalibrasi dan mode cascade

ECE StaticKD 0.041 di development set dan 0.139 di test set, lebih rendah daripada teacher (0.090 dan 0.245). Kedua model menjadi overconfident di test set, yang berada di luar distribusi training (Gambar 10). Dalam mode cascade, StaticKD memutuskan artikel yang confidence-nya minimal theta dan mengirim sisanya ke teacher (Tabel XII). Dengan theta = 0.8, StaticKD memutuskan 60.3% artikel dengan akurasi 0.813. Cascade mencapai akurasi keseluruhan 0.703 dan macro-F1 0.602, dibanding 0.699 dan 0.600 untuk teacher saja, dengan throughput efektif 1.92 artikel per detik per core dibanding 0.77. Mengirim sekitar dua per lima artikel ke teacher sudah cukup agar cascade menyamai akurasi teacher.

V. Pembahasan

StaticKD mempertahankan 91.1% macro-F1 teacher di unified test set dan 92.6% di development set, dengan biaya inference dua sampai tiga orde besaran lebih rendah (616 kali terhadap ONNX int8 dan 1,420 kali terhadap PyTorch). Ini sejalan dengan temuan bahwa representasi tanpa urutan kata (order-free) sudah kompetitif untuk klasifikasi topik [13]. Nama institusi, istilah olahraga, dan kosakata medis membawa sebagian besar sinyal topik. Selisih yang tersisa terkumpul di dua tempat. Pertama, label yang kosakatanya tumpang tindih dengan topik lain: selisih terbesar terhadap teacher ada pada environment (-0.17), religion (-0.15), dan arts (-0.08); label tersulit bagi StaticKD (dengan F1-nya) adalah society (0.16), disaster (0.29), human interest (0.32), dan conflict (0.37), yang juga termasuk tersulit bagi teacher; society dan human interest diketahui sulit juga bagi anotator manusia [2]. Kedua, bahasa yang kurang terwakili di data distilasi: StaticKD mencapai 97.5% skor teacher di bahasa dengan data distilasi cukup, tetapi hanya 72.3% di bahasa tanpa data.



Gambar 9: Gambar 10. Reliability diagram StaticKD di development set dan test set.

Dengan data distilasi yang sama, MiniLM-L6 menutup sebagian selisih ini (StaticKD dikurangi MiniLM -0.021, p 0.004), sedangkan DistilmBERT tidak (+0.010, p 0.800). Keduanya satu sampai dua orde besaran lebih mahal daripada StaticKD. MiniLM berasal dari distilasi XLM-R-large dan DistilmBERT dari mBERT, yang mengisyaratkan bahwa kualitas representasi multibahasa awal lebih menentukan daripada jumlah layer.

Ablasi menunjukkan dari mana pengetahuan student berasal (RQ3). Sumber terbesar adalah data distilasi multibahasa yang dilabeli teacher: tanpanya macro-F1 uji turun -0.051, sejalan dengan Sparse Distillation [22] yang juga bergantung pada transfer set besar. Berikutnya inisialisasi yang selaras lintas bahasa, dan varian compact memberi bukti paling langsung untuk ini. Di bahasa India yang hampir tidak ada di data distilasi (misalnya bn, pa, or), sebagian besar token tidak pernah di-update saat training dan tetap memakai embedding awal potion. StaticKD masih mengklasifikasi bahasa-bahasa ini dengan rata-rata akurasi 0.624, tetapi akurasinya jatuh ke 0.013 begitu pemangkasan tokenizer membuang token-token itu. Jadi transfer ke bahasa tanpa data dibawa oleh baris embedding yang tidak pernah dilatih tetapi berada di ruang yang sama dengan baris yang dilatih, sehingga kepala linear yang dipelajari dari bahasa kaya data juga berlaku untuknya.

Ablasi embedding beku memperlihatkan sisi lain dari mekanisme yang sama. Fine-tuning menggeser embedding token dari bahasa yang ada di data distilasi dan memperbaiki kecocokan in-distribution; membekukannya menurunkan skor development -0.035. Token bahasa lain tetap di ruang potion asli, di mana kepala yang sudah menyesuaikan diri dengan ruang yang bergeser kurang cocok untuknya. Di bahasa tanpa data atau dengan data distilasi sedikit, embedding beku lebih baik +0.037 dan +0.059. Ini adalah representation drift akibat fine-tuning sebagian vocabulary. Resep final tetap memakai fine-tuning karena resep dipilih pada development set dalam bahasa training. Untuk deployment yang menyasar bahasa tanpa data distilasi, embedding beku atau regularizer yang menjaga embedding dekat dengan potion adalah pilihan yang lebih aman, dan keduanya tetap bisa dilipat ke tabel.

Sebaliknya, soft label hampir tidak menambah apa-apa. Hard label dari teacher tidak berbeda signifikan dari soft label pada tau=1 (development -0.006, uji +0.005). Menaikkan temperature ke tau=2 menurunkan held-out agreement tanpa perubahan signifikan di test set, dan tau=4 menurunkan semua metrik. Pola ini sejalan dengan literatur capacity gap [24] [27]. Penjelasan yang masuk akal: satu layer linear di atas embedding rata-rata tidak mampu merepresentasikan struktur antarkelas di ekor distribusi teacher (dark knowledge) [26]. Distribusi yang tajam (tau=1) atau hard label memberi target yang bisa dicapai, sedangkan tau tinggi meminta student meniru bentuk distribusi di luar kapasitasnya. Untuk student berkapasitas sangat rendah, usaha lebih baik dicurahkan pada cakupan transfer set (bahasa, situs, topik) dan inisialisasi yang selaras daripada membentuk soft label.

Kinerja per bahasa terutama ditentukan oleh seberapa baik bahasa itu terwakili di data distilasi dan data pre-training, bukan oleh aksaranya (Kruskal-Wallis p 0.065). Bahasa terlemah adalah bahasa Afrika di luar pre-training XLM-R yang juga tidak ada di data distilasi (ig, lg, ln, pcm, rn, sn, ti, yo). Teacher masih mencapai akurasi 0.643 di bahasa-bahasa ini, mungkin berkat subword yang dibagi dengan bahasa lain dan konteks kalimat, sedangkan StaticKD hanya 0.407. Perbaikan termurah tidak butuh perubahan arsitektur: berita dalam bahasa-bahasa ini cukup ditambahkan ke transfer set dan dilabeli teacher. Ablasi data dan korelasi antara agreement dan jumlah data (rho = 0.31) mendukung langkah ini.

Beberapa varian menggeser agreement dengan teacher dan akurasi pada label editorial ke arah berlawanan. Embedding beku menurunkan held-out agreement (-0.020) tetapi menaikkan macro-F1 uji (+0.014). Memangkas data menjadi 130 ribu dokumen menurunkan agreement (-0.009) tanpa perubahan signifikan di test set (-0.002). Sejalan dengan [28], student sebaiknya dipilih dengan label yang tidak berasal dari teacher dan data uji di luar distribusi training, bukan hanya dengan fidelity.

Skor uji sebaiknya dibaca sesuai sifat labelnya. Dua pertiga label adalah topik editorial, yaitu tempat redak-

si menaruh artikel, diterjemahkan ke IPTC. Artikel tentang kasus kriminal yang melibatkan atlet bisa saja dengan benar ditaruh di rubrik olahraga, sementara model melabelinya crime; kedua jawaban masuk akal menurut IPTC, yang memperbolehkan beberapa topik per artikel. Jadi skor absolut pada label editorial mengukur kesesuaian dengan kategorisasi penerbit. Perbandingan antarmodel tetap adil karena semua model dinilai terhadap label yang sama, dan urutan model tidak berubah pada subset dengan jumlah per situs dibatasi.

Dibanding Sparse Distillation [22], StaticKD mengganti tabel n-gram yang dilatih dari nol dengan embedding multibahasa pra-latih yang dilipat menjadi 17 logit per token; modelnya jadi jauh lebih kecil dan bisa transfer ke bahasa yang tidak ada di transfer set. Inference adalah biaya berulang dalam pipeline berita karena setiap artikel yang masuk diklasifikasi; satu juta artikel per hari butuh 15.1 core dengan teacher ONNX int8 dibanding 0.02 dengan StaticKD (Bagian IV-D). Kuantisasi int8 pada teacher hanya memberi percepatan dengan faktor konstan.

Untuk pipeline real-time di server tanpa GPU, StaticKD memproses satu juta artikel per hari dengan 0.02 core, file 34 MB, dan hanya bergantung pada numpy dan tokenizers. Probabilitasnya lebih terkalibrasi daripada teacher (ECE uji 0.139 vs 0.245), sehingga mode cascade bisa dipakai. Dengan theta = 0.8, akurasi cascade (0.703) setara teacher saja (0.699) pada 1.92 artikel per detik per core, dibanding 0.77 untuk teacher saja. Mode ini cocok untuk batch job yang butuh akurasi setingkat teacher. Varian compact menurunkan RAM, tetapi hanya disarankan bila semua bahasa target tercakup data distilasi.

VI. Keterbatasan

Dari artikel uji, 47.5% berlabel rubrik JSON-LD dan 20.4% kategori penerbit. Label-label ini adalah topik editorial. Konvensi rubrik berbeda antarpenerbit, dan satu rubrik hanya mencerminkan satu sudut pandang redaksi atas artikel yang bisa mencakup beberapa topik. Tabel pemetaannya konservatif, divalidasi terhadap pohon IPTC, dan ditinjau penulis pertama, tetapi artikelnya tidak dianotasi ulang oleh manusia. Karena itu skor absolut pada label ini mengukur kesesuaian dengan kategorisasi penerbit, terutama untuk label yang batasnya tidak jelas (society, human interest, lifestyle).

Label MasakhaNEWS diberikan anotator manusia dengan skema mereka sendiri, lalu dipetakan ke IPTC. Hanya MN-DS yang dianotasi langsung dengan topik IPTC, dan hanya bahasa Inggris. Test set IPTC multibahasa milik Kuzman dan Ljubešić [2] tidak publik, sehingga tidak tersedia untuk studi ini.

Cakupan label per bahasa tidak merata, dengan median 7 label per bahasa, dan bahasa Afrika hanya mencakup empat atau lima topik luas. Macro-F1 dihitung atas label yang ada, jadi skor per bahasa tidak bisa dibandingkan langsung antarbahasa dengan cakupan label berbeda. Keragaman penerbit juga terbatas untuk sebagian bahasa: 27 bahasa praktis hanya dari satu penerbit, yaitu BBC/VOA untuk bahasa Afrika, L3Cube untuk bahasa India, dan satu situs untuk beberapa bahasa CC-NEWS. Klaim untuk bahasa-bahasa ini terbatas pada penerbit tersebut, dan site-cluster bootstrap melebarkan confidence interval-nya sesuai keadaan itu.

Teacher menjadi batas atas bagi student, dan kesalahan serta biasnya ikut tersalin. Fidelity set mengukur kemiripan dengan teacher, bukan kebenaran.

Hyperparameter fastText dan TF-IDF + SVM ditetapkan sekali tanpa pencarian, sedangkan resep StaticKD dipilih dari 72 run pada development set. Budget tuning yang tidak setara ini bisa memperlebar selisih akurasi terhadap kedua baseline itu. Trainer classifier dari library Model2Vec tidak dijalankan sebagai baseline; hanya komponennya yang diuji terpisah sebagai ablasi. MiniLM-L6 dan DistilmBERT dilatih dan dievaluasi dengan paling banyak 256 token, sehingga hanya melihat kurang dari separuh sebagian besar artikel uji, dan akurasinya mungkin terlalu rendah (underestimated).

Benchmark dijalankan di satu mesin dalam satu sesi, dengan 30 dokumen latency untuk teacher dan transformer. Angka absolut di server akan berbeda, dan sampel latency model berat kecil, tetapi rasio antarmodel yang diukur dengan protokol yang sama tetap informatif.

StaticKD jauh kurang akurat pada bahasa Afrika yang tidak ada di data distilasi maupun pre-training (Bagian V). Bila dipakai sebagai filter topik, StaticKD bisa lebih sering salah mengklasifikasi atau membuang berita dalam bahasa-bahasa ini. Sebelum deployment, akurasi perlu dipantau per bahasa, dan artikel dengan confidence rendah perlu dialihkan ke teacher lewat mode cascade.

Studi ini hanya mencakup label IPTC level atas dan klasifikasi single-label. Level yang lebih dalam dan artikel multi-topik belum diuji.

VII. Kesimpulan

Studi ini mengukur biaya CPU classifier IPTC multibahasa terbuka dan menunjukkan biaya itu bisa dipangkas dua sampai tiga orde besaran sambil mempertahankan sebagian besar akurasinya. StaticKD mendistill teacher XLM-R-large menjadi tabel 17 logit per token, diinisialisasi dari static embedding multibahasa dan dilatih pada 285,999 artikel berlabel teacher dalam 69 bahasa. Di unified test set berisi 12,744 artikel dalam 47 bahasa, dengan label yang tidak berasal dari teacher, StaticKD mencapai macro-F1 0.545, atau 91.1% dari teacher. StaticKD memproses 473 artikel per detik per core CPU, sekitar 616 kali kecepatan teacher ONNX int8, dengan model 34 MB yang tidak butuh library deep learning.

Akurasi student berkapasitas sangat rendah ini terutama berasal dari transfer set multibahasa dan embedding yang selaras lintas bahasa. Soft label tidak lebih baik daripada hard label, tau=4 menurunkan semua metrik, dan ensemble seed bisa dilipat ke satu tabel tanpa biaya. Fine-tuning embedding menaikkan akurasi di bahasa yang ada di data distilasi tetapi menurunkannya di bahasa tanpa data distilasi, karena transfer ke bahasa itu dibawa oleh embedding pra-latih yang tidak pernah di-update. Test set ini, dengan label editorial yang dipetakan ke pohon IPTC, kontrol kontaminasi, dan site-cluster bootstrap, bisa dipakai ulang untuk mengevaluasi classifier IPTC lain.

Beberapa arah lanjutan: (a) transfer set diperluas ke bahasa yang lemah, terutama bahasa Afrika di luar pre-training XLM-R; (b) regularizer fine-tuning yang menjaga embedding dekat ruang pra-latih bisa memberi akurasi in-distribution sekaligus transfer lintas bahasa; (c) tokenisasi memakan 98% waktu inference, jadi tokenizer yang lebih cepat (misalnya lookup langsung kata ke tabel) adalah sumber kecepatan berikutnya; (d) pemangkasan vocabulary apa pun harus mempertahankan token lintas bahasa; (e) kepala non-linear murah dengan embedding terkuantisasi, klasifikasi hierarkis ke IPTC level 2, klasifikasi multilabel, dan anotasi IPTC manusia untuk sampel multibahasa test set masih terbuka.

Ketersediaan Kode, Model, dan Data

Kode untuk pengumpulan data, konstruksi test set, pelabelan teacher, training, evaluasi, dan benchmark, beserta notebook yang mereproduksi setiap angka, tabel, dan gambar di paper ini, tersedia di [TODO: URL GitHub dan DOI Zenodo]. Model StaticKD tersedia di [TODO: URL Hugging Face]. Test set dirilis sebagai manifest berisi URL atau ID artikel, label, asal label, dan hash teks, beserta skrip rekonstruksi. Teks artikel tidak didistribusikan ulang karena hak cipta penerbit dan lisensi dataset sumber. Tabel pemetaan rubrik ke IPTC dirilis bersama kode. EMMediaTopic tersedia di repositori CLARIN.SI [35]. Tabel XIII mencantumkan lisensi aset yang dipakai dan dirilis dalam studi ini.

Tabel XIII — Lisensi aset yang dipakai dan dirilis. *(isi tabel: lihat PDF bahasa Inggris)*

Ucapan Terima Kasih

Ucapan terima kasih kepada Departemen Teknik Informatika, Institut Teknologi Sepuluh Nopember, atas dukungannya. Pernyataan penggunaan AI: penulis memakai Claude (Anthropic) untuk membantu penulisan kode eksperimen, pengolahan data (termasuk draf pertama tabel pemetaan rubrik ke IPTC, yang seluruhnya ditinjau penulis), serta review dan penyuntingan minor naskah. Naskah ditulis oleh penulis, yang bertanggung jawab penuh atas isi dan klaimnya.