Rancangan Struktur Ulang Naskah StaticKD

Target: IEEE Access, maksimal 14 halaman

Disusun untuk Obi Kastanya dan Ananta Dwi Prayoga Alwy

1 November 2026

Isi dokumen. Bagian 1 merangkum penelitian, termasuk apa saja yang sudah dieksplorasi dan fakta di repositori yang tidak tertulis atau tertulis keliru di naskah. Bagian 2 mereview struktur dan isi naskah. Bagian 3 adalah struktur baru beserta peta paragraf lama ke baru dan anggaran halaman. Bagian 4 berisi aturan restrukturisasi. Rencana perubahan isi berdasarkan review skeptis ada di dokumen terpisah, `rencana_perubahan.tex`.
Acuan. Nomor baris `LN` mengacu ke `paper_final/main.tex` pada commit `b4bf5e6` (naskah sebelum restrukturisasi, 760 baris). Semua fakta di Bagian 1 sudah dicek ke kode, hasil, dan arsip.

1 Pemahaman penelitian

1.1 Inti penelitian

- **Masalah.** Pengklasifikasi IPTC multibahasa terbuka (Kuzman & Ljubešić, XLM-R-large, 559,9 juta parameter) butuh 1.239 ms (ONNX int8) sampai 2.971 ms (PyTorch) per artikel per core CPU. Untuk satu juta artikel per hari, ini berarti 15,1 sampai 34,8 core.
- **Metode.** *Teacher* melabeli 285.999 artikel dari 69 bahasa (CC-News 2019–2021 ditambah EMMediaTopic train). *Student* adalah rata-rata embedding statis potion (500.353 token $\times$ 256) yang diikuti satu layer linear, dilatih dengan KL ($\tau = 1$) dan *token dropout* 0,2. Kepala linear lalu dilipat menjadi tabel $|V| \times 17$. Model final adalah rata-rata tabel dari tiga seed: 34 MB, cukup dengan `numpy` dan `tokenizers`.
- **Evaluasi.** *Unified test set* berisi 12.744 artikel dari 47 bahasa: 47,5% rubrik JSON-LD CC-NEWS 2024–2026, 32,1% anotasi manusia (MasakhaNEWS, MN-DS), dan 20,4% kategori penerbit. Labelnya dipetakan ke IPTC lewat 916 aturan. Interval kepercayaan dihitung dengan *site-cluster bootstrap*.
- **Hasil utama.** Macro-F1 0,545 (91,1% dari teacher 0,598) dengan 473 dok/s per core, sekitar 616 kali lebih cepat dari teacher ONNX int8. StaticKD lebih baik daripada fastText+KD dan TF-IDF+SVM+KD, setara dengan DistilmBERT, dan di bawah MiniLM-L6.
- **Temuan ablasi.** Inisialisasi potion paling menentukan ($-0{,}120$ tanpa potion). Data multibahasa juga penting ($-0{,}051$). Hard label setara dengan soft label. Embedding beku lebih baik di test ($+0{,}014$) tetapi lebih buruk di dev ($-0{,}035$).

1.2 Riwayat eksplorasi

1. **Proposal awal: KD + LoRA.** LoRA kemudian dibuang karena hanya menurunkan biaya *training*, bukan biaya inferensi (`docs/RANCANGAN_PENELITIAN.md`).
2. **26–27 September 2026: StaticKD v1, lalu v2.** v1 memakai $\tau = 2$. v2 memakai $\tau = 1$ dan *ensemble* tiga seed, dipilih dari set dev, *held-out*, dan set cek LLM berisi 320 artikel berlabel Claude. Resep dibekukan di commit `45320d2`, sebelum test set dibangun.
3. **Varian yang dieksplorasi tetapi tidak dilaporkan:** lebih dari 20, antara lain maksimum 512 token, *learned token weights* (dev 0,742, lebih buruk), *label smoothing*, embedding hasil distilasi teacher sebagai pengganti potion, pemangkasan kosakata, MiniLM ONNX int8 (runtuh ke 0,633), serta trik saat inferensi (pemotongan input, bobot posisi, kalibrasi bias).
4. **Test set sebelumnya.** Ada *silver set* JSON-LD saja (5.456 artikel, maksimal 5 per situs) yang kemudian diganti *unified test set*.

5. **72 run final** (10 resep penuh, 10 varian × 5 seed, 4 tambahan × 3 seed). Run ini adalah *training ulang* dengan kode final, dijalankan setelah file test set ditulis. Resepnya sendiri sudah dibekukan sebelumnya.

1.3 Fakta di repositori yang berbeda dari naskah atau belum tertulis

Hal	Yang ditunjukkan repositori	Status di naskah
Review tabel pemetaan	`mapping_review.xlsx` hanya punya satu set kolom reviewer, berisi Obi Kastanya pada 17 Oktober 2026. Semua 916 baris diberi "ya". Dari 814 nama, 48 diterima otomatis, sehingga yang ditinjau manusia 868 baris. Tidak ada reviewer kedua dan tidak ada ukuran kesepakatan. **Pengguna menyatakan test set diperiksa dua peneliti.** Pemeriksaan kedua ini belum tercatat di repositori.	Bertentangan di dalam naskah: `L755` menulis "the authors", sedangkan `L67`, `L118`, `L197`, `L701` menulis "first author".
Verifikasi label per artikel	Tidak ada. `audit_sample.csv` (340 baris) memiliki kolom `human_label` yang masih kosong, dan sampelnya diambil dari *silver set* lama: 0 dari 340 artikel ada di *unified test set*.	Benar (`L701`: "not re-annotated").
Grid baseline	`tune_baselines.py` menyiapkan 41 konfigurasi, tetapi hanya 2 yang dijalankan, dan hasilnya tidak dipakai.	Pada dasarnya benar ("set once without a search"). Grid yang dihentikan tidak disebut.
τ transformer	Hanya MiniLM yang diuji dengan $\tau \in \{1, 2\}$, dan terpilih $\tau = 1$. DistilmBERT memakai $\tau = 1$ tanpa uji.	Kurang detail (`L323`).
Asal resep	Resep berasal dari eksplorasi lebih dari 20 varian (dev dan set cek LLM). 72 run adalah run ulang.	`L709` ("selected from 72 runs") tidak tepat.
Learned token weights	Sudah diuji di v1 dan hasilnya lebih buruk.	`L709` menyebutnya "not tested", yang keliru.
Uji signifikansi ablasi	Welch antara seed varian dan 10 seed resep final. Koreksi Holm per metrik mencakup 14 varian, termasuk 4 tambahan. Akurasi test tidak diuji.	Kurang detail.
Uji berpasangan di dev	Sudah dihitung tetapi tidak dilaporkan. Di dev, StaticKD tidak berbeda signifikan dari TF-IDF+SVM ($p = 1{,}000$) maupun fastText.	Tidak dilaporkan.
Struktur klaster	L3Cube menjadi satu klaster (2.361 artikel, 10 bahasa). `bbc.com` punya 2.394 artikel. Dua klaster terbesar mencakup 37,3% test set, dan jumlah klaster efektif hanya 13,8.	Tidak disebut. Penting untuk menafsirkan CI.
Prediksi per seed	Ada 256 file prediksi, termasuk semua 72 run untuk dev, *held-out*, dan test. Uji *paired cluster bootstrap* untuk tiap varian ablasi bisa dihitung tanpa *training* ulang.	–
Benchmark	Dijalankan satu kali. Latensi teacher diukur pada 30 dokumen. *Throughput cascade* dihitung dengan rumus, bukan diukur.	Sebagian disebut (`L711`).
Peran AI	Metode dan eksperimen v1/v2 dirancang dan dijalankan oleh Claude secara mandiri (`_archive/root_docs_v1/prompt_transcript.md`).	Pernyataan AI di `L755` hanya menyebut kode, analisis data, dan penyuntingan. **Perlu dilengkapi** (kebijakan IEEE).

Hal	Yang ditunjukkan repositori	Status di naskah
Hipotesis	Tidak ada hipotesis formal di naskah maupun di rancangan penelitian, padahal materi kuliah Metpen memintanya.	Tidak ada.

2 Review struktur dan isi

2.1 Masalah struktur

1. **Urutan RQ tidak sama dengan urutan Hasil dan Pembahasan.** Urutan RQ adalah akurasi, komponen, biaya, bahasa. Hasil memakai urutan akurasi, validitas, komponen, biaya, bahasa, kalibrasi. Pembahasan memakai urutan lain lagi. Pembaca tidak bisa mengikuti satu benang.
2. **Validitas label (IV-B) terselip di antara RQ1 dan RQ2.** Isinya adalah pemeriksaan kualitas test set, bukan hasil model. Tempatnya bersama konstruksi test set.
3. **Analisis subkelompok ada di RQ1** (`L409`, Tabel groups dan sources, Fig. groups), padahal pertanyaannya "di mana StaticKD lemah" (RQ4).
4. **Metodologi berisi sepuluh subbab tanpa pengelompokan.** Metode StaticKD, data, test set, baseline, protokol, dan benchmark bercampur. Urutannya juga lompat-lompat: data distilasi, lalu test set, lalu kembali ke teacher yang melabeli data distilasi.
5. **Pendahuluan memuat ringkasan jawaban RQ** (`L62`) yang diulang lagi di Pembahasan dan Kesimpulan.
6. **Pembahasan tidak bersubbab.** Sepuluh paragraf berurutan tanpa penanda topik, dan banyak angka Hasil diulang.
7. **Limitations berdiri sebagai bab sendiri** yang cukup panjang. Di IEEE Access, bagian ini lazim menjadi subbab Pembahasan.
8. **Float terlalu banyak:** 12 tabel dan 10 gambar dalam 18 halaman template IEEE Access. Beberapa gambar mengulang isi tabel: Fig. groups sama dengan Tabel groups, Fig. latency dengan Tabel eff, Fig. temperature dengan Tabel ablation.

2.2 Isi yang perlu dipertahankan

- Uji berpasangan dengan *site-cluster bootstrap*, Holm, ablasi lima seed, dan analisis per bahasa dan label. Ini kekuatan utama naskah.
- Hasil negatif yang jujur: hard label sama dengan soft label, embedding beku lebih baik di test, dan τ tinggi merugikan.
- Tabel posisi (*related approaches*), peran set data, komposisi test set, Fig. 1 *pipeline*, Fig. *trade-off*, serta Fig. per bahasa dan per label.

2.3 Isi yang tidak perlu ada di naskah utama (pindah ke suplemen)

Pemindahan ke berkas suplemen tidak menghilangkan isi. Teks utama tetap merujuknya.

- Tabel hyperparameter dan Tabel lisensi. Keduanya detail reproduksi, dan teks utama sudah menyebut nilai pentingnya.
- Fig. heatmap test set, Fig. groups, Fig. temperature, Fig. ensemble size, Fig. latency/RAM/size, dan Fig. calibration. Semua angkanya sudah ada di tabel atau teks.
- Untuk mencapai anggaran halaman, empat item ini juga dipindah:
  - Algorithm 1, yang isinya sama dengan persamaan (3);
  - Tabel per sumber dan Tabel faktor per bahasa, karena angka yang dibahas tetap ada di teks;
  - Fig. per label.

2.4 Isi yang kurang (dibahas di `rencana_perubahan.tex`)

- Verifikasi label oleh manusia dengan ukuran kesepakatan (bisa dikerjakan 4–5 orang), dan pencatatan pemeriksaan oleh dua peneliti.
- *Paired cluster bootstrap* untuk ablasi, beserta pembedaan antara signifikansi statistik dan signifikansi praktis.
- Alasan kuantitatif kenapa CPU dipilih, bukan GPU kecil. Teacher di GPU laptop sudah memproses 50,1 dok/s, sementara satu juta artikel per hari setara 11,6 dok/s.
- Hipotesis eksplisit (tuntutan mata kuliah), pernyataan AI yang lengkap, dan baseline Model2Vec.

3 Struktur baru

3.1 Prinsip

1. **Satu benang:** masalah, metode, data, setup, lalu hasil per RQ, pembahasan per tema, dan kesimpulan. Urutan RQ sama di Pendahuluan, Hasil, dan Pembahasan.
2. **RQ diurutkan ulang** agar pasangan akurasi dan biaya (klaim utama) muncul berdampingan. RQ1 akurasi tetap. RQ2 menjadi biaya CPU (dulu RQ3). RQ3 menjadi komponen resep (dulu RQ2). RQ4 kelemahan tetap. Isi setiap RQ tidak berubah.
3. **Metodologi dipecah menjadi tiga bab:** metode StaticKD (apa yang diusulkan), data dan test set (dengan apa diuji), dan setup eksperimen (bagaimana diuji).
4. **Semua tentang kualitas test set dikumpulkan di satu tempat**, termasuk validitas label.

3.2 Kerangka dan anggaran halaman (template IEEE Access)

Bagian baru	Isi dan tujuan	Hlm
Abstract, Index Terms	Tetap	–
I. Introduction	Masalah, biaya, celah, ide StaticKD, celah evaluasi, RQ1–RQ4, kontribusi, peta naskah	1,4
II. Related Work	A. Klasifikasi topik berita dan IPTC; B. Distilasi ke *student* kecil (digabung dengan *capacity gap*); C. Embedding statis dan inferensi CPU; D. Label editorial, kontaminasi, ketergantungan sampel; Tabel I	1,0
III. The StaticKD Method	A. Study Overview (Fig. 1); B. Problem Formulation; C. Teacher and Distillation Labels; D. Student Model and Training; E. Folding, Table Ensemble, and Compact Variant	1,8
IV. Data and Test Set	A. Data Sets and Their Roles (Tabel data); B. Distillation Data; C. Unified Test Set Construction (Tabel komposisi); D. Validity of the Editorial Labels	1,8
V. Experimental Setup	A. Baselines; B. Evaluation Protocol and Statistical Tests; C. Efficiency Protocol; D. Ablation Design; E. Implementation Details. Urutannya mengikuti RQ1, RQ2, RQ3	1,2
VI. Results	A. Accuracy (RQ1); B. CPU Cost (RQ2); C. Recipe Components (RQ3); D. Weaknesses by Language, Label, and Source (RQ4); E. Calibration and Cascade Mode	4,0
VII. Discussion	A. Why a Token Table Suffices; B. Where the Accuracy Comes From; C. Weak Languages and Model Selection; D. Practical Implications; E. Limitations	1,6
VIII. Conclusion	Tetap	0,4
Availability, Acknowledgment	Tetap, dengan rujukan ke Tabel S4	0,3

Bagian baru	Isi dan tujuan	Hlm
References, biografi	–	1,6
Total rencana		14,1
Total tercapai (tanpa mengubah makna)	Lihat `restructure_log.md`	15,0

Selisih satu halaman dari rencana muncul karena float utama (Tabel main, sig, eff, ablation, groups, Fig. 1, Fig. trade-off, Fig. per bahasa) dan referensi saja sudah memakan sekitar 5,5 halaman. Halaman ke-14 hanya bisa dicapai dengan memangkas isi. Itu keputusan penulis, dan rencananya ada di `rencana_perubahan.tex`.

3.3 Peta paragraf lama ke baru

Kode: **tetap** = teks sama di posisi yang sama, **pindah** = teks sama di posisi baru, **suplemen** = pindah ke berkas suplemen, **hapus** = dihapus karena isinya sudah ada di bagian lain.

Lama	Status	Posisi baru dan catatan
Pendahuluan dan Related Work		
L50–L58 (I, P1–P5)	**tetap**	I
L60 RQ	**tetap**	I. Urutan kalimat RQ2/RQ3 ditukar sesuai prinsip 2
L62 ringkasan jawaban RQ	**hapus**	Isinya ada di abstrak, VII-B, dan VIII
L64–L72 kontribusi, peta	**tetap**	I. Peta naskah diperbarui sesuai bab baru
L76–L80 II-A, II-B	**tetap**	II-A, II-B
L81–L82 II-C Temperature	**pindah**	Menjadi paragraf kedua II-B, tanpa judul subbab sendiri
L84–L109 II-D, II-E, Tabel I	**tetap**	II-C, II-D
Metodologi lama		
L113–L118 Study Design P1–P3	**pindah**	III-A Study Overview, beserta Fig. 1
L120, Tabel datasets	**pindah**	IV-A
L144–L172 Fig. 1 (TikZ)	**pindah**	III-A. TikZ dikompilasi menjadi `figures/fig_pipeline.pdf`, karena TikZ bentrok dengan kelas `ieeeaccess`
L174–L175 Problem Formulation	**pindah**	III-B
L177–L189 Distillation data	**pindah**	IV-B
L191–L234 Test set, Tabel komposisi	**pindah**	IV-C
L236–L241 Fig. heatmap	**suplemen**	Fig. S1 (nomor S mengikuti urutan rujukan pertama di naskah baru)
L243–L245 Teacher	**pindah**	III-C
L247–L262 Student	**pindah**	III-D
L264–L269, L282 Folding, compact	**pindah**	III-E
L271–L280 Algorithm 1	**suplemen**	Algorithm S1
L284–L319 Tabel hparams	**suplemen**	Tabel S1
L321–L325 Baselines	**pindah**	V-A
L327–L331 Protokol evaluasi	**pindah**	V-B
L333–L337 Efisiensi	**pindah**	V-C
L341 Experimental design	**pindah**	Dipecah: desain ablasi ke V-D; waktu run dan versi pustaka ke V-E
Hasil lama		
L347–L407 IV-A (Tabel main, sig)	**pindah**	VI-A (RQ1)
L409 subkelompok	**pindah**	Dipecah: kalimat subkelompok ke VI-D; kalimat sensitivitas 5 per situs tetap di VI-A
L411–L445 Tabel groups, teks sumber	**pindah**	VI-D (RQ4)
L447–L465 Tabel sources	**suplemen**	Tabel S2
L467–L472 Fig. groups	**suplemen**	Fig. S5
L474–L482 IV-B Validity	**pindah**	IV-D
L484–L541 IV-C Ablasi	**pindah**	VI-C (RQ3)

Lama	Status	Posisi baru dan catatan
L543–L555 Fig. temperature, ensemble	**suplemen**	Fig. S3, Fig. S4
L557–L592 IV-D Efisiensi, Fig. tradeoff	**pindah**	VI-B (RQ2)
L594–L599 Fig. latency	**suplemen**	Fig. S2
L601–L637 IV-E per bahasa dan label	**pindah**	VI-D (RQ4). Tabel factors (L603–L623) menjadi Tabel S3
L639–L644 Fig. per label	**suplemen**	Fig. S6
L646–L668 IV-F kalibrasi, Tabel cascade	**pindah**	VI-E
L670–L675 Fig. calibration	**suplemen**	Fig. S7
Pembahasan, Limitations, Kesimpulan		
L679, L681	**pindah**	VII-A
L683–L687	**pindah**	VII-B. “For RQ2” menjadi “For RQ3”
L689–L693	**pindah**	VII-C
L695, L697	**pindah**	VII-D. Tiga kalimat yang hanya mengulang angka VI-B dan VI-E dihapus (D2, D3)
L699–L715 Limitations	**pindah**	VII-E (subbab, teks sama)
L717–L755 Kesimpulan, Availability, Ack	**tetap**	VIII dan sesudahnya. Rujukan Tabel lisensi menjadi Tabel S4

4 Aturan restrukturisasi

1. **Makna dan gaya tidak diubah.** Kalimat dipindah utuh. Teks baru hanya berupa judul subbab, nomor RQ, rujukan ke suplemen, dan peta naskah di akhir Pendahuluan.
2. **Penghapusan hanya untuk kalimat yang isinya sudah ada di tempat lain.** Setiap penghapusan dicatat di `restructure_log.md` beserta tempat isinya masih ada.
3. **Perbaikan fakta di Bagian 1.3 tidak dikerjakan pada tahap ini**, karena mengubah isi. Semuanya masuk `rencana_perubahan.tex`.
4. **Naskah memakai kelas** `ieeeaccess` dari `paper_writing/template_ieeeaccess`. Biografi penulis masih *placeholder*.
5. **Pemeriksaan sesudah restrukturisasi:**
   - setiap kalimat lama ada di naskah baru, ada di suplemen, atau tercatat sebagai dihapus;
   - tidak ada rujukan `??`;
   - `scripts/check_paper.py` untuk angka;
   - `scripts/check_style.py` untuk teks baru.